2024-2025学年广东省职业院校技能大赛

中职组大数据应用与服务赛项

样

题

3

一、背景描述

大数据时代背景下，人们的出行方式发生了显著变化。共享单车作为一种新型的城市短途出行解决方案，不仅满足了人们"最后一公里"的出行需求，也为城市交通带来了新的活力。在传统的运营模式中，由于缺乏数据支持，共享单车的投放和调度主要依靠运营人员的经验判断，导致供需失衡、车辆分布不均等问题。而在大数据时代，通过对骑行数据的分析，可以更精准地预测用户需求，优化车辆调度，提升运营效率。

共享单车平台可以收集包括用户骑行轨迹、使用时段、车辆状态等多维度数据。通过对这些数据的分析，可以识别热门区域和时段，预测车辆使用需求，优化调度策略，同时也能够对车辆维护进行预警，提升用户体验。这些数据还可以为城市交通规划提供重要参考，助力智慧城市建设。

因数据驱动的大数据时代已经到来，没有大数据，我们无法为用户提供高效的共享单车服务。为完成共享单车使用数据分析工作，你所在的小组将应用大数据技术，通过Python语言以数据采集为基础，将采集的数据进行相应处理，并且进行数据标注、数据分析与可视化、通过大数据业务分析方法实现相应数据分析。运行维护数据库系统保障存储数据的安全性。通过运用相关大数据工具软件解决具体业务问题。你们作为该小组的技术人员，请按照下面任务完成本次工作。

二、模块一：平台搭建与运维

（一）任务一：大数据平台搭建

1．子任务一：基础环境准备

本任务需要使用 root 用户完成相关配置，安装 Hadoop 需要配置前置环境。命令中要求使用绝对路径，具体要求如下：

（1）配置三个节点的主机名，分别为 master、slave1、slave2，然后修改三个节点的 hosts 文件，使得三个节点之间可以通过主机名访问，在 master上将执行命令 cat /etc/hosts 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）将 /opt/software 目录下将文件 jdk-8u191-linux-x64.tar.gz 安装包解压到 /opt/module 路径中，将 JDK 解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 /etc/profile 文件中配置 JDK 环境变量 JAVA_HOME 和 PATH 的值，并让配置文件立即生效，将在 master上 /etc/profile 中新增的内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

（4）查看 JDK 版本，检测 JDK 是否安装成功，在 master 上将执行命令 java -version 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（5）创建 hadoop 用户并设置密码，为 hadoop 用户添加管理员权限。在 master 上将执行命令 grep 'hadoop' /etc/sudoers 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（6）关闭防火墙，设置开机不自动启动防火墙，在 master 上将执行命令 systemctl status firewalld 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（7）配置三个节点的 SSH 免密登录，在 master 上通过 SSH 连接 slave1 和 slave2 来验证。

2．子任务二：Hadoop 完全分布式安装配置

本任务需要使用 root 用户和 hadoop 用户完成相关配置，使用三个节点完成 Hadoop 完全分布式安装配置。命令中要求使用绝对路径，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将文件 hadoop-3.3.6.tar.gz 安装包解压到 /opt/module 路径中，将 hadoop 安装包解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）在 master 节点中将解压的 Hadoop 安装目录重命名为 hadoop，并修改该目录下的所有文件的所属者为 hadoop，所属组为 hadoop，将修改所属者的完整命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中使用 hadoop 用户依次配置 hadoop-env.sh、core-site.xml、hdfs-site.xml、mapred-site.xml、yarn-site.xml、masters 和

workers 配置文件，Hadoop集群部署规划如下表，将 yarn-site.xml 文件内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

服务器	master	slave1	slave2
HDFS	NameNode		
HDFS	SecondaryNameNode		
HDFS	DataNode	DataNode	DataNode
YARN	ResourceManager		
YARN	NodeManager	NodeManager	NodeManager
历史日志服务器	JobHistoryServer		

（二）任务二：数据库服务器的安装与运维

1. 子任务一：MySQL 安装配置

本任务需要使用 rpm 工具安装 MySQL 并初始化，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将 MySQL 5.7.44 安装包解压到 /opt/module 目录下；

（2）在 master 节点中使用 rpm -ivh 依次安装 mysql-community-common、mysql-community-libs、mysql-community-libs-compat、mysql-community-client 和 mysql-community-server 包，将所有命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中启动数据库系统并初始化 MySQL 数据库系统，将完整命令复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：MySQL 运维

本任务需要在成功安装 MySQL 的前提下，对 MySQL 进行运维操作，具体要求如下：

（1）配置服务端 MySQL 数据库的远程连接，将新增的配置内容复制粘贴至【提交结果.docx】中对应的任务序号下；

（2）配置 root 用户允许任意 IP 连接，将完整命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）通过 root 用户登录 MySQL 数据库系统，查看 mysql 库下的所有表，将完整命令及执行命令后的结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（4）创建新的用户 bike_admin，将完整命令及执行命令后的结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（5）创建数据库 bike_data，并设置正确的字符集，将完整命令及执行命令后的结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（6）授予新用户查询数据和插入数据的权限，将完整命令及执行命令后的结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（7）刷新权限，将完整命令及执行命令后的结果复制粘贴至【提交结果.docx】中对应的任务序号下。

3. 子任务三：数据表的创建及维护

（1）根据以下数据字段在 bike_data 数据库中创建骑行记录表（ride_records）。骑行记录表字段如下：

字段	类型	中文含义	备注
id	int	记录编号	主键
bike_id	varchar	单车编号	
user_id	varchar	用户ID	
start_time	datetime	开始时间	
end_time	datetime	结束时间	
start_location	varchar	起始位置	
end_location	varchar	结束位置	
ride_distance	double	骑行距离(km)	
ride_duration	int	骑行时长(分钟)	

（2）根据以下数据字段在 bike_data 数据库中创建单车状态表（bike_status）。单车状态表字段如下：

字段	类型	中文含义	备注
bike_id	varchar	单车编号	主键

status	varchar	车辆状态
battery_level	int	电量百分比
last_maintain_time	datetime	最后维护时间
current_location	varchar	当前位置
total_mileage	double	总里程(km)

将这两个 SQL 建表语句分别复制粘贴至【提交结果.docx】中对应的任务序号下。

（3）根据已提供的 SQL 文件将这两份数据导入 bike_data 数据库中，并对其中的数据进行如下操作：

- 在 ride_records 表中查询骑行时长超过60分钟的记录数量；
- 在 bike_status 表中统计各个状态的单车数量；

将这两个 SQL 语句分别复制粘贴至【提交结果.docx】中对应的任务序号下。

三、模块二：数据获取与处理

（一）任务一：数据获取与清洗

1. 子任务一：数据获取

有一份共享单车使用数据，包含以下字段：骑行ID、单车编号、用户ID、开始时间、结束时间、起始位置、结束位置、骑行距离(km)、骑行时长(分钟)、天气状况、温度、周末标记。

数据已存入 bike_rides.csv 文件中，请使用 pandas 读取 bike_rides.csv 并将数据集的前10行打印在 IDE 终端的截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：使用 Python 进行数据清洗

现已从共享单车平台获取到原始数据集，为保障用户隐私和商业敏感信息，已进行数据脱敏处理。数据脱敏是指对某些敏感信息通过脱敏规则进行数据的变形，实现敏感隐私数据的可靠保护。在涉及用户安全数据或者商业敏感数据的情况下，不违反系统规则条件下，对真实数据进行改造并提供测试使用。

请使用 pandas 库加载并分析相关数据集，根据题目规定要求使用 pandas 库实现数据处理，具体要求如下：

（1）删除骑行距离为空或为0的记录，并将结果存储为 cleaned_data_c1_N.csv，N 为删除的数据条数；

（2）删除骑行时长小于1分钟或大于24小时的异常记录，并将结果存储为 cleaned_data_c2_N.csv，N 为删除的数据条数；

（3）将天气状况中的空值替换为该时段最常见的天气状况，并存储为 cleaned_data_c3_N.csv，N 为修改的数据条数；

（4）识别并删除重复的骑行记录，将结果存储为 cleaned_data_c5_N.csv，N 为删除的数据条数；

将该 4 个文件名截一张图复制粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据标注

1. 子任务一：骑行距离分类标注

使用 Python 编写脚本，根据骑行距离将骑行记录分为三类："短途"、"中途"和"长途"。具体的分类要求如下：

（1）短途：骑行距离小于2公里；

（2）中途：骑行距离在2公里至5公里之间；

（3）长途：骑行距离超过5公里；

在数据集中新增一列"距离分类"，根据上述标准对每条骑行记录进行分类标注，存入 ride_distance_mark.csv 文件中。具体格式如下：

骑行ID	开始时间	骑行距离(km)	距离分类
1001	2025-01-01 08:30:00	3.5	中途

将 ride_distance_mark.csv 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：时段热度标注

使用 Python 编写脚本，基于骑行开始时间，对每个时段进行热度标注。具体的分类要求如下：

（1）高峰时段：工作日的7:00-9:00和17:00-19:00；

（2）平峰时段：工作日的9:00-17:00和19:00-22:00；

（3）低峰时段：工作日的22:00-次日7:00以及周末全天。

在数据集中新增一列"时段热度"，根据上述标准对每条骑行记录进行时段标注，存入 time_period_mark.csv 文件中。具体格式如下：

骑行ID	开始时间	周末标记	时段热度
1001	2025-01-01 08:30:00	0	高峰时段

将 time_period_mark.csv 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

（三）任务三：数据统计

1. 子任务一：HDFS 文件操作

本任务需要使用 Hadoop、HDFS 命令，已安装 Hadoop 及需要配置前置环境，具体要求如下：

（1）在 HDFS 目录下新建目录 /bike_data，将新建目录的完整命令粘贴至【提交结果.docx】中对应的任务序号下；

（2）修改权限，赋予目录 /bike_data 最高 777 权限，将修改目录权限的完整命令粘贴至【提交结果.docx】对应的任务序号下；

（3）下载 HDFS 新建目录 /bike_data，到本地容器 master 指定目录 /tmp下，将完整命令粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：计算输入文件中的单词数

本任务需要使用 Hadoop 默认提供的 wordcount 示例来完成单词数统计任务，具体要求如下：

（1）在 HDFS 上创建 /user/hadoop/input 目录；

（2）在 master 节点将 /var/log/dmesg 文件上传到 HDFS 的 /user/hadoop/input 目录下；

（3）使用 Hadoop 中提供的 wordcount 示例对 HDFS 上的 dmesg 文件进行单词统计，并将统计结果存储到 HDFS 的 /user/hadoop/output 目录下；

（4）查看 HDFS 中的 /user/hadoop/output 单词数统计结果并将结果前十行截图粘贴至【提交结果.docx】中对应的任务序号下。

3．子任务三：计算区域平均骑行时长

本任务需要使用 MapReduce 框架计算每个区域的平均骑行时长，具体要求如下：

（1）编写 MapReduce 程序，计算每个区域（根据起始位置划分）的平均骑行时长。输入数据格式为：

```
起始位置,结束位置,骑行时长(分钟)

朝阳区望京,朝阳区大屯,15

海淀区中关村,海淀区五道口,22

...
```

（2）Map 函数需要从输入数据中提取起始位置的区域名称和骑行时长，Reduce 函数需要计算每个区域的平均骑行时长；

（3）将计算结果输出到 HDFS 的 /user/hadoop/avg_duration 目录下，输出格式为：

```
区域名称　　平均骑行时长(分钟)
```

朝阳区 18.5

海淀区 20.3

...

（4）将程序运行结果截图粘贴至【提交结果.docx】中对应的任务序号下。

四、模块三：业务分析与可视化

（一）任务一：数据分析与可视化

1．子任务一：数据分析

数据分析是理解共享单车使用模式的重要手段，可以揭示用户偏好、使用高峰和运营效率。在这个任务中，我们将运用 Python 对共享单车使用数据进行深入分析，以获取关键洞察。参赛者需要运用 Python 的数据处理和分析库，如 Pandas 来完成以下任务：

（1）按开始时间统计每个小时的平均骑行量，进行倒序排序展示前三个高峰时段；

（2）计算不同天气状况下的平均骑行时长和平均骑行距离；

（3）分析工作日和周末的骑行模式差异，计算两者的平均骑行量、平均骑行时长和平均骑行距离；

（4）统计每个区域的起始和结束骑行次数，识别最热门的上车区域和下车区域；

（5）分析温度对骑行量的影响，计算不同温度区间（0-10℃、10-20℃、20-30℃、30℃以上）的平均骑行量；

将该 5 个统计结果在 IDE 的控制台中打印并分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：数据可视化

在这个任务中，参赛者将使用 pyecharts 库来创建直观、互动的图表，以展示共享单车使用的关键模式和趋势。具体要求如下：

（1）创建时间热力图展示一周内各时段的骑行量分布，横轴为星期（周一至周日），纵轴为小时（0-23时），颜色深浅表示骑行量的多少；

（2）使用折线图展示一天24小时内的骑行量变化趋势，图中需要包含工作日和周末两条折线，以便对比不同类型日期的使用模式差异；

（3）制作区域流向图，展示不同区域之间的骑行流量，使用箭头的粗细表示流量大小，颜色表示平均骑行时长；

（4）创建散点图分析气温与骑行量的关系，横轴为温度，纵轴为日骑行量，每个点的大小表示平均骑行时长，颜色表示天气状况；

将该 4 个可视化图表分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：业务分析

在共享单车运营中，准确理解用户需求、使用模式和运营效率至关重要。通过分析骑行数据，可以优化运营策略，提升服务质量。本任务中使用 Python 对骑行数据进行深入的业务分析，目的是识别关键运营指标，并提出基于数据的改进建议。

使用提供的骑行数据集，计算以下指标：

（1）单车周转率

- 日均使用次数 = 单车每日骑行订单数的平均值
- 日均使用时长 = 单车每日总骑行时长的平均值（小时）
- 计算周转率 = 日均使用时长 / 24小时，结果以百分比表示
- 需分别计算工作日和周末的周转率

（2）区域供需分析

- 区域供需平衡指数计算方法：
    - 计算每个区域的供给量 = 该区域结束骑行的单车数量

    - 计算每个区域的需求量 = 该区域开始骑行的单车数量
    - 供需平衡指数 = (供给量 - 需求量) / 需求量 × 100%
    - 指数为正表示供大于求，为负表示供不应求
    - 理想范围应在 ±20% 之内

（3）高峰期分析

- 对于每个区域在工作日早晚高峰时段（7:00-9:00，17:00-19:00）：
    - 计算平均小时需求量 = 该时段内每小时发起的骑行订单数量
    - 计算实际供给量 = 该时段内区域内可用单车数量
    - 计算供需比 = 实际供给量 / 平均小时需求量
    - 供需比低于1.2的区域被认定为供给不足
    - 供需比高于2.0的区域被认定为供给过剩

根据上述分析结果，请撰写一份简短的分析报告（300字以内），内容应包括：

- 当前运营情况的主要发现
- 存在的关键问题和挑战
- 至少三条具体的优化建议，并说明预期效果

将分析报告内容复制粘贴至【提交结果.docx】中对应的任务序号下。