2024-2025学年广东省职业院校技能大赛

中职组大数据应用与服务赛项

样

题

4

一、背景描述

大数据时代背景下，人们生活习惯发生了很多改变。在传统运营模式中，缺乏数据积累，人们在做出一些决策行为过程中，更多是凭借个人经验和直觉，发展路径比较自我封闭。而大数据时代，为人们提供一种全新的思路，通过大量的数据分析得出的结果将更加现实和准确。旅游行业作为现代服务业的重要组成部分，其数据分析对于提升游客体验、优化资源配置具有重要意义。通过收集和分析游客的行为数据，包括景点偏好、消费习惯、住宿选择等，可以为旅游服务提供者制定更精准的运营策略提供依据。

因数据驱动的大数据时代已经到来，没有大数据，我们无法为用户提供大部分服务。为完成旅游景区客流量预测与分析工作，你所在的小组将应用大数据技术，通过 Python 语言以数据采集为基础，将采集的数据进行相应处理，并且进行数据标注、数据分析与可视化、通过大数据业务分析方法实现相应数据分析。运行维护数据库系统保障存储数据的安全性。通过运用相关大数据工具软件解决具体业务问题。你们作为该小组的技术人员，请按照下面任务完成本次工作。

二、模块一：平台搭建与运维

（一）任务一：大数据平台搭建

1．子任务一：基础环境准备

本任务需要使用 root 用户完成相关配置，安装 Hadoop 需要配置前置环境。命令中要求使用绝对路径，具体要求如下：

（1）配置三个节点的主机名，分别为 master、slave1、slave2，然后修改三个节点的 hosts 文件，使得三个节点之间可以通过主机名访问，在 master上将执行命令 cat /etc/hosts 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）将 /opt/software 目录下将文件 jdk-8u191-linux-x64.tar.gz 安装包解压到 /opt/module 路径中，将 JDK 解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 /etc/profile 文件中配置 JDK 环境变量 JAVA_HOME 和 PATH 的值，并让配置文件立即生效，将在 master上 /etc/profile 中新增的内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

（4）查看 JDK 版本，检测 JDK 是否安装成功，在 master 上将执行命令 java -version 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（5）创建 hadoop 用户并设置密码，为 hadoop 用户添加管理员权限。在 master 上将执行命令 grep 'hadoop' /etc/sudoers 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（6）关闭防火墙，设置开机不自动启动防火墙，在 master 上将执行命令 systemctl status fireawlld 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（7）配置三个节点的 SSH 免密登录，在 master 上通过 SSH 连接 slave1 和 slave2 来验证。

2．子任务二：Hadoop 完全分布式安装配置

本任务需要使用 root 用户和 hadoop 用户完成相关配置，使用三个节点完成 Hadoop 完全分布式安装配置。命令中要求使用绝对路径，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将文件 hadoop-3.3.6.tar.gz 安装包解压到 /opt/module 路径中，将 hadoop 安装包解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）在 master 节点中将解压的 Hadoop 安装目录重命名为 hadoop，并修改该目录下的所有文件的所属者为 hadoop，所属组为 hadoop，将修改所属者的完整命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中使用 hadoop 用户依次配置 hadoop-env.sh、core-site.xml、hdfs-site.xml、mapred-site.xml、yarn-site.xml、masters 和 workers 配置文件，Hadoop集群部署规划如下表，将 yarn-site.xml 文件内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

服务器	master	slave1	slave2
DHFS	NameNode		

HDFS	SecondaryNameNode		
HDFS	DataNode	DataNode	DataNode
YARN	ResourceManager		
YARN	NodeManager	NodeManager	NodeManager
历史日志服务器	JobHistoryServer		

（4）在 master 节点中使用 scp 命令将配置完的 hadoop 安装目录直接拷贝至 slave1 和 slave2 节点，将完整的 scp 命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（5）在 slave1 和 slave2 节点中将 hadoop 安装目录的所有文件的所属者为 hadoop，所属组为 hadoop。

（6）在三个节点的 /etc/profile 文件中配置 Hadoop 环境变量 HADOOP_HOME 和 PATH 的值，并让配置文件立即生效，将 master 节点中 /etc/profile 文件新增的内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

（7）在 master 节点中初始化 Hadoop 环境 namenode，将初始化命令及初始化结果（截取初始化结果日志最后 20 行即可）粘贴至【提交结果.docx】中对应的任务序号下；

（8）在 master 节点中依次启动HDFS、YARN集群和历史服务。在 master 上将执行命令 jps 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（9）在 slave1 查看 Java 进程情况。在 slave1上将执行命令 jps 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据库服务器的安装与运维

1. 子任务一：MySQL 安装配置

本任务需要使用 rpm 工具安装 MySQL 并初始化，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将 MySQL 5.7.44 安装包解压到 /opt/module 目录下；

（2）在 master 节点中使用 rpm -ivh 依次安装 mysql-community-common、mysql-community-libs、mysql-community-libs-compat、mysql-community-client 和 mysql-community-server 包，将所有命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中启动数据库系统并初始化 MySQL 数据库系统，将完整命令复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：MySQL 运维

本任务需要在成功安装 MySQL 的前提，对 MySQL 进行运维操作，具体要求如下：

（1）配置 MySQL 服务器的最大连接数为 1000，并将配置命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（2）创建数据库 tourism 并设置默认字符集为 utf8mb4，并将设置命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）创建一个名为 tourism_backup 的定时备份脚本，每天凌晨 2 点自动备份数据库 tourism，将脚本内容复制粘贴至【提交结果.docx】中对应的任务序号下；

（4）优化 MySQL 查询性能，开启慢查询日志，设置超过 3 秒的查询被记录，将配置命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（5）配置 MySQL 的 binlog 日志，设置过期时间为 7 天，将配置命令复制粘贴至【提交结果.docx】中对应的任务序号下。

3. 子任务三：数据表的创建及维护

（1）根据以下数据字段在 tourism 数据库中创建景区信息表（scenic_spot）。景区信息表字段如下：

字段	类型	中文含义	备注

spot_id	int	景区编号	主键
spot_name	varchar	景区名称	
city	varchar	所在城市	
level	varchar	景区等级	
type	varchar	景区类型	
ticket_price	decimal	门票价格	
opening_hours	varchar	开放时间	
max_capacity	int	最大承载量	

（2）根据以下数据字段在 tourism 数据库中创建游客流量表（visitor_flow）。游客流量表字段如下：

字段	类型	中文含义	备注
record_id	int	记录ID	主键
spot_id	int	景区编号	外键
visit_date	date	参观日期	
visitor_count	int	游客数量	
peak_hour	time	高峰时段	
weather	varchar	天气状况	
is_holiday	boolean	是否节假日	

将这两个 SQL 建表语句分别复制粘贴至【提交结果.docx】中对应的任务序号下。

（3）将提供的数据文件导入数据库 tourism 中并编写以下数据库操作语句：

- 查询2024年1月每个景区的总游客人数。查询结果需要显示景区名称、所在城市和游客总数，并按游客总数降序排列。
- 统计每个景区在节假日和非节假日的平均游客数量。查询结果需要显示景区名称、景区等级、节假日平均游客数和非节假日平均游客数，按景区编号排序。
- 找出所有景区中单日游客量超过该景区最大承载量的情况。查询结果需要显示景区名称、参观日期、实际游客数量、最大承载量和超出人数，按超出人数降序排列。

将这三个 SQL 语句分别复制粘贴至【提交结果.docx】中对应的任务序号下。

三、模块二：数据获取与处理

（一）任务一：数据获取与清洗

1. 子任务一：数据获取

有一份景区游客数据文件：景区名称、日期、游客来源地、游客年龄段、停留时长（小时）、消费金额（元）、满意度评分、出行方式、天气状况等信息。

数据已存入到 tourist_data.csv 文件中，请使用 pandas 读取 tourist_data.csv 并将数据集的前10行打印在 IDE 终端的截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：使用 Python 进行数据清洗

请使用 pandas 库加载并分析相关数据集，根据题目规定要求使用 pandas 库实现数据处理，具体要求如下：

（1）删除天气状况为空或为零的记录，并将结果存储为 cleaned_data_c1_N.csv，N 为删除的数据条数；

（2）删除停留时长异常（超过24小时或小于0.1小时）的记录，并将结果存储为 cleaned_data_c2_N.csv，N 为删除的数据条数；

（3）将游客来源地为空的记录填充为"未知"，并存储为 cleaned_data_c3_N.csv，N 为修改的数据条数；

（4）将满意度评分超出范围（0-5分）的记录删除，并将结果存储为 cleaned_data_c4_N.csv，N 为删除的数据条数；

（5）将消费金额明显异常（超过该景区平均消费金额5倍）的记录删除，将结果存储为 cleaned_data_c5_N.csv，N 为删除的数据条数。

将该 5 个文件名截一张图复制粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据标注

1. 子任务一：游客价值分类标注

使用 Python 编写脚本，根据游客的消费金额和停留时长对游客进行价值分类标注。具体的分类要求如下：

（1）高价值游客：消费金额高于平均值的1.5倍且停留时长超过4小时；

（2）中价值游客：消费金额在平均值的0.5-1.5倍之间且停留时长在2-4小时之间；

（3）低价值游客：不满足上述条件的游客。

在数据集中新增一列"游客价值类型"，根据上述标准进行标注，存入 tourist_value_mark.csv 文件中。具体格式如下：

编号	景区名称	消费金额(元)	停留时长(小时)	游客价值类型
1	西湖	1200	5.5	高价值游客

将 tourist_value_mark.csv 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：旅游旺季标注

使用 Python 编写脚本，根据每月的游客数量和平均消费对旅游季节进行标注。具体的分类要求如下：

（1）旺季：月游客量超过年平均值的120%且月平均消费超过年平均值的110%；

（2）平季：月游客量在年平均值的80%-120%之间或月平均消费在年平均值的90%-110%之间；

（3）淡季：月游客量低于年平均值的80%且月平均消费低于年平均值的90%。

在数据集中新增一列"季节类型"，根据上述标准对每个月份进行标注，存入 season_mark.csv 文件中。具体格式如下：

月份	游客总量	平均消费(元)	同比年平均	季节类型
1月	45000	980	85%	淡季

将 season_mark.csv 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

（三）任务三：数据统计

1. 子任务一：HDFS 文件操作

本任务需要使用 Hadoop、HDFS 命令，已安装 Hadoop 及需要配置前置环境，具体要求如下：

（1）在 HDFS 目录下新建目录 /tourism_data，将新建目录的完整命令粘贴至【提交结果.docx】中对应的任务序号下；

（2）修改权限，赋予目录 /tourism_data 最高 777 权限，将修改目录权限的完整命令粘贴至【提交结果.docx】对应的任务序号下；

（3）将本地的旅游数据集上传至 HDFS 的 /tourism_data 目录下，并验证文件是否上传成功，将完整命令粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：使用 MapReduce 进行数据分析

本任务需要使用 Hadoop 的 MapReduce 功能完成数据分析任务，具体要求如下：

（1）编写 MapReduce 程序，统计不同景区的每日平均游客数量；

（2）将统计结果存储到 HDFS 的 /tourism_analysis/daily_visitors 目录下；

（3）运行 MapReduce 程序并查看执行结果，将运行命令和结果的前十行截图粘贴至【提交结果.docx】中对应的任务序号下。

3. 子任务三：使用 Hive 进行数据分析

本任务需要使用 Hive 完成数据分析任务，具体要求如下：

（1）在 Hive 中创建外部表 tourist_flow，加载 HDFS 中的旅游数据；

（2）编写 HQL 查询，分析以下内容：

- 统计每个景区的月度游客总量
- 计算不同游客来源地的平均消费金额
- 统计不同天气状况下的游客总量

（3）将查询结果导出到本地文件系统，并将导出命令和结果截图粘贴至【提交结果.docx】中对应的任务序号下。

四、模块三：业务分析与可视化

（一）任务一：数据分析与可视化

1. 子任务一：数据分析

本任务要求使用 Python 对旅游数据进行深入分析，揭示游客行为模式和景区运营特点。参赛者需要使用 Python 的数据处理和分析库完成以下任务：

（1）分析各景区的游客来源地分布，找出每个景区最主要的客源地（占比超过20%）；

（2）计算不同年龄段游客的平均消费金额和停留时长，发现最具消费潜力的游客群体；

（3）分析周末和工作日的游客量差异，计算周末游客量相对工作日的增长百分比；

（4）统计不同出行方式的游客比例，并根据平均消费金额对出行方式进行排序；

（5）分析满意度评分与停留时长的关系，计算相关系数。

将这 5 个统计结果在 IDE 的控制台中打印并分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：数据可视化

本任务要求使用 pyecharts 库创建交互式数据可视化图表，帮助直观地展示旅游数据分析结果。具体要求如下：

（1）创建玫瑰图展示各景区游客量分布 要求：使用玫瑰图展示不同景区的年度游客总量占比，每个扇形区域的半径表示游客量大小，颜色深浅代表游客量级别，并添加图例说明和标题。图表需要支持鼠标悬停显示详细数据。

（2）制作气泡图分析景区特征 要求：创建气泡图展示各景区的特征分布，横轴表示平均消费金额，纵轴表示日均游客量，气泡大小表示满意度评分，颜色表示景区等级。图表需要支持图例筛选和缩放交互。

（3）绘制堆叠面积图展示游客来源地变化趋势 要求：使用堆叠面积图展示一年内各主要客源地游客量的变化趋势，不同颜色代表不同来源地，需要显示月度数据点，并支持区域高亮显示。

（4）创建雷达图对比不同游客群体特征 要求：使用雷达图对比不同年龄段游客的消费特征，包含消费金额、停留时长、满意度评分、重游率、景点打卡数等维度，并添加数据标签。

将以上 4 个可视化图表分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。图表必须包含完整的标题、图例、坐标轴标签等要素，确保图表清晰易读、专业美观。

（二）任务二：业务分析

旅游行业的数据分析对于提升景区运营效率和游客体验至关重要。本任务要求对旅游数据进行深入的业务分析，识别关键问题并提出改进建议。

1. 基础指标分析

使用提供的数据集，计算并分析以下核心指标：

（1）客流指标分析

- 日均客流量：计算每日游客总数的算术平均值
- 客流波动系数：使用标准差除以平均值来衡量客流的稳定性
- 节假日客流比：节假日期间日均客流量与普通日期日均客流量的比值

（2）消费行为分析

- 人均消费计算：游客总消费金额除以总游客人数
- 不同群体消费差异：按年龄段和来源地分组计算平均消费

（3）游客体验评估

- 满意度评分：采用5分制，计算所有有效评分的加权平均值

2. 运营建议

基于上述分析结果，从以下三个方面提出具体的运营优化建议：

（1）差异化票价策略：结合客流波动规律和游客消费能力，设计分时段、分群体的票价方案

（2）服务优化方案：针对满意度影响因素分析结果，提出服务改进的具体措施

（3）精准营销建议：基于高价值客群画像，设计有针对性的营销策略

请将分析报告（不超过300字）提交至【提交结果.docx】中对应的任务序号下。报告内容应包含数据分析结果和具体可行的运营建议。