2025-2026学年广东省职业院校技能大赛

中职组大数据应用与服务赛项

样

题

2

一、背景描述

在大数据时代背景下，教育行业正迎来深刻的结构性变革。传统教育模式往往依赖于教师的主观经验，缺乏对学习者行为的系统化洞察与精准评估。而在线教育平台的迅速发展，为教育领域注入了新的活力。通过汇聚并分析学习者在平台中产生的各类行为数据——例如课程选修偏好、学习进度、作业完成质量、互动参与频率等，教育者能够更全面、更客观地把握学习者的真实需求与个体特征。

基于用户的学习轨迹、知识掌握程度、学习时间分布等多维度数据，平台可构建精细化的个人学习画像，从而为每位学习者推荐更贴合其需求的课程内容，并提供个性化的学习路径指导。数据驱动已成为教育现代化的重要方向，在线教育平台需借助大数据分析来持续提升服务品质与教学效果。

为应对这一趋势，你们小组将依托大数据技术，以 Python 为主要工具，开展从数据采集、处理、标注到分析与可视化的全流程实践，并运用大数据业务分析方法完成特定场景下的数据分析任务。同时，需负责数据库系统的运行维护，保障数据存储的安全性与稳定性，最终通过大数据工具软件解决实际业务问题。作为小组的技术成员，请依据后续任务要求，完成本次大数据应用与服务的实践工作。

二、项目一：平台搭建与运维

（一）任务一：大数据平台搭建

1. 子任务一：基础环境准备

本任务需要使用 root 用户完成相关配置，安装 Hadoop 前置环境。命令中要求使用绝对路径，具体要求如下：

(1) 配置三个节点的主机名，分别为 master、node01、node02，然后修改每个节点的 hosts 文件，使其三个节点之间互相可以使用主机名访问，在 master 节点上执行 ping -c 4 node01 命令，将命令结果提交至【提交结果.docx】中对应的任务序号下；

(2) 在 master 节点上，将 /opt/software 目录下的文件 jdk-8u391-linux-x64.tar.gz 安装包解压到/opt/module 路径中（若路径不存在时，则需新建目录），执行 ll /opt/module 命令，将命令结果提交至【提交结果.docx】中对应的任务序号下；

(3) 在 master 节点上，在 /etc/profile 文件中配置 JDK 的环境变量 JAVA_HOME 和 PATH，并立即生效配置文件，在 master 上将/etc/profile 新

增的内容截图至【提交结果.docx】中对应的任务序号下；

(4) 在三个节点上，关闭防火墙，设置开机不自启动防火墙，在 master 节点上使用 systemctl status firewalld 命令，查看防火墙状态，将结果提交至【提交结果.docx】中对应的任务序号下；

(5) 配置三个节点的免密登录，并指定 SSH 密钥的类型为 rsa，在 master 节点上通过 SSH 连接 node01 和 node02 来验证，将验证结果截图至【提交结果.docx】中对应的任务序号下；

(6) 将 JDK 安装包分发至 node01 和 node02 对应节点的目录（目录不存在，则需创建）下，并配置 node01 和 node02 的环境变量，同时立即生效配置文件，将完整命令截图至【提交结果.docx】中对应的任务序号下；

(7) 查看 JDK 版本,检查 JDK 是否安装成功,在 node01 节点上将执行命令 java -version 的结果截图至【提交结果.docx】中对应的任务序号下；

(8) 在三个节点上创建 hadoop 用户和设置用户密码，并为 hadoop 用户添加管理员权限，在 master 节点上执行 grep 'hadoop' /etc/sudoers 命令并将结果截图至【提交结果.docx】中对应的任务序号下；

2. 子任务二：Hadoop 完全分布式安装配置

本任务需要使用 root 用户和 hadoop 用户完成相关配置，使用三个节点完成 Hadoop 完全分布式安装配置。命令中要求使用绝对路径，具体要求如下：

(1) 在 master 节点上将/opt/software 目录下的 hadoop-3.1.3.tar.gz 安装包解压到/opt/module 路径中，将解压 hadoop 安装包的完整命令截图至【提交结果.docx】中对应的任务序号下；

(2) 在 master 节点上将解压的 Hadoop 安装目录重命名为 hadoop，同时修改 Hadoop 安装目录及其子文件的所属者为 hadoop，所属组为 hadoop，将完整命令截图至【提交结果.docx】中对应的任务序号下；

(3) 根据如下 hadoop 集群规划表，使用 hadoop 用户，在 master 节点上依次配置 hadoop-env.sh、core-site.xml、hdfs-site.xml、mapred-site.xml、yarn-site.xml、workers 配置文件，并将 yarn-site.xml 文件的内容截图至【提交结果.docx】中对应的任务序号下；

服务器	master	node01	node02
HDFS	NameNode		
HDFS		SecondaryNameNode	
HDFS	DataNode	DataNode	DataNode
YARN	ResourceManager		

YARN	NodeManager	NodeManager	NodeManager
历史日志服务器		JobHistoryServer	

(4) 在 master 节点上配置/etc/profile 文件，添加 Hadoop 环境变量，并立即生效配置文件，在 master 节点上将/etc/profile 新增的内容截图至【提交结果.docx】中对应的任务序号下；

(5) 在 master 节点上使用 scp 命令，分发 Hadoop 的安装目录和环境变量至 node01 和 node02 节点，并将 Hadoop 安装目录的所属者和所属组修改为 hadoop，同时生效环境变量配置文件，将完整的 scp 分发命令截图至【提交结果.docx】中对应的任务序号下；

(6) 在 master 节点上使用 hadoop 用户初始化 Hadoop 环境 namenode 将初始化命令和结果（取最后 20 行）截图至【提交结果.docx】中对应的任务序号下；

(7) 在 master 节点上使用 hadoop 用户依次启动 HDFS、YARN 集群，在 node01 节点上启动历史日志服务。在 master 节点上执行 jps 命令，将命令及结果截图至【提交结果.docx】中对应的任务序号下；

(8) 在 node01 节点上执行 jps 命令，将命令及结果截图至【提交结果.docx】中对应的任务序号下；

（二）任务二：数据库服务器的安装与运维

1．子任务一：MySQL 安装配置

本任务要求使用 root 用户和 rpm 工具安装 MySQL 并初始化。命令中要求使用绝对路径，具体要求如下：

(1) 在 master 节点上将/opt/software 目录下的 mysql-5.7.25-1.el7.x86_64.rpm-bundle.tar 安装包解压到/opt/module 目录下。将解压命令和结果截图至【提交结果.docx】中对应的任务序号下；

(2) 在 master 节点上卸载自带的 mariadb，并使用 rpm 命令安装 MySQL 相关包，并将命令截图至【提交结果.docx】中对应的任务序号下；

(3)在 master 节点上执行 rpm -qa | grep mysql 命令，检验 MySQL 的安装情况。将结果截图至【提交结果.docx】中对应的任务序号下；

(4) 在 master 上启动数据库并完成初始化，将命令截图至【提交结果.docx】中对应的任务序号下；

2．子任务二：MySQL 运维

(1) 配置服务端 MySQL 的远程连接，将新增的配置内容截图至【提交结果.docx】中对应的任务序号下；

(2) 配置 root 用户允许任意 IP 连接，将命令和完整结果截图至【提交结果.docx】中对应的任务序号下；

(3) 使用 root 用户登录 MySQL 数据库，查看当前 MySQL 下所有的数据库，将命令和完整结果截图至【提交结果.docx】中对应的任务序号下；

(4) 创建 hadoop 用户，设置密码为 qwER12#$，并允许任意 IP 进行连接，将命令和完整结果截图至【提交结果.docx】中对应的任务序号下；

(5) 授予 hadoop 用户拥有对所有数据库的插入数据,查询数据,删除数据权限，将命令和完整结果截图至【提交结果.docx】中对应的任务序号下；

3．子任务三：数据表的创建及维护

（1）根据以下数据字段，在 education 数据库中创建课程信息表（course）。该表用于存储在线教育平台中各类课程的基本信息与运营数据。具体字段定义如下：

字段名	类型	中文含义	备注
course_id	int	课程 ID	主键
title	varchar(255)	课程标题	
subject	varchar(100)	所属学科	如：数学、编程、语言等
difficulty	char(10)	难度级别	枚举值：初级、中级、高级
total_lessons	int	总课时数	
original_price	decimal(10,2)	课程原价	
current_price	decimal(10,2)	课程现价	
teacher_name	varchar(100)	主讲教师	
publish_date	date	上架日期	
total_students	int	累计学习人数	
avg_review_score	float	平均好评率	范围：0.0 - 5.0

（2）根据以下数据字段，在 education 数据库中创建用户学习行为表（study_behavior）。该表用于记录用户对每门课程的具体学习过程与成效。具体字段定义如下：

字段名	类型	中文含义	备注
record_id	bigint	行为记录 ID	主键
user_id	int	用户 ID	
course_id	int	课程 ID	外键，关联 course 表
access_date	date	学习日期	
daily_study_minutes	int	当日学习时长(分钟)	
finished_lessons	int	当日完成课时数	
assignment_score	float	作业平均得分	

is_joined_discussion	tinyint	是否参与课堂讨论	1 是，0 否
note_count	int	当日笔记条数	

将上述两个创建表的 SQL 语句，分别编写并复制到【提交结果.docx】文档中对应的任务序号下。

（3）基于已创建的表，编写并完成以下业务分析查询：

查询各难度级别课程的平均好评率与平均学习人数。

统计每位主讲教师名下所有课程的总学习人次（需关联学习行为表）。

找出“编程”学科中，当日学习时长超过 60 分钟且完成了作业（作业得分大于 0）的所有学习记录。

将上述三个 SQL 查询语句，分别编写并复制到【提交结果.docx】文档中对应的任务序号下。

三、项目二：数据获取与处理

（一）任务一：数据获取与清洗

1．子任务一：数据获取

现有一份在线教育平台的用户学习行为数据集，包含以下字段：学员 ID、课程 ID、课程名称、课程类别、学习时长(分钟)、章节完成率、最近学习日期、测试得分、提问次数、登录设备、学习时间段。

该数据已存储在 user_study_log.csv 文件中，请使用 pandas 读取该文件，并将数据集的前 8 行打印输出。将 IDE 终端中显示结果的截图粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：使用 Python 进行数据清洗

原始数据集已进行初步脱敏处理。请使用 pandas 库加载数据，并按要求完成以下清洗步骤，每一步均需生成新的清洗后文件：

（1）删除“学习时长”为空值或小于等于 5 分钟的记录，将结果保存为 cleaned_step1_N.csv，其中 N 为删除的记录条数；

（2）将“测试得分”中小于 0 分的记录修正为 0 分，大于 100 分的记录修正为 100 分，将结果保存为 cleaned_step2_N.csv，其中 N 为修正的记录条数；

（3）将“最近学习日期”列统一转换为 YYYY-MM-DD 格式，并将结果保存为 cleaned_step3_N.csv，其中 N 为格式被修改的记录条数；

（4）删除“章节完成率”大于100%或小于0%的异常记录，将结果保存为cleaned_step4_N.csv，其中 N 为删除的记录条数；

（5）基于“学员 ID”、“课程 ID”和“最近学习日期”三列判断并删除完全重复的记录，将结果保存为 cleaned_step5_N.csv，其中 N 为删除的记录条数。

请将最终生成的 5 个文件名列表截图粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据标注

1．子任务一：学习投入度标注

根据“学习时长”和“提问次数”对单次学习会话的活跃度进行分级标注，规则如下：

（1）高度活跃：学习时长 > 45 分钟 且 提问次数 ≥ 3；

（2）一般活跃：学习时长在 15-45 分钟（含） 或 提问次数为 1-2；

（3）不活跃：学习时长 < 15 分钟 且 提问次数为 0。

在数据集中新增“活跃度等级”列，根据规则进行标注，并将结果保存为activity_label.csv 文件。将该文件打开后的前若干行内容截图粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：学习模式标注

根据用户主要使用的“登录设备”和“学习时间段”分析其学习习惯，定义以下偏好类型：

（1）晨间移动型：学习时间段集中在 06:00-09:00，且主要使用“手机”或“平板”；

（2）日间桌面型：学习时间段集中在 09:00-18:00，且主要使用“台式机”或“笔记本电脑”；

（3）深夜沉浸型：学习时间段集中在 22:00-次日02:00，设备不限，且平均单次学习时长 ≥ 60 分钟；

（4）跨设备灵活型：未明显集中于上述任一时段，且使用过至少两种设备类型。

为每位用户计算其最常使用的设备和最主要的学习时间段，据此标注“偏好类型”，将结果保存为 preference_analysis.csv 文件。将该文件打开后的前若干行内容截图粘贴至【提交结果.docx】中对应的任务序号下。

（三）任务三：数据统计

1．子任务一：HDFS 文件操作

（1）在 HDFS 上创建目录 /bigdata_edu/input；

（2）将本地清洗后的最终数据文件 cleaned_step5_N.csv 上传至该 HDFS 目录；

（3）检查该文件在 HDFS 中的存储状态，并确认其文件大小。

将以上操作对应的完整命令序列及最终状态检查命令的输出结果截图粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：计算输入文件中的单词数

现有课程评价文本数据 course_reviews.txt，请使用 Hadoop 完成以下任务：

（1）将文本文件上传至 HDFS 的 /bigdata_edu/reviews 目录；

（2）调用 Hadoop 官方示例 jar 包中的词频统计程序，对评论文本进行统计；

（3）将统计结果输出到 HDFS 的 /bigdata_edu/review_wordcount 目录；

（4）将词频统计结果中按词频降序排列的前 10 个单词及其频次截图粘贴至【提交结果.docx】中对应的任务序号下。

3．子任务三：学习行为分析

请设计 MapReduce 程序，完成以下分析：

（1）目标：基于用户每日的学习记录，统计每位用户的“月度活跃天数”（即在一个月内有学习记录的天数）。

（2）Map 阶段：以用户 ID 为键，输出该用户有学习记录的日期。

（3）Reduce 阶段：对同一用户 ID 下的所有日期进行去重，并统计该月去重后的日期数量，即为月度活跃天数。

（4）输出格式应为：用户 ID,月度活跃天数。

（5）将程序运行后，结果文件的前 10 行内容截图粘贴至【提交结果.docx】中对应的任务序号下。

四、项目三：业务分析与可视化

（一）任务一：数据分析与可视化

1．子任务一：数据分析

本任务要求使用 Python 对在线教育平台数据进行多维度分析，以评估课程质量和学习行为模式。参赛者需运用 Pandas 等库完成以下量化分析：

（1）计算各“课程类别”的平均“最终通过率”，并筛选出高于平台整体平均通过率的类别，按通过率从高到低排序，展示所有达标类别；

（2）将一天划分为四个学习区间（清晨：5:00-10:59， 午间：11:00-16:59，傍晚：17:00-21:59， 深夜：22:00-4:59），计算每个区间内发起学习会话的独立用户数，找出最活跃的学习区间；

（3）分析不同“内容形式”（如视频、图文、直播、互动课）的平均“用户满意度评分”，识别最受欢迎的内容形式；

（4）统计各类“登录设备”（如智能手机、平板电脑、桌面电脑、网页端）下的平均“单次访问时长”和“页面访问深度”，分析不同设备的典型使用场景差异；

（5）定义“高留存用户”为在最近 30 天内累计学习天数≥10 天的用户，计算各门课程的“高留存用户占比”，并找出占比最高的三门课程。

请将上述五项分析的计算结果，在 IDE 控制台中格式化打印（例如使用 print 函数或 DataFrame 展示），并将对应的输出截图粘贴至【提交结果.docx】中指定的位置。

2．子任务二：数据可视化

参赛者需使用 Matplotlib、Seaborn 等库绘制专业图表，以直观呈现分析结论。具体要求如下：

（1）绘制双轴组合图，展示“课程更新频率”与“用户参与度”（以平均学习时长衡量）之间的关系：

- 主 Y 轴（柱状图）为各课程的平均学习时长。
- 次 Y 轴（折线图，带标记点）为对应课程的近一年更新次数。
- X 轴为按“学科领域”分组的课程列表。

• 图表需包含清晰的标题、双轴标签、图例及必要的数值标注。

（2）绘制热力图，呈现“用户学习时段”（按小时划分）与“常用设备类型”之间的共现关系，揭示不同设备在不同时间的使用强度：

• X 轴为一天中的 24 个小时。

• Y 轴为主要的设备类型。

• 单元格颜色深浅代表在该时段使用该设备的学习人次占比。

• 图表需包含色标、标题及坐标轴标签。

请将生成的两个高质量图表分别截图，并粘贴至【提交结果.docx】中对应的任务序号下。图表应遵循可视化最佳实践，确保信息传达的准确性和美观性。

（二）任务二：业务分析

基于前述分析，参赛者需从平台运营者视角，整合数据发现，形成一份结构化的业务分析简报。

请根据您的分析结果，撰写一份涵盖以下要点的报告：

核心发现总结

• 用户活跃规律：指出用户最活跃的时段及最偏好的设备组合，描述典型的用户学习场景。

• 课程内容表现：总结何种内容形式、更新频率或学科领域更受用户欢迎、更能促进学习完成与留存。

• 潜在风险与机会：识别可能存在的用户参与度下降的课程类别、时段或设备渠道。

数据驱动的优化建议
基于核心发现，提出具体、可操作的改进建议，例如：

• 内容与运营策略：针对高留存课程的成功要素，提出可复制的课程设计或运营方案。

• 功能与体验优化：结合用户时段与设备偏好，提出个性化的学习提醒、内容推

送或界面适配建议。

• 资源分配建议：为课程更新、技术开发（如移动端优化）或市场推广（针对特定活跃时段）提出优先级建议。

报告要求观点明确、逻辑清晰，分析结论须有前述任务中的数据结果作为支撑，总字数控制在 350 字以内。

五、项目四：AI 大模型应用开发综合实践

随着人工智能技术的快速发展，越来越多的企业和开发者希望能够使用强大的 AI 模型来处理各类任务，如自然语言处理、文本生成、自动化客服、智能推荐等。在此背景下，利用 Ollama 和 Dify 搭建一个可定制的 AI 系统成为了提升智能应用的重要途径。

通过 在 openEuler 系统上搭建一个基于 Ollama 和 Docker 的 AI 大模型平台，可以通过 Dify 平台将 Ollama 注册为模型供应商，从而实现不同服务应用效果。Dify 是一个轻量级的 AI 平台，能够快速整合模型和应用，允许用户通过简单的配置和管理，调用不同的 AI 模型提供服务。

（一）任务一：AI 大模型服务综合部署

1.子任务一：基本配置

本任务需要使用 root 用户完成相关配置，已提供操作系统镜像及需要配置前置环境，所需软件安装包均在/root/目录下。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中将操作系统镜像挂载至/media/cdrom，并实现开机自启。

（2）在 AI-SRV 中完成软件源配置文件的编写，禁用 GPG 校验，并为源数据建立缓存。

2.子任务二：环境搭建

本任务需要使用 root 用户完成相关配置，已提供 ollama 安装包及需要配置前置环境。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中为 ollama 配置用户/组，该用户仅用于运行服务，禁止其登录系统，家目录位于/usrlshare/ollama。

（2）在 AI-SRV 中为 root 用户加入附加组 ollama。

（3）在 AI-SRV 中将文件 ollama-linux-amd64.tgz 解压安装至/usr 目录下。

（4）在 AI-SRV 中编写 SystemD 服务配置，使用服务运行专用用户完成启动，无论发生任何意外情况，服务都会进行自动重启（冷却 3 秒），以保证服务可靠运行，服务需要监听所有地址。

（5）在 AI-SRV 中启动 ollama 服务，并完成开机启动配置，最终启动 ollama 服务。

（6）在 AI-SRV 中导入 1.5b.tgz 压缩文件模型至 ollama。

（二）任务二：AI 大模型综合应用开发

1.子任务一：Dify 运行环境搭建

本任务需要使用 root 用户完成相关配置,已提供安装 dify 及需要配置前置环境。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中完成 Docker 环境的安装，并查看 Docker 版本信息。

（2）在 AlI-SRV 中将文件 dify-0.14.2.tar.gz 解压至/opt 路径中。

（3）在 AI-SRV 中完成 dify 镜像的导入，相关文件位于 dify-images 目录中，完成后检查镜像列表。

（4）在 AI-SRV 中完成 dify 的启动，并在客户机中访问 AI-SRV 中的 dify web 服务。

（5）在客户机中访问 dify，完成用户注册，邮箱为 admin@dify.ai，用户名为 admin，密码为 Qwer1234，注册后登录 dify 管理页面。

（6）在客户机中访问 dify，完成对 ollama 模型提供商的注册。

2.子任务二：教育数据分析助手构建

本任务需要基于前置环境完成，选手须先自行完成配置，具体要求如下:

（1）根据教育数据分析场景需要，创建空白应用“Edu Data Assistant”。

（2）为用户提供教育数据查询功能，其中参数包含：Query（查询内容），支持以下类型的查询:

学生查询

- 学生成绩查询（如："张明最近的考试成绩"）

- 学习进度查询（如："李华完成了多少课程"）

- 出勤情况查询（如："王磊这个月的出勤记录"）

课程查询

- 课程信息查询（如："Python 基础课有多少学生"）

- 课程难度分析（如："哪些课程学生挂科最多"）

- 教师授课查询（如："张老师教哪些课"）

统计查询

- 班级排名查询（如："三班学生的平均分"）

- 成绩分布查询（如："数学考试的成绩分布"）

- 学习时间统计（如："学生平均每天学多久"）

（3）为确保结果准确性，需要从以下多个维度提供数据支持：

- 从 MySQL 的 education 数据库读取数据

- 从本地 CSV 文件（user_study_log.csv）读取数据

- 使用 Ollama 本地模型分析数据

（4）配置提示词要求：

- 系统角色设定为"教育数据分析助手"

- 支持 SQL 查询语句的自动生成和解释

- 支持自然语言到数据分析需求的转换

- 输出结果需包含数据来源说明

（5）运行应用，测试以下查询场景：

简单统计查询

- 输入："查询编程课程的平均分"

- 检查：能否正确查询 course 表

学生信息查询

- 输入："学生李四的学习记录"

- 检查：能否连接 study_behavior 表

成绩分析查询

- 输入："哪些学生数学不及格"

- 检查：能否筛选数据

时间统计查询

- 输入："上周的学习时长统计"

- 检查：能否按时间查询

多表关联查询

- 输入："张老师教的学生成绩"

- 检查：能否关联 course 和 study_behavior 表。