2025-2026学年广东省职业院校技能大赛

中职组大数据应用与服务赛项

样

题

3

一、背景描述

在大数据时代背景下，气象服务领域正经历着深刻的智能化转型。精准的天气预报与气候分析不仅关系到社会生产与民众生活的方方面面，也为防灾减灾、能源调度和农业规划提供了至关重要的决策依据。在传统的气象预报模式中，预测主要依赖于有限观测站点的数据和经验模型，难以实现对复杂天气系统的高精度、细粒度刻画。而在大数据时代，通过汇集并分析海量、多源的气象与环境数据，能够显著提升预报的准确性与时效性，实现从“预报天气”到“预警风险”的跨越。

气象大数据平台可以整合卫星遥感数据、地面观测站数据、雷达回波数据、以及来自社交媒体、交通网络等的众包感知数据。通过对这些多维度、时序性数据的深度挖掘与融合分析，可以构建更精准的数值预报模型，实现极端天气的早期识别与精准预警。同时，基于历史与实时数据的分析，能够为不同行业提供定制化的气候风险评估与生产建议，例如为农业提供病虫害气象条件预警，为物流行业规划最优运输路径。这些数据洞察也为城市应对气候变化、建设气候适应性城市提供了科学支撑。

数据驱动已成为现代气象服务发展的核心动力。为构建并优化此类智能气象分析系统，您所在的小组将应用大数据技术体系，从多源数据采集与处理入手，利用 Python 等工具进行数据清洗、融合与标注，进而开展深入的数据分析与可视化呈现，并通过大数据业务分析方法挖掘其应用价值。在此过程中，需设计与运行维护数据库系统以保障数据安全，并综合运用各类大数据工具软件解决具体业务问题。作为小组的技术人员，请您依据后续任务要求，完成本次气象大数据应用与服务的实践工作。

二、项目一：平台搭建与运维

（一）任务一：大数据平台搭建

1. 子任务一：基础环境准备

本任务需要使用 root 用户完成相关配置，安装 Hadoop 需要配置前置环境。命令中要求使用绝对路径，具体要求如下：

（1）配置三个节点的主机名，分别为 master、slave1、slave2，然后修改三个节点的 hosts 文件，使得三个节点之间可以通过主机名访问，在 master 上将执行命令 cat /etc/hosts 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）将 /opt/software 目录下将文件 jdk-8u391-linux-x64.tar.gz 安装包解压到 /opt/module 路径中，将 JDK 解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 /etc/profile 文件中配置 JDK 环境变量 JAVA_HOME 和 PATH 的值，并让配置文件立即生效，将在 master 上 /etc/profile 中新增的内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

（4）查看 JDK 版本，检测 JDK 是否安装成功，在 master 上将执行命令 java -version 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（5）创建 hadoop 用户并设置密码，为 hadoop 用户添加管理员权限。在 master 上将执行命令 grep 'hadoop' /etc/sudoers 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（6）关闭防火墙，设置开机不自动启动防火墙，在 master 上将执行命令 systemctl status firewalld 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（7）配置三个节点的 SSH 免密登录，在 master 上通过 SSH 连接 slave1 和 slave2 来验证。

2. 子任务二：Hadoop 完全分布式安装配置

本任务需要使用 root 用户和 hadoop 用户完成相关配置，使用三个节点完成 Hadoop 完全分布式安装配置。命令中要求使用绝对路径，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将文件 hadoop-3.1.3.tar.gz 安装包解压到 /opt/module 路径中，将 hadoop 安装包解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）在 master 节点中将解压的 Hadoop 安装目录重命名为 hadoop，并修改该目录下的所有文件的所属者为 hadoop，所属组为 hadoop，将修改所属者的完整命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中使用 hadoop 用户依次配置 hadoop-env.sh、core-site.xml、hdfs-site.xml、mapred-site.xml、yarn-site.xml、masters 和 workers 配置文件，Hadoop 集群部署规划如下表，将 yarn-site.xml 文件内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

服务器	master	slave1	slave2
HDFS	NameNode		
HDFS	SecondaryNameNode		
HDFS	DataNode	DataNode	DataNode

YARN	ResourceManager		
YARN	NodeManager	NodeManager	NodeManager
历史日志服务器	JobHistoryServer		

（二）任务二：数据库服务器的安装与运维

1．子任务一：MySQL 安装配置

本任务需要使用 rpm 工具安装 MySQL 并初始化，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将 mysql-5.7.25-1.el7.x86_64.rpm-bundle.tar 安装包解压到 /opt/module 目录下；

（2)在 master 节点中使用 rpm -ivh 依次安装 mysql-community-common、mysql-community-libs、mysql-community-libs-compat、mysql-community-client 和 mysql-community-server 包，将所有命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中启动数据库系统并初始化 MySQL 数据库系统，将完整命令复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：MySQL 运维

本任务需要在成功安装 MySQL 的前提下，对 MySQL 进行运维操作，具体要求如下：

（1）配置服务端 MySQL 数据库的远程连接，将新增的配置内容复制粘贴至【提交结果.docx】中对应的任务序号下；

（2）配置 root 用户允许任意 IP 连接，将完整命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）通过 root 用户登录 MySQL 数据库系统，查看 mysql 库下的所有表，将完整命令及执行命令后的结果复制粘贴至【提交结果.docx】中对应的任务序号下；

(4) 创建 hadoop 用户，设置密码为 qwER12#$，并允许任意 IP 进行连接，将命令和完整结果截图至【提交结果.docx】中对应的任务序号下；

(5) 授予 hadoop 用户拥有对所有数据库的插入数据,查询数据,删除数据权限，将命令和完整结果截图至【提交结果.docx】中对应的任务序号下；

(6) 在 MySQL 数据库中创建一个名为 hddb 的数据库，并指定 utf8mb4 的字符集和 utf8mb4_unicode_ci 的排序规则，将命令和完整结果截图至【提交结果.docx】中对应的任务序号下；

(7) 创建名为 hdadmin 的新用户,并授予 hdadmin 对 hddb 数据库的全部权限，将创建用户及授予权限的命令截图至【提交结果.docx】中对应的任务序号下；

(8) 刷新权限，并查看 hdadmin 用户的权限信息，将显示权限信息的命令和结果截图至【提交结果.docx】中对应的任务序号下；

(9) 查看 MySQL 数据库的全局的默认字符集，将命令和结果截图至【提交结果.docx】中对应的任务序号下；

3．子任务三：数据表的创建及维护

根据以下数据字段在 hddb 数据库中创建天气表（new_weather）。天气表字段如下：

字段	类型	列注释	约束
id	INT	城市 ID	主键 自增
province_id	INT	省份 ID	非空
city_name	VARCHAR(255)	城市名称	非空
zip_code	INT	邮编	
levels	INT	城市等级	
climate	VARCHAR(255)	气候条件	

将天气表（new_weather）的建表语句截图至【提交结果.docx】中对应的任务序号下；

向 hddb 数据库中的天气表（new_weather）中插入以下记录，并查看天气表的全部记录。将 SQL 语句和执行结果截图至【提交结果.docx】中对应的任务序号下；

id	province_id	city_name	zip_code	level	climate
1	1016	三亚	572000	2	热带海洋性季风气候
2	1026	上海	200000	1	亚热带季风气候

3	1032	乌鲁木齐	830000	2	中温带半干旱大陆性气候

为天气表添加气候介绍字段（comment），并查询天气表的结构，将 SQL 语句和结果截图至【提交结果.docx】中对应的任务序号下；

根据/opt/software/mysql 路径下的三份数据库文件（city_info.sql、province_info.sql、weather.sql），将其导入到数据库 hddb 中。将导入命令和结果截图至【提交结果.docx】中对应的任务序号下；

对导入的三份数据进行以下操作：

（1） 编写一个 SQL 查询，查询最高气温超过 30 且天气为多云的所有记录。将 SQL 语句和执行结果截图至【提交结果.docx】中对应的任务序号下；

（2） 编写一个 SQL 查询，统计城市阿克苏最高气温超过 17 度的记录，并按照降序排列。将 SQL 语句和执行结果截图至【提交结果.docx】中对应的任务序号下；

（3）编写一个 SQL 查询，统计每个城市当日天气状况为多云的天数，并按照降序排列。将 SQL 语句和执行结果截图至【提交结果.docx】中对应的任务序号下；

（4）查询属于亚热带季风气候，最高气温大于 30 度且风力大于 2 级的城市名称和最高气温。将 SQL 语句和执行结果截图至【提交结果.docx】中对应的任务序号下；

三、项目二：数据获取与处理

（一）任务一：数据获取与清洗

1．子任务一：数据获取

现有一份气象观测数据集，包含以下字段：记录 ID、观测站 ID、观测日期、观测时间、气温(℃)、相对湿度(%)、降水量(mm)、风速(m/s)、风向、气压(hPa)、天气现象（如晴、雨、雪等）。

数据已存入 weather_observations.csv 文件中，请使用 pandas 读取该文件，并将数据集的前 10 行打印在 IDE 终端的截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：使用 Python 进行数据清洗

从气象数据中心获取的原始数据集，已对观测站 ID 等敏感信息进行了脱敏处理。请使用 pandas 库，按照以下要求对数据进行清洗和整理：

（1）删除“降水量”为空值且“天气现象”不为“雨”或“雪”的无效记录（即疑似缺失的记录），并将结果存储为 cleaned_weather_c1_N.csv，N 为删除的数据条数；

（2）识别并删除物理上不可能的异常记录（如：气温低于-50℃或高于 50℃，气压低于 800hPa 或高于 1100hPa），将结果存储为 cleaned_weather_c2_N.csv，N 为删除的数据条数；

（3）将“观测日期”和“观测时间”两列合并为标准的 YYYY-MM-DD HH:MM:SS 格式的“观测时间戳”列，并删除原两列，将结果存储为 cleaned_weather_c3_N.csv，N 为总记录条数（此项无需统计修改量，N 为处理后数据总行数）；

（4）删除所有字段完全相同的重复观测记录，并将结果存储为 cleaned_weather_c5_N.csv，N 为删除的数据条数；

请将该 4 个文件名截图，复制粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据标注

1. 子任务一：骑行距离分类标注

使用 Python 编写脚本，根据日最高气温将每日天气情况分为“寒冷”、“凉爽”、“舒适”、“炎热”四类。具体的分类要求如下：

（1）寒冷：日最高气温 < 10℃；

（2）凉爽：10℃ ≤ 日最高气温 < 20℃；

（3）舒适：20℃ ≤ 日最高气温 < 28℃；

（4）炎热：日最高气温 ≥ 28℃。

在数据集中新增一列“气温等级”，根据上述标准对每日的天气记录进行标注（需先按“观测日期”和“观测站 ID”分组计算日最高气温），存入 temperature_level.csv 文件中。具体格式如下：

观测日期	观测站 ID	日最高气温	气温等级
2025-01-01	STATION_001	8.5	寒冷

将 temperature_level.csv 打开后的前若干行直接截图，复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：时段热度标注

使用 Python 编写脚本，基于“天气现象”和“降水量”字段，对降水类天气的强度进行标注。具体的分类要求如下：

（1）小雨/小雪：天气现象为“雨”或“雪”，且降水量 < 10mm；

（2）中雨/中雪：天气现象为“雨”或“雪”，且 10mm ≤ 降水量 < 25mm；

（3）大雨/大雪：天气现象为“雨”或“雪”，且降水量 ≥ 25mm；

（4）非降水：天气现象为“晴”、“多云”、“阴”等。

在数据集中新增一列“降水强度”，根据上述标准对每条观测记录进行标注，存入 precipitation_intensity.csv 文件中。具体格式如下：

记录 ID	观测时间	天气现象	降水量(mm)	降水强度
1001	2025-01-01	雨	15.2	中雨/中雪

将 precipitation_intensity.csv 打开后的前若干行直接截图，复制粘贴至【提交结果.docx】中对应的任务序号下。

（三）任务三：数据统计

1．子任务一：HDFS 文件操作

本任务需要使用 Hadoop、HDFS 命令，具体要求如下：

（1）在 HDFS 根目录下新建目录 /weather_data/input；

（2）修改该目录权限，赋予其 755 权限；

（3）将本地清洗后的最终数据文件 cleaned_weather_c5_N.csv 上传至 HDFS 的该目录下。

请将以上三条操作的完整命令粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：计算输入文件中的单词数

有一份从气象报告中提取的关键词文本文件 weather_keywords.txt，每行一个词。本任务要求使用 Hadoop MapReduce 完成词频统计，具体要求如下：

（1）将该文本文件上传至 HDFS 的 /weather_data/keywords 目录下；

（2）使用 Hadoop 提供的 wordcount 示例程序对该文件进行词频统计；

（3）将统计结果输出到 HDFS 的 /weather_data/keyword_count 目录下；

（4）将最终词频统计结果的前十行内容截图粘贴至【提交结果.docx】中对应的任务序号下。

3. 子任务三：计算区域平均骑行时长

本任务要求使用 MapReduce 框架，计算每个观测站所在区域（根据观测站 ID 前缀划分，如 STATION_BJ_001 前缀为 BJ）的月平均气温。

（1）编写 MapReduce 程序，输入数据格式为：

观测站 ID，观测时间戳，气温

STATION_BJ_001,2025-01-01 08:00:00, -2.5

STATION_SH_002,2025-01-01 08:05:00, 5.0

...

（2）Map 函数需要从每条记录中提取 (区域-月份) 作为键（如 BJ-202501），气温作为值；

（3）Reduce 函数需要计算每个 (区域-月份) 组合下的所有气温值的平均值；

（4）将计算结果输出到 HDFS 的 /weather_data/avg_temperature 目录下，输出格式为：

区域-月份 平均气温

BJ-202501 1.2

SH-202501 6.8

...

（5）将程序运行结果的前十行截图粘贴至【提交结果.docx】中对应的任务序号下。

四、项目三：业务分析与可视化

（一）任务一：数据分析与可视化

1．子任务一：数据分析

气象数据分析是理解气候变化规律、评估观测质量和服务效果的重要手段。在本任务中，您将运用 Python 对气象观测数据进行多维度分析，以获取关键洞察。参赛者需要运用 Pandas 等数据处理和分析库来完成以下任务：

（1）按观测时间统计一天中每个小时的平均温度、最高温度和最低温度，并找出日温差最大的三个时段；

（2）计算不同天气现象（如晴、雨、雪、阴、多云）下的平均温度、平均降水量和平均风速；

（3）分析不同季节（春季：3-5 月，夏季：6-8 月，秋季：9-11 月，冬季：12-2 月）的温度与降水量模式差异，计算各季节的平均温度、总降水量；

（4）统计各观测站的日最高气温极值和日最低气温极值，识别出高温区域和低温区域；

（5）分析降水量等级（无降水：0mm，小雨：0-10mm，中雨：10-25mm，大雨：>25mm）与平均相对湿度、平均风速之间的关系；

请将该 5 项统计结果在 IDE 的控制台中格式化打印，并分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：数据可视化

在本任务中，参赛者将使用 pyecharts 库创建直观、互动的图表，以揭示气象数据中的时空模式和关联关系。具体要求如下：

（1）创建时间热力图展示一周内各时段（小时）的温度分布，横轴为星期（周一至周日），纵轴为小时（0-23 时），颜色冷暖表示温度高低；

（2）使用多系列折线图展示一年中（按月份）的温度变化趋势，图中需要包含平均气温、历史同期最高气温和最低气温三条折线，以便进行对比；

（3）制作风向玫瑰图，展示特定区域（如某城市）在特定时期内（如一个季度）的风向频率分布，使用扇区表示风向，半径长度表示该风向出现的频率；

（4）创建散点图分析温度与相对湿度的关系，横轴为温度（℃），纵轴为相对湿度（%），每个点的大小可表示观测时的风速，颜色表示天气现象（晴、雨等）；

请将该 4 个可视化图表分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：业务分析

在气象服务中，准确评估数据质量、理解气候规律并优化预报服务至关重要。通过分析历史观测数据，可以诊断观测网络效能、验证模型准确性并为服务改进提供依据。本任务要求使用 Python 对气象数据进行深入的业务分析，目的是识别关键指标，并提出基于数据的优化建议。

使用提供的气象数据集，计算以下指标：

（1）气象数据质量评估

• 数据完整性：按观测站统计各主要要素（气温、降水量、风速）的有效记录条数占总应记录条数的百分比。

• 数据稳定性：计算各观测站日最高气温与日最低气温的月平均差值（日温差），分析其月际波动情况。

• 异常值检出率：识别并统计超出历史同期（近五年）平均值±3 倍标准差范围的记录数量及其占比。

（2）预报准确性对比分析

• 温度预报误差：将实际观测温度与前一天发布的预报温度进行对比，计算平均绝对误差（MAE）。

• 降水预报准确率：评估对于“有降水”（降水量>0）和“无降水”事件的预报准确率（命中率）。

• 趋势一致性：分析预报的温度变化趋势（如升温、降温）与实际观测趋势的一致天数占比。

（3）服务需求分析

• 高温服务需求：统计日最高气温超过 35℃的天数，并分析这些高温日中不同时段（如午后）的平均湿度与风速（用于评估体感热度）。

• 降水服务需求：统计中雨及以上降水事件（降水量≥10mm）的持续时长、发生时段（白天/夜间）及伴随的平均风速。

• 舒适度区间分析：根据温度（18-26℃）和湿度（40%-70%）定义“人体舒适度区间”，统计全年处于该区间的天数比例。

根据上述分析结果，请撰写一份简短的分析报告（300 字以内），内容应包括：

• 对当前气象观测数据质量和预报准确性的核心评估结论；

• 在数据收集或服务中存在的关键薄弱环节；

• 至少三条基于数据分析的具体优化建议（如针对观测网络、预报模型或公众服务），并简述其预期价值。

将分析报告内容复制粘贴至【提交结果.docx】中对应的任务序号下。

五、项目四：AI 大模型应用开发综合实践

随着人工智能技术的快速发展，越来越多的企业和开发者希望能够使用强大的 AI 模型来处理各类任务，如自然语言处理、文本生成、自动化客服、智能推荐等。在此背景下，利用 Ollama 和 Dify 搭建一个可定制的 AI 系统成为了提升智能应用的重要途径。

通过 在 openEuler 系统上搭建一个基于 Ollama 和 Docker 的 AI 大模型平台，可以通过 Dify 平台将 Ollama 注册为模型供应商，从而实现不同服务应用效果。Dify 是一个轻量级的 AI 平台，能够快速整合模型和应用，允许用户通过简单的配置和管理，调用不同的 AI 模型提供服务。

（一）任务一：AI 大模型服务综合部署

1.子任务一：基本配置

本任务需要使用 root 用户完成相关配置，已提供操作系统镜像及需要配置前置环境，所需软件安装包均在/root/目录下。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中将操作系统镜像挂载至/media/cdrom，并实现开机自启。

（2）在 AI-SRV 中完成软件源配置文件的编写，禁用 GPG 校验，并为源数据建立缓存。

2.子任务二：环境搭建

本任务需要使用 root 用户完成相关配置，已提供 ollama 安装包及需要配置前置环境。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中为 ollama 配置用户/组，该用户仅用于运行服务，禁止其登录系统，家目录位于/usrlshare/ollama。

（2）在 AI-SRV 中为 root 用户加入附加组 ollama。

（3）在 AI-SRV 中将文件 ollama-linux-amd64.tgz 解压安装至/usr 目录下。

（4）在 AI-SRV 中编写 SystemD 服务配置，使用服务运行专用用户完成启动，无论发生任何意外情况，服务都会进行自动重启（冷却 3 秒），以保证服务可靠运行，服务需要监听所有地址。

（5）在 AI-SRV 中启动 ollama 服务，并完成开机启动配置，最终启动 ollama 服务。

（6）在 AI-SRV 中导入 1.5b.tgz 压缩文件模型至 ollama。

（二）任务二：AI 大模型综合应用开发

1.子任务一：Dify 运行环境搭建

本任务需要使用 root 用户完成相关配置,已提供安装 dify 及需要配置前置环境。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中完成 Docker 环境的安装，并查看 Docker 版本信息。

（2）在 AlI-SRV 中将文件 dify-0.14.2.tar.gz 解压至/opt 路径中。

（3）在 AI-SRV 中完成 dify 镜像的导入，相关文件位于 dify-images 目录中，完成后检查镜像列表。

（4）在 AI-SRV 中完成 dify 的启动，并在客户机中访问 AI-SRV 中的 dify web 服务。

（5）在客户机中访问 dify，完成用户注册，邮箱为 admin@dify.ai，用户名为 admin，密码为 Qwer1234，注册后登录 dify 管理页面。

（6）在客户机中访问 dify，完成对 ollama 模型提供商的注册。

2.子任务二：气象数据智能助手构建

本任务需要基于前置环境完成，选手须先自行完成配置，具体要求如下:

（1）根据气象数据分析场景需要，创建空白应用 "Meteorological Data Assistant"。

（2）为用户提供气象数据智能查询功能，其中参数包含：Query（查询内容），支持以下类型的查询：

城市气候查询（如：“查询‘广州’的历史平均温度、年降水量”）

极端天气统计（如：“查询2025年广东省最高气温超过35℃的天数”）

天气现象分析（如：“查询‘暴雨’事件的发生频率和平均持续时间”）

区域对比分析（如：“对比珠三角和粤北地区的年平均风速”）

气象趋势预测建议（基于历史数据的简单推演）

（3）为确保结果准确性，需要从以下多个维度提供数据支持：

基于MySQL数据库中的结构化气象数据（如 hddb 数据库中的 weather、city_info 等表）

基于清洗后的CSV文件（如 cleaned_weather_c5_N.csv 及相关处理结果）

基于大模型的智能解析和推理能力

（4）配置提示词要求：

系统角色设定为 “气象数据分析专家”

支持SQL查询语句的自动生成和解释

支持自然语言到气象数据分析需求的转换

输出结果需包含数据来源说明（如数据库表、CSV文件等）

（5）运行应用，测试以下查询场景：

“查询2025年广州市每月平均气温和降水量”

“广东省哪个城市在2025年出现暴雨次数最多？”

“对比深圳和珠海的风向频率分布”

“预测未来一周深圳的天气趋势（基于历史同期数据）”

“查询2025年广东省极端高温事件的持续时间和影响范围”