2025-2026学年广东省职业院校技能大赛

中职组大数据应用与服务赛项

样

题

4

一、背景描述

在大数据时代背景下，房地产行业正经历深刻的数字化转型。传统房地产运营模式多依赖于从业者的经验判断与市场直觉，在项目定位、客群分析、营销策略制定及资产运营等方面往往存在主观局限，发展路径较为同质化。而在大数据时代，海量用户行为数据与市场信息为行业提供了全新的决策支持，通过科学分析得出的结论更为客观、精准，能够有效驱动项目决策、营销优化与服务升级。

互联网平台与行业系统可以持续收集并整合用户在房产交易和居住过程中的各类行为数据，如房源浏览记录、区位偏好、价格关注区间、咨询内容、成交周期、居住反馈等。同时，结合宏观经济数据、区域发展规划、交通配套信息等多维度数据，进行深度挖掘与融合分析，平台能够构建精细化的客户画像，对房源价值进行动态评估，并最终实现向潜在客户的精准推荐与个性化服务，显著提升成交效率与用户满意度。

数据驱动已成为现代房地产行业提升竞争力的核心。为完成此次房地产领域的大数据分析工作，您所在小组将全面应用大数据技术体系：以 Python 为核心工具，从多源数据采集入手，对原始数据进行清洗、集成与标注；进而开展深入的数据分析与可视化呈现，并运用大数据业务分析方法提炼商业洞察；同时，需设计并运行维护数据库系统以确保数据存储的安全与稳定；最终，通过综合运用各类大数据工具软件来解决具体的业务问题。作为小组的技术人员，请根据后续任务要求，完成本次大数据应用与服务的实践工作。。

二、项目一：平台搭建与运维

（一）任务一：大数据平台搭建

1. 子任务一：基础环境准备

本任务需要使用 root 用户完成相关配置，安装 Hadoop 需要配置前置环境。命令中要求使用绝对路径，具体要求如下：

（1）配置三个节点的主机名，分别为 master、slave1、slave2，然后修改三个节点的 hosts 文件，使得三个节点之间可以通过主机名访问，在 master 上将执行命令 cat /etc/hosts 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）将 /opt/software 目录下将文件 jdk-8u191-linux-x64.tar.gz 安装包解压到 /opt/module 路径中，将 JDK 解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 /etc/profile 文件中配置 JDK 环境变量 JAVA_HOME 和 PATH 的值，并让配置文件立即生效，将在 master 上 /etc/profile 中新增的内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

（4）查看 JDK 版本，检测 JDK 是否安装成功，在 master 上将执行命令 java -version 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（5）创建 hadoop 用户并设置密码，为 hadoop 用户添加管理员权限。在 master 上将执行命令 grep 'hadoop' /etc/sudoers 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（6）关闭防火墙，设置开机不自动启动防火墙，在 master 上将执行命令 systemctl status fireawlld 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（7）配置三个节点的 SSH 免密登录，在 master 上通过 SSH 连接 slave1 和 slave2 来验证。

2．子任务二：Hadoop 完全分布式安装配置

本任务需要使用 root 用户和 hadoop 用户完成相关配置，使用三个节点完成 Hadoop 完全分布式安装配置。命令中要求使用绝对路径，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将文件 hadoop-3.1.3.tar.gz 安装包解压到 /opt/module 路径中，将 hadoop 安装包解压命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（2）在 master 节点中将解压的 Hadoop 安装目录重命名为 hadoop，并修改该目录下的所有文件的所属者为 hadoop，所属组为 hadoop，将修改所属者的完整命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中使用 hadoop 用户依次配置 hadoop-env.sh、core-site.xml、hdfs-site.xml、mapred-site.xml、yarn-site.xml、masters 和 workers 配置文件，Hadoop 集群部署规划如下表，将 yarn-site.xml 文件内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

服务器	master	slave1	slave2
DHFS	NameNode		
HDFS	SecondaryNameNode		
HDFS	DataNode	DataNode	DataNode
YARN	ResourceManager		
YARN	NodeManager	NodeManager	NodeManager
历史日志服务器	JobHistoryServer		

（4）在 master 节点中使用 scp 命令将配置完的 hadoop 安装目录直接拷贝至 slave1 和 slave2 节点，将完整的 scp 命令复制并粘贴至【提交结果.docx】中对应的任务序号下；

（5）在 slave1 和 slave2 节点中将 hadoop 安装目录的所有文件的所属者为 hadoop，所属组为 hadoop。

（6）在三个节点的 /etc/profile 文件中配置 Hadoop 环境变量 HADOOP_HOME 和 PATH 的值，并让配置文件立即生效，将 master 节点中

/etc/profile 文件新增的内容复制并粘贴至【提交结果.docx】中对应的任务序号下；

（7）在 master 节点中初始化 Hadoop 环境 namenode，将初始化命令及初始化结果（截取初始化结果日志最后 20 行即可）粘贴至【提交结果.docx】中对应的任务序号下；

（8）在 master 节点中依次启动 HDFS、YARN 集群和历史服务。在 master 上将执行命令 jps 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下；

（9）在 slave1 查看 Java 进程情况。在 slave1 上将执行命令 jps 的结果复制并粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据库服务器的安装与运维

1．子任务一：MySQL 安装配置

本任务需要使用 rpm 工具安装 MySQL 并初始化，具体要求如下：

（1）在 master 节点中的 /opt/software 目录下将 mysql-5.7.25-1.el7.x86_64.rpm-bundle.tar 安装包解压到 /opt/module 目录下；

（2)在 master 节点中使用 rpm -ivh 依次安装 mysql-community-common、mysql-community-libs、mysql-community-libs-compat、mysql-community-client 和 mysql-community-server 包，将所有命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）在 master 节点中启动数据库系统并初始化 MySQL 数据库系统，将完整命令复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：MySQL 运维

本任务需要在已安装 MySQL 的环境下，进行以下运维操作，具体要求如下：

（1）修改 MySQL 配置文件，将服务器最大连接数调整为 300，并将修改配置的完整命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（2)创建名为 tourism_analysis 的数据库，并设置其默认字符集为 utf8mb4、排序规则为 utf8mb4_general_ci，将完整 SQL 语句复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）编写一个名为 daily_backup.sh 的定时备份脚本，要求每天凌晨 3 点自动完整备份 tourism_analysis 数据库，并将脚本内容完整复制粘贴至【提交结果.docx】中对应的任务序号下；

（4）为提升查询效率，开启查询缓存（Query Cache）并设置其大小为 64MB，将相关配置命令复制粘贴至【提交结果.docx】中对应的任务序号下；

（5）启用二进制日志（binlog）并设置日志格式为“ROW”，同时配置日志保留时长为 15 天，将相关配置命令复制粘贴至【提交结果.docx】中对应的任务序号下。

3．子任务三：数据表的创建及维护

（1）根据以下数据字段，在 tourism_analysis 数据库中创建旅游目的地信息表（destination）：

字段名	类型	中文含义	备注
dest_id	INT	目的地 ID	主键，自增
dest_name	VARCHAR(100)	目的地名称	
country	VARCHAR(50)	所在国家	
region	VARCHAR(50)	所属地区	如：东南亚、欧洲等
dest_type	VARCHAR(30)	目的地类型	如：海滨、山区、

			城市等
avg_rating	DECIMAL(3,2)	平均用户评分	范围 1.0-5.0
best_season	VARCHAR(50)	最佳旅游季节	
estimated_cost	DECIMAL(10,2)	人均预估费用（元）	

（2）根据以下数据字段，在 tourism_analysis 数据库中创建游客出行记录表（travel_record）：

字段名	类型	中文含义	备注
record_id	BIGINT	记录 ID	主键，自增
user_id	VARCHAR(50)	用户 ID	脱敏处理
dest_id	INT	目的地 ID	外键，关联 destination 表
travel_date	DATE	出行日期	
travel_days	INT	出行天数	
total_expense	DECIMAL(10,2)	总花费（元）	
transport_mode	VARCHAR(20)	主要交通方式	如：飞机、高铁、自驾
is_group_tour	TINYINT(1)	是否跟团游	1 是，0 否
satisfaction	INT	满意度评分	1-5 分

将上述两个创建表的 SQL 语句分别复制粘贴至【提交结果.docx】中对应的任务序号下。

（3）将提供的 tourism_data.csv 文件导入 tourism_analysis 数据库，并编写以下查询语句：

查询 2024 年各季度（Q1:1-3 月，Q2:4-6 月，Q3:7-9 月，Q4:10-12 月）的出行总人次和人均花费。结果需显示季度、出行总人次、人均花费（保留两位小数），并按季度顺序排列。

统计不同“目的地类型”在跟团游和自由行中的占比。结果需显示目的地类型、跟团游次数、自由行次数、跟团游占比（百分比，保留一位小数），按跟团游次数降序排列。

找出“人均预估费用”低于实际“人均花费”（即总花费/出行人数）20%以上的目的地。结果需显示目的地名称、所在国家、预估人均费用、实际人均花费、差值（实际-预估），按差值降序排列。

将上述三个 SQL 查询语句分别复制粘贴至【提交结果.docx】中对应的任务序号下。

三、项目二：数据获取与处理

（一）任务一：数据获取与清洗

1．子任务一：数据获取

有一份房地产交易数据文件：小区名称、交易日期、房源户型、建筑面积（㎡）、成交总价（万元）、成交单价（元/㎡）、楼层、朝向、装修情况、建筑年代、配套设施等信息。

数据已存入到 tourist_data.csv 文件中，请使用 pandas 读取 tourist_data.csv 并将数据集的前 10 行打印在 IDE 终端的截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：使用 Python 进行数据清洗

请使用 pandas 库加载并分析相关数据集,根据题目规定要求使用 pandas 库实现数据处理，具体要求如下：

（1)删除装修情况为空或为零的记录,并将结果存储为 cleaned_data_c1_N.csv，N 为删除的数据条数；

（2）删除建筑面积异常（超过 500 ㎡或小于 20 ㎡）的记录，并将结果存储为 cleaned_data_c2_N.csv，N 为删除的数据条数；

（3）将朝向为空的记录填充为"未知"，并存储为 cleaned_data_c3_N.csv，N 为修改的数据条数；

（4）将成交单价超出范围（低于 5000 元/㎡或高于 200000 元/㎡）的记录删除，并将结果存储为 cleaned_data_c4_N.csv，N 为删除的数据条数；

（5）将成交总价明显异常（超过该小区平均成交总价 5 倍）的记录删除，将结果存储为 cleaned_data_c5_N.csv，N 为删除的数据条数。

将该 5 个文件名截一张图复制粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据标注

1．子任务一：房源价值分类标注

使用 Python 编写脚本，根据房源的成交总价和建筑面积对房源进行价值分类标注。具体的分类要求如下：

（1）高价值房源：成交总价高于平均值的 1.5 倍且建筑面积超过 120 ㎡；

（2）中价值房源：成交总价在平均值的 0.5-1.5 倍之间且建筑面积在 80-120 ㎡之间；

（3）低价值房源：不满足上述条件的房源。

在数据集中新增一列"房源价值类型"，根据上述标准进行标注，存入 tourist_value_mark.csv 文件中。具体格式如下：

编号	小区名称	成交总价(万元)	建筑面积(㎡)	房源价值类型
1	花园小区	850	135	高价值房源

将 tourist_value_mark.csv 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：交易热季标注

使用 Python 编写脚本，根据每月的交易数量和平均成交总价对交易季节进行标注。具体的分类要求如下：

（1）旺季：月交易量超过年平均值的 120%且月平均成交总价超过年平均值的 110%；

（2）平季：月交易量在年平均值的 80%-120%之间或月平均成交总价在年平均值的 90%-110%之间；

（3）淡季：月交易量低于年平均值的 80%且月平均成交总价低于年平均值的 90%。

在数据集中新增一列"季节类型"，根据上述标准对每个月份进行标注，存入 season_mark.csv 文件中。具体格式如下：

月份	交易总量	平均成交总价(万元)	同比年平均	季节类型
1 月	125	520	92%	平季

将 season_mark.csv 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

（三）任务三：数据统计

1．子任务一：HDFS 文件操作

本任务需要使用 Hadoop、HDFS 命令，已安装 Hadoop 及需要配置前置环境，具体要求如下：

（1）在 HDFS 目录下新建目录 /tourism_data，将新建目录的完整命令粘贴至【提交结果.docx】中对应的任务序号下；

（2）修改权限，赋予目录 /tourism_data 最高 777 权限，将修改目录权限的完整命令粘贴至【提交结果.docx】对应的任务序号下；

（3）将本地的旅游数据集上传至 HDFS 的 /tourism_data 目录下，并验证文件是否上传成功，将完整命令粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：使用 MapReduce 进行数据分析

本任务需要使用 Hadoop 的 MapReduce 功能完成数据分析任务，具体要求如下：

（1）编写 MapReduce 程序，统计不同小区的每月平均交易数量；

（2）将统计结果存储到 HDFS 的 /tourism_analysis/daily_visitors 目录下；

（3）运行 MapReduce 程序并查看执行结果，将运行命令和结果的前十行截图粘贴至【提交结果.docx】中对应的任务序号下。

3．子任务三：使用 Hive 进行数据分析

本任务需要使用 Hive 完成数据分析任务，具体要求如下：

（1）在 Hive 中创建外部表 tourist_flow，加载 HDFS 中的旅游数据；

（2）编写 HQL 查询，分析以下内容：

统计每个小区的月度交易总量

计算不同房源户型的平均成交总价

统计不同装修情况下的交易总量

（3）将查询结果导出到本地文件系统，并将导出命令和结果截图粘贴至【提交结果.docx】中对应的任务序号下。

四、项目三：业务分析与可视化

（一）任务一：数据分析与可视化

1．子任务一：数据分析

本任务要求使用 Python 对房地产交易数据进行深入分析，揭示房源特征和市场趋势。参赛者需要使用 Python 的数据处理和分析库完成以下任务：

（1）分析各小区的户型分布，找出每个小区最主要的户型（占比超过 20%）；

（2）计算不同建筑年代房源的平均成交总价和建筑面积，发现最具升值潜力的房源群体；

（3）分析周末和工作日的交易量差异，计算周末交易量相对工作日的增长百分比；

（4）统计不同朝向的房源比例，并根据平均成交总价对朝向进行排序；

（5）分析建筑面积与成交总价的关系，计算相关系数。

将这 5 个统计结果在 IDE 的控制台中打印并分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：数据可视化

本任务要求使用 pyecharts 库创建交互式数据可视化图表，帮助直观地展示房

地产数据分析结果。具体要求如下：

（1）创建玫瑰图展示各小区交易量分布 要求：使用玫瑰图展示不同小区的年度交易总量占比，每个扇形区域的半径表示交易量大小，颜色深浅代表交易量级别，并添加图例说明和标题。图表需要支持鼠标悬停显示详细数据。

（2）制作气泡图分析小区特征 要求：创建气泡图展示各小区的特征分布，横轴表示平均成交总价，纵轴表示月均交易量，气泡大小表示平均建筑面积，颜色表示小区等级。图表需要支持图例筛选和缩放交互。

（3）绘制堆叠面积图展示户型变化趋势 要求：使用堆叠面积图展示一年内各主要户型交易量的变化趋势，不同颜色代表不同户型，需要显示月度数据点，并支持区域高亮显示。

（4）创建雷达图对比不同房源群体特征 要求：使用雷达图对比不同建筑年代房源的交易特征，包含成交总价、建筑面积、楼层、朝向评分、配套设施等维度，并添加数据标签。

将以上 4 个可视化图表分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。图表必须包含完整的标题、图例、坐标轴标签等要素，确保图表清晰易读、专业美观。

（二）任务二：业务分析

房地产行业的数据分析对于把握市场动态和优化资源配置至关重要。本任务要求对房地产数据进行深入的业务分析，识别关键问题并提出改进建议。

1．基础指标分析

使用提供的数据集，计算并分析以下核心指标：

（1）交易量指标分析

日均交易量：计算每日交易总数的算术平均值

交易量波动系数：使用标准差除以平均值来衡量交易量的稳定性

节假日交易量比：节假日期间日均交易量与普通日期日均交易量的比值

（2）价格行为分析

套均总价计算：交易总金额除以总交易套数

不同群体价格差异：按建筑年代和户型分组计算平均成交总价

（3）房源竞争力评估

房源特征评分：采用 5 分制，计算所有有效特征（如楼层、朝向、装修）的加权平均值

2．运营建议

基于上述分析结果，从以下三个方面提出具体的运营优化建议：

（1）差异化定价策略：结合交易量波动规律和房源价值，设计分区域、分类别的定价方案

（2）房源展示优化方案：针对房源特征评分影响因素分析结果，提出房源信息完善的具体措施

（3）精准营销建议：基于高价值房源画像，设计有针对性的推广策略

请将分析报告（不超过 300 字）提交至【提交结果.docx】中对应的任务序号下。报告内容应包含数据分析结果和具体可行的运营建议。

五、项目四：AI 大模型应用开发综合实践

随着人工智能技术的快速发展，越来越多的企业和开发者希望能够使用强大的 AI 模型来处理各类任务，如自然语言处理、文本生成、自动化客服、智能推荐等。在此背景下，利用 Ollama 和 Dify 搭建一个可定制的 AI 系统成为了提升智能应用的重要途径。

通过 在 openEuler 系统上搭建一个基于 Ollama 和 Docker 的 AI 大模型平台，可以通过 Dify 平台将 Ollama 注册为模型供应商，从而实现不同服务应用效果。Dify 是一个轻量级的 AI 平台，能够快速整合模型和应用，允许用户通过简单的配置和管理，调用不同的 AI 模型提供服务。

（一）任务一：AI 大模型服务综合部署

1.子任务一：基本配置

本任务需要使用 root 用户完成相关配置，已提供操作系统镜像及需要配置前置

环境，所需软件安装包均在/root/目录下。命令中要求使用绝对路径，具体要求如下：

（1）在 AI-SRV 中将操作系统镜像挂载至/media/cdrom，并实现开机自启。

（2）在 AI-SRV 中完成软件源配置文件的编写，禁用 GPG 校验，并为源数据建立缓存。

2.子任务二：环境搭建

本任务需要使用 root 用户完成相关配置，已提供 ollama 安装包及需要配置前置环境。命令中要求使用绝对路径，具体要求如下：

（1）在 AI-SRV 中为 ollama 配置用户/组，该用户仅用于运行服务，禁止其登录系统，家目录位于/usrlshare/ollama。

（2）在 AI-SRV 中为 root 用户加入附加组 ollama。

（3）在 AI-SRV 中将文件 ollama-linux-amd64.tgz 解压安装至/usr 目录下。

（4）在 AI-SRV 中编写 SystemD 服务配置，使用服务运行专用用户完成启动，无论发生任何意外情况，服务都会进行自动重启（冷却 3 秒），以保证服务可靠运行，服务需要监听所有地址。

（5）在 AI-SRV 中启动 ollama 服务，并完成开机启动配置，最终启动 ollama 服务。

（6）在 AI-SRV 中导入 1.5b.tgz 压缩文件模型至 ollama。

（二）任务二：AI 大模型综合应用开发

1.子任务一：Dify 运行环境搭建

本任务需要使用 root 用户完成相关配置，已提供安装 dify 及需要配置前置环境。命令中要求使用绝对路径，具体要求如下：

（1）在 AI-SRV 中完成 Docker 环境的安装，并查看 Docker 版本信息。

（2）在 AlI-SRV 中将文件 dify-0.14.2.tar.gz 解压至/opt 路径中。

（3）在 AI-SRV 中完成 dify 镜像的导入，相关文件位于 dify-images 目录中，完成后检查镜像列表。

（4）在 AI-SRV 中完成 dify 的启动，并在客户机中访问 AI-SRV 中的 dify web 服务。

（5）在客户机中访问 dify，完成用户注册，邮箱为 admin@dify.ai，用户名为 admin，密码为 Qwer1234，注册后登录 dify 管理页面。

（6）在客户机中访问 dify，完成对 ollama 模型提供商的注册。

2.子任务二：房地产数据智能助手构建

本任务需要基于前置环境完成，选手须先自行完成配置，具体要求如下：

（1）根据房地产数据分析场景需要，创建空白应用 "Real Estate Data Assistant"。

（2）为用户提供房地产数据智能查询功能，其中参数包含：Query（查询内容），支持以下类型的查询：

小区行情查询（如：“查询‘花园小区’2024 年的平均成交单价、成交量”）

交易热点统计（如：“查询 2024 年单月成交量超过 50 套的小区数量”）

房源特征分析（如：“查询‘精装修’房源的成交均价和平均面积”）

区域对比分析（如：“对比 A 区和 B 区的平均成交总价和成交量”）

市场趋势预测建议（基于历史数据的简单推演）

（3）为确保结果准确性，需要从以下多个维度提供数据支持：

基于 MySQL 数据库中的结构化交易数据（如 tourism_analysis 数据库中的相关表）

基于清洗后的 CSV 文件（如 tourist_value_mark.csv、season_mark.csv 及相关处理结果）

基于大模型的智能解析和推理能力

（4）配置提示词要求：

系统角色设定为 “房地产数据分析专家”

支持 SQL 查询语句的自动生成和解释

支持自然语言到房地产数据分析需求的转换

输出结果需包含数据来源说明（如数据库表、CSV 文件等）

（5）运行应用，测试以下查询场景：

“查询 2024 年各小区月度平均成交单价和成交量”

“哪个小区在 2024 年成交量最高？”

“对比精装修与简装修房源的成交均价差异”

“预测未来一个季度花园小区的成交趋势（基于历史同期数据）”

“查询 2024 年高价值房源（标注为高价值）的分布情况”

（6）将以上 5 个测试场景的查询结果截图分别粘贴至【提交结果.docx】中对应的任务序号下。