2025-2026 学年广东省职业院校技能大赛

中职组大数据应用与服务赛项

样

题

5

一、背景描述

在大数据时代背景下，人们生活习惯发生了很多改变。在传统运营模式中，缺乏数据积累，人们在出行决策过程中更多是凭借个人经验和习惯，选择相对有限且路径固化。而大数据时代，为出行服务提供了一种全新的视角，通过大量的多源数据融合分析得出的结果将更加精准和高效。出行服务作为现代城市运行和居民生活的重要组成部分，其数据分析对于优化交通网络、提升出行效率、改善用户体验具有关键意义。通过收集和分析用户的出行行为数据，包括通勤路线、交通工具偏好、出行时段、消费水平等，可以为出行服务提供者规划更科学的调度方案、设计更个性化的产品提供决策依据。

数据驱动已成为智慧出行发展的核心引擎，大数据技术是提升服务质量的基石。为完成城市出行需求预测与调度优化分析工作，你所在的小组将全面应用大数据技术：通过 Python 语言从多维度进行数据采集，将采集的原始数据进行清洗、集成与处理，并进行有效的数据标注；进而开展深入的数据分析与可视化呈现，通过大数据业务分析方法挖掘出行规律与潜在问题；运行维护数据库系统以保障存储数据的安全与稳定；最终，通过综合运用相关大数据工具软件，解决具体的业务场景问题。作为该小组的技术人员，请按照后续任务要求，完成本次大数据应用与实践工作。。

二、项目一：平台搭建与运维

（一）任务一：大数据平台搭建

1．子任务一：基础环境准备

本任务需要使用 root 用户完成相关配置，安装 Hadoop 前置环境。命令中要求使用绝对路径，具体要求如下：

(1)　配置三个节点的主机名，分别为 master、node01、node02，然后修改每个节点的 hosts 文件，使其三个节点之间互相可以使用主机名访问，在 master 节点上执行 ping -c 4 node01 命令，将命令结果提交至【提交结果.docx】中对应的任务序号下；

(2)　在 master 节点上，将/opt/software 目录下的文件 jdk-8u391-linux-x64.tar.gz 安装包解压到/opt/module 路径中（若路径不存在时，则需新建目录），执行 ll /opt/module 命令，将命令结果提交至【提交结果.docx】中对应的任务序号下；

(3)　在 master 节点上，在/etc/profile 文件中配置 JDK 的环境变量 JAVA_HOME 和 PATH，并立即生效配置文件，在 master 上将/etc/profile 新增的内容截图至【提交结果.docx】中对应的任务序号下；

(4)　在三个节点上，关闭防火墙，设置开机不自启动防火墙，在 master 节点上使用 systemctl status firewalld 命令，查看防火墙状态，将结果提交至【提交结果.docx】中对应的任务序号下；

(5)　配置三个节点的免密登录，并指定 SSH 密钥的类型为 rsa，在 master 节点上通过 SSH 连接 node01 和 node02 来验证，将验证结果截图至【提交结果.docx】中对应的任务序号下；

(6)　将 JDK 安装包分发至 node01 和 node02 对应节点的目录（目录不存在，则需创建）下，并配置 node01 和 node02 的环境变量，同时立即生效配置文件，将完整命令截图至【提交结果.docx】中对应的任务序号下；

(7)　查看 JDK 版本，检查 JDK 是否安装成功，在 node01 节点上将执行命令 java -version 的结果截图至【提交结果.docx】中对应的任务序号下；

(8)　在三个节点上创建 hadoop 用户和设置用户密码，并为 hadoop 用户添加管理员权限，在 master 节点上执行 grep 'hadoop' /etc/sudoers 命令并将结果截图至【提交结果.docx】中对应的任务序号下；

2. 子任务二：Hadoop 完全分布式安装配置

本任务需要使用 root 用户和 hadoop 用户完成相关配置，使用三个节点完成 Hadoop 完全分布式安装配置。命令中要求使用绝对路径，具体要求如下：

(1) 在 master 节点上将/opt/software 目录下的 hadoop-3.1.3.tar.gz 安装包解压到/opt/module 路径中，将解压 hadoop 安装包的完整命令截图至【提交结果.docx】中对应的任务序号下；

(2) 在 master 节点上将解压的 Hadoop 安装目录重命名为 hadoop，同时修改 Hadoop 安装目录及其子文件的所属者为 hadoop，所属组为 hadoop，将完整命令截图至【提交结果.docx】中对应的任务序号下；

(3) 根据如下 hadoop 集群规划表，使用 hadoop 用户，在 master 节点上依次配置 hadoop-env.sh、core-site.xml、hdfs-site.xml、mapred-site.xml、yarn-site.xml、workers 配置文件，并将 yarn-site.xml 文件的内容截图至【提交结果.docx】中对应的任务序号下；

服务器	master	node01	node02
HDFS	NameNode		
HDFS		SecondaryNameNode	
HDFS	DataNode	DataNode	DataNode
YARN	ResourceManager		
YARN	NodeManager	NodeManager	NodeManager
历史日志服务器		JobHistoryServer	

(4) 在 master 节点上配置/etc/profile 文件，添加 Hadoop 环境变量，并立即生效配置文件，在 master 节点上将/etc/profile 新增的内容截图至【提交结果.docx】中对应的任务序号下；

(5) 在 master 节点上使用 scp 命令，分发 Hadoop 的安装目录和环境变量至 node01 和 node02 节点，并将 Hadoop 安装目录的所属者和所属组修改为 hadoop，同时生效环境变量配置文件，将完整的 scp 分发命令截图至【提交结果.docx】中对应的任务序号下；

(6)　在 master 节点上使用 hadoop 用户初始化 Hadoop 环境 namenode 将初始化命令和结果（取最后 20 行）截图至【提交结果.docx】中对应的任务序号下；

(7)　在 master 节点上使用 hadoop 用户依次启动 HDFS、YARN 集群,在 node01 节点上启动历史日志服务。在 master 节点上执行 jps 命令，将命令及结果截图至【提交结果.docx】中对应的任务序号下；

(8)　在 node01 节点上执行 jps 命令，将命令及结果截图至【提交结果.docx】中对应的任务序号下；

（二）任务二：数据库服务器的安装与运维

1. 子任务一：MySQL 安装配置

本任务需要使用 rpm 工具安装 MySQL 并初始化，具体要求如下：

（1） 在 master 节点中的 /opt/software 目录下将 mysql-5.7.25-1.el7.x86_64.rpm-bundle.tar 安装包解压到 /opt/module 目录下；

（2）在 master 节点中使用 rpm -ivh 依次安装 mysql-community-common、mysql-community-libs、mysql-community-libs-compat 、mysql-community-client 和 mysql-community-server 包，将所有命令复制粘贴至【提交结果.docx】 中对应的任务序号下；

（3）在 master 节点中启动数据库系统并初始化 MySQL 数据库系统，将完整命令复制粘贴至【提交结果.docx】 中对应的任务序号下；

2.子任务二：MySQL 运维

本任务需要在成功安装 MySQL 的前提，对 MySQL 进行运维操作，具体要求如下：

（1）修改 MySQL 配置文件启用远程连接，将修改后的配置内容复制粘贴至【提交结果.docx】中对应的任务序号下；

（2）启用 MySQL 慢查询日志功能，设置慢查询阈值为 2 秒，将完整的配置命令和验证命令结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（3）创建名为 hadoop 的数据库用户，密码设置为 Hadoop@2025，将创建用户的完整命令及执行结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（4）为 hadoop 用户授予 bigdata 数据库的 SELECT、INSERT 和 UPDATE 权限，将授权命令及执行结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（5）创建名为 monitor 的监控专用用户，仅授予 PROCESS 和 SHOW DATABASES 权限，将完整命令及执行结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（6）使用 mysqldump 工具备份 bigdata 数据库，将备份文件保存为 bigdata_backup.sql，将备份命令及执行过程复制粘贴至【提交结果.docx】中对应的任务序号下；

（7）配置数据库字符集为 utf8mb4，并将默认排序规则设置为 utf8mb4_unicode_ci，将配置命令和验证结果复制粘贴至【提交结果.docx】中对应的任务序号下；

（8）创建一个定时备份脚本，实现每天凌晨 2 点自动备份 bigdata 数据库到 /opt/backup 目录，并只保留最近 7 天的备份文件，将完整脚本内容复制粘贴至【提交结果.docx】中对应的任务序号下；

3.子任务三：数据表的创建及维护

（1）根据以下数据字段在 bigdata 数据库中创建酒店表 （hotel）。酒店表字段如下：

字段	类型	中文含义	备注
id	int	酒店编号	
hotel_name	varchar	酒店名称	
city	varchar	城市	
province	varchar	省份	
level	varchar	星级	
room_num	int	房间数	
score	double	评分	

commnet_num	varchar	评论数	

（2）根据以下数据字段在 bigdata 数据库中创建评论表 （comment）。评论表字段如下：

字段	类型	中文含义	备注
id	int	评论编号	
name	varchar	酒店名称	
commentator	varchar	评论人	
score	double	评分	
comment_time	datetime	评论时间	
content	varchar	评论内容	

将这两个 SQL 建表语句分别复制粘贴至【提交结果.docx】中对应的任务序号下。

（3）根据已给到的 sql 文件将这两份数据导入 bigdata 数据库中，并对其中的数据进行如下操作：

- 统计各省份的平均酒店评分，并将评分低于该省份平均分的酒店评分上调 0.5 分（评分上限为 5 分）；
- 查找出每个城市评论数最多的酒店及其详细信息；
- 找出所有发表过 3 条及以上差评（评分小于等于 2 分）的评论人，并列出这些评论人的评论时间、评论内容及对应的酒店名称，按评论时间降序排序。

将这 3 个 SQL 语句分别复制粘贴至 【提交结果.docx】中对应的任务序号下。

三、项目二：数据获取与处理

（一）任务一：数据获取与清洗

1. 子任务一：数据获取

有一份出行订单数据文件：订单 ID、日期、乘客年龄段、出行时长（小时）、订单金额（元）、服务评分（1-5 分）、出行方式（如快车、专车）、天气状况、道路状况等信息。

数据已存入到 `travel_order_data.csv` 文件中，请使用 pandas 读取 `travel_order_data.csv` 并将数据集的前 10 行打印在 IDE 终端的截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2. 子任务二：使用 Python 进行数据清洗

请使用 pandas 库加载并分析相关数据集，根据题目规定要求使用 pandas 库实现数据处理，具体要求如下：

（1）删除天气状况为空或为无效值的记录，并将结果存储为 `cleaned_data_c1_N.csv`，N 为删除的数据条数；

（2）删除出行时长异常（超过 12 小时或小于 0.1 小时）的记录，并将结果存储为 `cleaned_data_c2_N.csv`，N 为删除的数据条数；

（3）将出行方式为空的记录填充为“未知”，并存储为 `cleaned_data_c3_N.csv`，N 为修改的数据条数；

（4）将服务评分超出范围（1-5 分）的记录删除，并将结果存储为 `cleaned_data_c4_N.csv`，N 为删除的数据条数；

（5）将订单金额明显异常（超过该出行方式平均订单金额 5 倍）的记录删除，将结果存储为 `cleaned_data_c5_N.csv`，N 为删除的数据条数。

将该 5 个文件名截一张图复制粘贴至【提交结果.docx】中对应的任务序号下。

（二）任务二：数据标注

1. 子任务一：乘客价值分类标注

使用 Python 编写脚本，根据乘客的订单金额和出行时段对乘客进行价值分类标注。具体的分类要求如下：

（1）高价值乘客：订单金额高于平均值的 1.5 倍且出行时段位于高峰时段（如 07-09 点或 17-19 点）；

（2）中价值乘客：订单金额在平均值的 0.5-1.5 倍之间且出行时段在平峰时段（如 10-16 点）；

（3）低价值乘客：不满足上述条件的乘客。

在数据集中新增一列“乘客价值类型”，根据上述标准进行标注，存入 `passenger_value_mark.csv` 文件中。具体格式如下：

编号	出行方式	订单金额(元)	出行时段(小时)	乘客价值类型
1	专车	85	8.5	高价值乘客

将 `passenger_value_mark.csv` 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：出行需求旺季标注

使用 Python 编写脚本，根据每月的订单总量和平均订单金额对出行需求强度进行标注。具体的分类要求如下：

（1）旺季：月订单量超过年平均值的 120%且月平均订单金额超过年平均值的 110%；

（2）平季：月订单量在年平均值的 80%-120%之间或月平均订单金额在年平均值的 90%-110%之间；

（3）淡季：月订单量低于年平均值的 80%且月平均订单金额低于年平均值的 90%。

在数据集中新增一列“需求季节类型”，根据上述标准对每个月份进行标注，存入 `demand_season_mark.csv` 文件中。具体格式如下：

月份	订单总量	平均订单金额(元)	同比年平均	需求季节类型
1 月	45000	38	85%	淡季

将 `demand_season_mark.csv` 打开后直接截图（不用下拉）复制粘贴至【提交结果.docx】中对应的任务序号下。

（三）任务三：数据统计

1．子任务一：HDFS 文件操作

本任务需要使用 Hadoop、HDFS 命令，已安装 Hadoop 及需要配置前置环境，具体要求如下：

（1）在 HDFS 目录下新建目录 `/travel_order_data`，将新建目录的完整命令粘贴至【提交结果.docx】中对应的任务序号下；

（2）修改权限，赋予目录 `/travel_order_data` 最高 777 权限，将修改目录权限的完整命令粘贴至【提交结果.docx】对应的任务序号下；

（3）将本地的出行订单数据集上传至 HDFS 的 `/travel_order_data` 目录下，并验证文件是否上传成功，将完整命令粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：使用 MapReduce 进行数据分析

本任务需要使用 Hadoop 的 MapReduce 功能完成数据分析任务，具体要求如下：

（1）编写 MapReduce 程序，统计不同出行方式的日均订单数量；

（2）将统计结果存储到 HDFS 的 `/travel_analysis/daily_avg_orders` 目录下；

（3）运行 MapReduce 程序并查看执行结果，将运行命令和结果的前十行截图粘贴至【提交结果.docx】中对应的任务序号下。

3. 子任务三：使用 Hive 进行数据分析

本任务需要使用 Hive 完成数据分析任务，具体要求如下：

（1）在 Hive 中创建外部表 `travel_orders`，加载 HDFS 中的出行订单数据；

（2）编写 HQL 查询，分析以下内容：

- 统计每个月的订单总量和平均订单金额
- 计算不同天气状况下的订单总量和平均服务评分
- 统计不同出行方式在工作日和周末的订单分布

（3）将查询结果导出到本地文件系统，并将导出命令和结果截图粘贴至【提交结果.docx】中对应的任务序号下。

四、项目三：业务分析与可视化

（一）任务一：数据分析与可视化

1. 子任务一：数据分析

本任务要求使用 Python 对出行订单数据进行深入分析，揭示乘客出行规律和平台运营特点。参赛者需要使用 Python 的数据处理和分析库完成以下任务：

（1）分析各出行方式的订单分布，找出最主要的出行方式（占比超过 40%）；

（2）计算不同年龄段乘客的平均订单金额和常用出行时段，发现最具消费潜力的乘客群体；

（3）分析周末和工作日的订单量差异，计算周末订单量相对工作日的增长百分比；

（4）统计不同天气状况下的订单比例，并根据平均订单金额对天气状况进行排序；

（5）分析服务评分与订单金额的关系，计算相关系数。

将这 5 个统计结果在 IDE 的控制台中打印并分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。

2．子任务二：数据可视化

本任务要求使用 pyecharts 库创建交互式数据可视化图表，帮助直观地展示出行数据分析结果。具体要求如下：

（1）创建玫瑰图展示各出行方式订单量分布 要求：使用玫瑰图展示不同出行方式的年度订单总量占比，每个扇形区域的半径表示订单量大小，颜色深浅代表订单量级别，并添加图例说明和标题。图表需要支持鼠标悬停显示详细数据。

（2）制作气泡图分析订单特征 要求：创建气泡图展示各出行方式的特征分布，横轴表示平均订单金额，纵轴表示日均订单量，气泡大小表示平均服务评分，颜色表示出行方式类型。图表需要支持图例筛选和缩放交互。

（3）绘制堆叠面积图展示一周内各时段订单量变化趋势 要求：使用堆叠面积图展示一周内（周一至周日）各小时段订单量的变化趋势，不同颜色代表不同日期类型（工作日/周末），需要显示小时数据点，并支持区域高亮显示。

（4）创建雷达图对比不同乘客群体特征 要求：使用雷达图对比不同年龄段乘客的出行特征，包含订单金额、出行距离偏好、服务评分、出行频率、夜间订单比例等维度，并添加数据标签。

将以上 4 个可视化图表分别截图复制粘贴至【提交结果.docx】中对应的任务序号下。图表必须包含完整的标题、图例、坐标轴标签等要素，确保图表清晰易读、专业美观。

（二）任务二：业务分析

出行服务行业的数据分析对于提升平台运力调度效率和乘客体验至关重要。本任务要求对出行订单数据进行深入的业务分析，识别关键问题并提出改进建议。

1．基础指标分析

使用提供的数据集，计算并分析以下核心指标：

（1）运力指标分析

- 日均订单量：计算每日订单总数的算术平均值
- 订单波动系数：使用标准差除以平均值来衡量订单的稳定性

- 节假日订单比：节假日期间日均订单量与普通日期日均订单量的比值

（2）收益行为分析

- 平均客单价：订单总金额除以总订单数
- 不同群体消费差异：按年龄段和出行方式分组计算平均订单金额

（3）服务质量评估

- 服务评分：采用 5 分制，计算所有有效评分的加权平均值

2．运营建议

基于上述分析结果，从以下三个方面提出具体的运营优化建议：

（1）动态定价策略：结合订单波动规律和乘客支付能力，设计分时段、分区域的动态调价方案。

（2）运力调度优化：针对高峰时段和热点区域，提出司机调度的具体优化措施。

（3）精准营销建议：基于高价值乘客画像，设计有针对性的优惠券或会员权益策略。

请将分析报告（不超过 300 字）提交至【提交结果.docx】中对应的任务序号下。报告内容应包含数据分析结果和具体可行的运营建议。

五、项目四：AI 大模型应用开发综合实践

随着人工智能技术的快速发展，越来越多的企业和开发者希望能够使用强大的 AI 模型来处理各类任务，如自然语言处理、文本生成、自动化客服、智能推荐等。在此背景下，利用 Ollama 和 Dify 搭建一个可定制的 AI 系统成为了提升智能应用的重要途径。

通过 在 openEuler 系统上搭建一个基于 Ollama 和 Docker 的 AI 大模型平台，可以通过 Dify 平台将 Ollama 注册为模型供应商，从而实现不同服务应用效果。Dify 是一个轻量级的 AI 平台，能够快速整合模型和应用，允许用户通过简单的配置和管理，调用不同的 AI 模型提供服务。

（一）任务一：AI 大模型服务综合部署

1.子任务一：基本配置

本任务需要使用 root 用户完成相关配置，已提供操作系统镜像及需要配置前置环境，所需软件安装包均在/root/目录下。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中将操作系统镜像挂载至/media/cdrom，并实现开机自启。

（2）在 AI-SRV 中完成软件源配置文件的编写，禁用 GPG 校验，并为源数据建立缓存。

2.子任务二：环境搭建

本任务需要使用 root 用户完成相关配置，已提供 ollama 安装包及需要配置前置环境。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中为 ollama 配置用户/组，该用户仅用于运行服务，禁止其登录系统，家目录位于/usrlshare/ollama。

（2）在 AI-SRV 中为 root 用户加入附加组 ollama。

（3）在 AI-SRV 中将文件 ollama-linux-amd64.tgz 解压安装至/usr 目录下。

（4）在 AI-SRV 中编写 SystemD 服务配置，使用服务运行专用用户完成启动，无论发生任何意外情况，服务都会进行自动重启（冷却 3 秒），以保证服务可靠运行，服务需要监听所有地址。

（5）在 AI-SRV 中启动 ollama 服务，并完成开机启动配置，最终启动 ollama 服务。

（6）在 AI-SRV 中导入 1.5b.tgz 压缩文件模型至 ollama。

（二）任务二：AI 大模型综合应用开发

1.子任务一：Dify 运行环境搭建

本任务需要使用 root 用户完成相关配置，已提供安装 dify 及需要配置前置环境。命令中要求使用绝对路径，具体要求如下:

（1）在 AI-SRV 中完成 Docker 环境的安装，并查看 Docker 版本信息。

（2）在 AlI-SRV 中将文件 dify-0.14.2.tar.gz 解压至/opt 路径中。

（3）在 AI-SRV 中完成 dify 镜像的导入，相关文件位于 dify-images 目录中，完成后检查镜像列表。

（4）在 AI-SRV 中完成 dify 的启动，并在客户机中访问 AI-SRV 中的 dify web 服务。

（5）在客户机中访问 dify，完成用户注册，邮箱为 admin@dify.ai，用户名为 admin，密码为 Qwer1234，注册后登录 dify 管理页面。

（6）在客户机中访问 dify，完成对 ollama 模型提供商的注册。

2 子任务二：出行服务智能助手构建

本任务需要基于前置环境完成，选手须先自行完成配置，具体要求如下：

（1）根据出行服务数据分析场景需要，创建空白应用 “Travel Service Assistant”。

（2）为用户提供出行订单智能查询功能，其中参数包含：Query（查询内容），支持以下类型的查询：

- 出行方式订单分析（如：“查询‘专车’在过去一个月的日均订单量”）
- 高价值乘客画像查询（如：“查询高价值乘客最常用的出行时段和出行方式”）
- 天气与订单影响分析（如：“查询‘雨天’对各类出行方式订单量的影响程度”）
- 区域订单对比分析（如：“对比工作日与周末在高峰时段的订单分布差异”）

- 出行趋势预测建议（基于历史数据的简单推演）

（3）为确保结果准确性，需要从以下多个维度提供数据支持：

- 基于MySQL数据库中的结构化出行订单数据（如 `bigdata` 数据库中的 `travel_order`、`hotel` 等表）

- 基于清洗后的CSV文件（如 `cleaned_data_c5_N.csv` 及相关处理结果）

- 基于大模型的智能解析和推理能力

（4）配置提示词要求：

- 系统角色设定为“出行服务数据分析专家

- 支持SQL查询语句的自动生成和解释

- 支持自然语言到出行数据分析需求的转换

- 输出结果需包含数据来源说明（如数据库表、CSV文件等）

（5）运行应用，测试以下查询场景：

1. 查询2025年第三季度‘快车’出行方式的月度订单总量

2. 哪些年龄段的乘客在周末订单金额最高？

3. 对比晴天与雨天情况下，‘专车’与‘快车’的平均服务评分差异

4. 预测下个月工作日早高峰（7-9点）的订单趋势（基于历史同期数据）

5. 查询2025年节假日期间订单量最高的前三个城市及其平均订单金额