样题2

模块一：平台搭建与运维

(一)任务一：大数据平台搭建

1.子任务一：基础环境准备

(1)`ifconfig` 查看ip

`hostnamectl set-hostname master` 配置主机名

`systemctl restart network`

`vim /etc/hosts` 打开hosts文件，在里面写入以下内容

```
ip地址 master
ip地址 slave1
ip地址 slave2
```

`cat/etc/hosts`

(2)`tar -zxvf /opt/software/jdk-8u191-linux-x64.tar.gz -C /opt/module` 将文件解压到/opt/module

(3)`vim /etc/profile` 打开配置文件 添加以下内容

```
export JAVA_HOME=/opt/module/jdk
export PATH=$PATH:$JAVA_HOME/bin
```

`source /etc/profile` 立即生效

(4)`java -version`

(5)`useradd hadoop` 创建用户hadoop

`passwd hadoop` 设置密码

`visudo /etc/sudoers` 添加以下内容

```
hadoop  ALL=(ALL)       NOPASSWD:ALL
```

`grep 'hadoop' /etc/sudoers`

(6)`systemctl stop firewalld` 关闭防火墙

`systemctl disable firewalld` 禁止开机自启

`systemctl status fierwalld` 查看状态

(7)`ssh-keygen -t rsa` 生成密钥

`ssh-copy-id hadoop@slave1` 复制公钥

`ssh-copy-id hadoop@slave2`

`sudo service sshd restart` 重启ssh服务
`ssh slave1(slave2)` ssh连接

2.子任务二：Hadoop 完全分布式安装配置

(1)`tar -zxvf /opt/software/hadoop- 3.3.6.tar.gz -C /opt/module` 将文件解压到/opt/module
(2)`mv /opt/module/hadoop-3.3.6 /opt/module/hadoop` 重命名为hadoop
`chown -R hadoop:hadoop /opt/module/hadoop` 修改所属组者
(3)`cd /opt/module/hadoop/etc/hadoop`
hadoop-env.sh

```shell
export JAVA_HOME=/opt/module/jdk
export HADOOP_HOME=/opt/module/hadoop
export HADOOP_CONF_DIR=${HADOOP_HOME}/etc/hadoop
export HADOOP_LOG_DIR=${HADOOP_HOME}/logs
```

core-site.xml

```xml
<property>
   <name>fs.defaultFS</name>
   <value>hdfs://master:9820</value>
</property>
<property>
   <name>hadoop.tmp.dir</name>
   <value>/opt/module/hadoop/tmp</value>
</property>
```

hdfs-site.xml

```xml
<property>
   <name>dfs.replication</name>
   <value>3</value>
</property>
<property>
   <name>dfs.namenode.secondary.http-address</name>
   <value>master:9896</value>
</property>
<property>
   <name>dfs.datanode.data.dir</name>
   <value>/opt/module/hadoop/datanode/data</value>
</property>
```

mapred-site.xml

XML

```xml
<property>
   <name>mapreduce.framework.name</name>
   <value>yarn</value>
</property>
<property>
   <name>mapreduce.jobhistory.address</name>
   <value>master:10020</value>
</property>
<property>
   <name>mapreduce.jobhistory.webapp.address</name>
   <value>master:19888</value>
</property>
```

yarn-site.xml

XML

```xml
<property>
   <name>yarn.resourcemanager.hostname</name>
   <value>master</value>
</property>
<property>
   <name>yarn.nodemanager.aux-services</name>
   <value>mapreduce_shuffle</value>
</property>
<property>
   <name>yarn.log-aggregation-enable</name>
   <value>true</value>
</property>
<property>
   <name>yarn.log.server.url</name>
   <value>http://master:19888/jobhistory/logs</value>
</property>
```

masters

```
master
slave1
slave2
```

workers

```
slave1
slave2
```

(4)`scp -r /opt/module/hadoop hadoop@slave1:/opt/module/` 拷贝安装目录到slave1
`scp -r /opt/module/hadoop hadoop@slave2:/opt/module/` 拷贝安装目录到slave2
(5)`chown -R hadoop:hadoop /opt/module/hadoop` 其余两个节点hadoop 安装目录的所有文件修改所属组者
(6)`vim /etc/profile` 打开配置文件 添加以下内容

```
export HADOOP_HOME=/opt/module/hadoop
export PATH=$PATH:$HADOOP_HOME/bin:$HADOOP_HOME/sbin
```

`source /etc/profile` 立即生效
(7)`su - hadoop`
`hdfs namenode -format` master节点初始化
日志
.....
(8)`start-dfs.sh`
`start-yarn.sh`
`mapred --daemon start historyserver`
`jps`
结果...
(9)`jps`
结果...

(二)任务二：数据库服务器的安装与运维

1.子任务一：MySQL 安装配置

(1)`tar -xvf /opt/software/mysql-5.7.44-1.el7.x86_64.rpm-bundle.tar -C /opt/module` 将文件解压到/opt/module
(2)`rpm -ivh mysql-communitycommon mysql-community-libs mysql-community-libscompat mysql-community-client mysql-community-server` 安装解压出的包
(3)`systemctl start mysqld` 启动mysql系统
`systemctl enable mysqld` 设置开机自启
`mysqld --initialize --user=mysql` 初始化设置
`systemctl status mysqld` 查看状态

2.子任务二：MySQL 运维

(1)`vim /etc/my.cnf` 打开配置文件 在[mysqld]部分添加以下内容

```
bind-address = 0.0.0.0  # 允许所有IP连接
```

`systemctl restart mysqld` 重启服务(若需要)
(2)`mysql -u root -p` 登录mysql
`use mysql;`
`update user set host='%' where user='root';` 配置 root 用户允许任意 IP 连接
(3)`mysql -u root -p` 登录mysql
`use mysql;` 切换到mysql库
`show tables;` 查看库中所有表
(4)`create user 'eduadmin'@'%' identified by '密码';` 创建eduadmin用户
(5)`create database education default character set utf8mb4 collate utf8mb4_unicode_ci;` 创建数据库 education 并设置正确的字符集
(6)`grant select on education.* to 'eduadmin'@'%';` 授予查询权限
(7)`flush privileges;` 刷新

3.子任务三：数据表的创建及维护

(1)`use education;` 使用education库(若需要)
创建course表

```
create table course (
   id int primary key ,
   course_name varchar(n),
   category varchar(n),
   level varchar(n),
   duration int ,
   price decimal(n,n),
   instructor varchar(n),
   avg_rating float,
   enrollment_count int
) ;
```

(2)创建learning_record表

```
create table learning_record (
   id int primary key,
   user_id int,
   course_id int,
   watch_duration int,
   completion_rate float,
   last_watch_time datatime,
   quiz_score float,
   study_duration int
) ;
```

(3)查询每门课程的平均完成率

```
select
   l.course_id,
   avg(l.completion_rate) as 平均完成率
from
   learning_record as l
group by
   l.course_id;
```

统计每个课程类别的总报名人数

```
select
   category,
   sum(enrollment_count)
from
   course
group by
   category;
```

查找观看时长超过课程时长的学习记录

```
select
   c.duration as "课程时长",
   l.*
from
   learning_record as l
join
   course as c
on
   l.course_id = c.id
where
   l.watch_duration > "课程时长";
```

模块二：数据获取与处理

(一)任务一：数据获取与清洗

1.子任务一：数据获取

读取数据CSV文件

```
import pandas as pd
data = pd.read_csv('learning_data.csv')
print(data.head(10))
```

2.子任务二：使用 Python 进行数据清洗

(1)删除学习时长为空或为 0 的记录，并将结果存储为 `cleaned_data_c1_21.csv`，N 为删除的数据条数
(2)删除测验成绩异常（大于 100 分或小于 0 分）的记录，并将结果存储为 `cleaned_data_c2_155.csv`，N 为删除的数据条数
(3)将最后学习时间格式不规范的记录进行标准化处理（统一用 `pd.to_datetime` 解析，无法解析的置为 `NaT`），并将结果存储为 `cleaned_data_c3_41.csv`，N 为修改的数据条数
(4)将完成进度超过 100% 的记录设置为 100%，并将结果存储为 `cleaned_data_c4_146.csv`，N 为修改的数据条数
(5)删除重复的学习记录，并将结果存储为 `cleaned_data_c5_0.csv`，N 为删除的数据条数

清洗过程行数变化：原始数据 1000 条 → c1 后 979 条 → c2 后 824 条 → c3 后 824 条 → c4 后 824 条 → c5 后 824 条。

(二)任务二：数据标注

1.子任务一：学习投入度标注

根据学习时长与互动次数两个维度标注学习投入度，结果存入 `engagement_level.csv`（824 行，列：记录ID、课程名称、学习时长(分钟)、互动次数、学习投入度）。标注结果分布为：高度投入 662 条、中度投入 134 条、低度投入 28 条，高度投入记录占全部记录的 80.34%，说明平台学习者整体投入度较高。

2.子任务二：学习模式标注

先按用户聚合出主要学习时段、常用设备与平均单次时长，再按学习时段和设备使用情况标注学习模式，结果存入 `learning_pattern.csv`（198 行，列：用户ID、主要学习时段、常用设备、平均单次时长、学习模式）。标注结果分布为：周末集中型 161 人、工作学习型 31 人、夜间学习型 5 人、碎片学习型 1 人，周末集中型占全部 198 位用户的 81.31%；从用户特征看，主要学习时段以下午（55 人）、凌晨（51 人）为主，常用设备以平板端（84 人）、移动端（58 人）为主，单个用户的平均单次学习时长在 18.0~240.0 分钟之间。

(三)任务三：数据统计

1.子任务一：HDFS 文件操作

(1)`hdfs dfs -mkdir /education_data` 创建目录
(2)`hdfs dfs -chmod 777 /education_data` 授予权限

(3)`hdfs dfs -put <本地路径> /education_data` 上传文件

2.子任务二：计算输入文件中的单词数

(1)`hdfs dfs -mkdir -p /user/hadoop/comments`
(2)`hdfs dfs -put <本地路径> /user/hadoop/comments`
(3)`hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar wordcount /user/hadoop/comments/comments.txt /user/hadoop/comment_stats` 使用默认wordcount
(4)`hdfs dfs -cat /user/hadoop/comment_stats/part-r-00000 | head -n 10` 查看统计结果并将结果前十行

3.子任务三：学习行为分析

(1)Map 阶段：将每个用户的学习记录按时间排序；Reduce 阶段：统计每个用户的最长连续学习天数
(2)结果要求包含以下字段：用户ID、起始日期、结束日期、连续天数
(3)将分析结果存储到 HDFS 的 `/user/hadoop/learning_streak` 目录下
(4)查看分析结果并将前十行数据截图，结果如下

```
用户ID   起始日期 结束日期 连续天数
7962    2025-02-27  2025-03-01  3
2210    2025-04-29  2025-04-30  2
8803    2024-10-21  2024-10-22  2
1068    2025-01-11  2025-01-11  1
1070    2025-05-21  2025-05-21  1
1072    2024-09-12  2024-09-12  1
1107    2025-03-31  2025-03-31  1
1130    2024-09-18  2024-09-18  1
1139    2025-01-02  2025-01-02  1
1247    2024-09-07  2024-09-07  1
```

统计结果共覆盖 197 个用户，最大连续学习天数为 3 天，连续天数分布为 1 天 194 人、2 天 2 人、3 天 1 人。

模块三：业务分析与可视化

(一)任务一：数据分析与可视化

1.子任务一：数据分析

(1)各类别课程完课率（完成进度达 100% 的学习者人数 / 课程报名总人数）降序前三名：兴趣 22.90%（30/131）、数据科学 21.31%（26/122）、商业 19.38%（25/129）
(2)各时间段平均学习时长：凌晨 128.14 分钟（213 条）、上午 124.57 分钟（207 条）、下午 117.48 分钟（198 条）、晚上 112.11 分钟（206 条），学习参与度最高的时间段为凌晨

(3)不同难度等级课程的平均测验成绩：等级 A 51.41 分、B 50.64 分、C 40.77 分、D 49.41 分、E 51.55 分、F 46.06 分、G 53.32 分、H 54.94 分、I 56.91 分、J 50.73 分、K 50.95 分、L 53.19 分；C 等级明显偏低，说明难度梯度设置存在偏难的部分
(4)设备使用比例与平均单次学习时长：平板端 305 条、占比 37.01%、平均 121.42 分钟；PC 端 277 条、占比 33.62%、平均 119.03 分钟；移动端 242 条、占比 29.37%、平均 121.61 分钟，用户最偏好平板端
(5)课程学习黏性：连续学习天数大于 7 天的用户 0 人，占比 0.00%（本数据集单个用户最长连续学习天数仅 3 天，197 个用户的连续天数分布为 1 天 194 人、2 天 2 人、3 天 1 人）；退化为用连续学习天数最长的用户（用户 7962，连续 3 天）排序，其学习记录前三门课程为机器学习原理 2 条、英语口语 1 条、Java 核心技术 1 条

2.子任务二：数据可视化

(1)多系列折线图：横轴为星期一至星期日，纵轴为学习人数，用不同颜色的线条区分上午、下午、晚上三个时段，添加图例、标题和坐标轴标签，并在关键点标注数值
(2)堆叠柱状图：横轴为课程类别，纵轴为课程数量，用不同颜色代表入门、初级、中级、高级四个难度级别，显示各部分占比数据并添加图例说明

(二)任务二：业务分析

(1)课程参与度分析：财务分析平均学习时长 127.4 分钟、平均完课率 63.6%、平均测验得分 50.9 分、互动率 96.3%；Java 核心技术 113.1 分钟、60.4%、51.4 分、93.5%；机器学习原理 135.0 分钟、62.1%、56.9 分、91.8%；Web 开发实战 108.1 分钟、52.0%、49.4 分、97.2%；英语口语 116.8 分钟、56.5%、50.7 分、93.0%。整体学习者互动率 100.00%（198/198 人有互动记录）。最受欢迎的课程特征是学习投入时长、完课率与互动率三项同时偏高
(2)学习者行为分析：最佳学习时段为凌晨，平均单次学习 128.14 分钟；学习持续性方面，连续学习天数大于 7 天的用户占比 0.00%，最长连续 3 天，粘性整体偏低；设备偏好方面平板端占比最高（37.01%），PC 端次之（33.62%），移动端最低（29.37%），三类设备平均时长差异在 3 分钟以内
(3)课程效果评估：学习时长与测验成绩的皮尔逊相关系数 `r = -0.0104`（n=824），两者几乎无线性相关，测验成绩主要由课程难度决定而非学习时长；各难度等级平均分分布在 40.77～56.91 分之间，等级 C 仅 40.77 分，是难度设置不合理、需要优先优化的环节；完课率（进度达 100% 的记录占比）最低的课程为英语口语 12.68%（9/71），平均完成进度最低的课程为 Web 开发实战 51.96%，这两门课应作为内容与难度优化的优先对象