样题3

模块一：平台搭建与运维

(一)任务一：大数据平台搭建

1.子任务一：基础环境准备

(1)`ifconfig`

`hostnamectl set-hostname master` 配置主机名

`systemctl restart network`

`vim /etc/hosts`

```
ip master
ip slave1
ip slave2
```

`cat /etc/hosts`

(2)`tar -zxvf /opt/software/jdk-8u191-linux-x64.tar.gz -C /opt/module`

`mv` 重命名

(3)`vim /etc/profile`

```
export JAVA_HOME=/opt/module/jdk
export PATH=$PATH:$JAVA_HOME/bin
```

`source /etc/profile`

(4)`java -version`

(5)`useradd hadoop`

`passwd hadoop`

`visudo /etc/sudoers` 添加一下内容

```
hadoop ALL=(ALL)    NOPASSWD:ALL
```

(6)`systemctl stop firewalld`

`systemctl disable firewalld` 禁止开机自启

`systemctl status firewalld`

(7)`ssh-keygen -t rsa`

`ssh-copy-id hadoop@slave1`

`ssh-copy-id hadoop@slave2`

`ssh slave1`

2.子任务二：Hadoop 完全分布式安装配置

(1)`tar -zxvf /opt/software/hadoop- 3.3.6.tar.gz -C /opt/module`
`mv /opt/module/Hadoop /opt/module/hadoop`

(2)`chown -R hadoop:hadoop /opt/module/hadoop`

(3)`cd /opt/module/hadoop/etc/hadoop`

hadoop-env.sh

```shell
export JAVA_HOME=/opt/module/jdk
export HADOOP_HOME=/opt/module/hadoop
export HADOOP_CONF_DIR=${HADOOP_HOME}/etc/hadoop
export HADOOP_LOG_DIR=${HADOOP_HOME}/logs
```

core-site.xml

```xml
<property>
   <name>fs.defaultFS</name>
   <value>hdfs://master:9820</value>
</property>
<property>
   <name>hadoop.tmp.dir</name>
   <value>/opt/module/hadoop/tmp</value>
</property>
```

hdfs-site.xml

```xml
<property>
   <name>dfs.replication</name>
   <value>3</value>
</property>
<property>
   <name>dfs.namenode.secondary.http-address</name>
   <value>master:9896</value>
</property>
<property>
   <name>dfs.datanode.data.dir</name>
   <value>/opt/module/hadoop/datanode/data</value>
</property>
```

mapred-site.xml

XML

```xml
<property>
   <name>mapreduce.framework.name</name>
   <value>yarn</value>
</property>
<property>
   <name>mapreduce.jobhistory.address</name>
   <value>master:10020</value>
</property>
<property>
   <name>mapreduce.jobhistory.webapp.address</name>
   <value>master:19888</value>
</property>
```

yarn-site.xml

XML

```xml
<property>
   <name>yarn.resourcemanager.hostname</name>
   <value>master</value>
</property>
<property>
   <name>yarn.nodemanager.aux-services</name>
   <value>mapreduce_shuffle</value>
</property>
<property>
   <name>yarn.log-aggregation-enable</name>
   <value>true</value>
</property>
<property>
   <name>yarn.log.server.url</name>
   <value>http://master:19888/jobhistory/logs</value>
</property>
```

masters

```
master
slave1
slave2
```

workers

```
slave1
slave2
```

(二)任务二：数据库服务器的安装与运维

1.子任务一：MySQL 安装配置

(1)`tar -zxvf /opt/software/mysql-5.7.44-1.el7.x86_64.rpm-bundle.tar -C /opt/module`

(2)`rpm -ivh mysql-communitycommon mysql-community-libs mysql-community-libscompat mysql-community-client mysql-community-server`

(3)`systemctl start mysqld`
`systemctl enable mysqld`
`mysqld --initialize --user=mysql` 初始化

2.子任务二：MySQL 运维

(1)`vim /etc/my.cnf`

```
bind-address = 0.0.0.0
```

(2)`use mysql;`
`update user set host='%' where set user='root';` 配置 root 用户允许任意 IP 连接

(3)`mysql -u root -p`
`use mysql;`
`show tables;`

(4)`create user 'bike_admin'@'%' identified by '密码';`

(5)`create database bike_data default character set utf8mb4 collate utf8mb4_unicode_ci;`

(6)`grant select,insert on bike_data.* to 'bike_admin'@'%';`

(7)`flush privileges`

3.子任务三：数据表的创建及维护

(1)

```
create table ride_records(
   id int primary key,
   bike_id varchar(n),
   user_id varchar(n),
   start_time datetime,
   end_time datetime,
   start_location varchar(n),
   end_location varchar(n),
   ride_distance double,
   ride_duration int,
);
```

(2)

```
create table bike_status(
   bike_id varchar(n),
   status varchar(n),
   battery_level int,
   last_maintain_time datetime,
   current_location varchar(n),
   total_mileage double
);
```

(3)在Linux中

`mysql -u bike_admin -p bike_data < *.sql`

在MySQL中

`use bike_data;`

`source /opt/.../*.sql;`

在 ride_records 表中查询骑行时长超过60分钟的记录数量

```
select
   count(*)
from
   ride_records
where
   ride_duration > 60;
```

在 bike_status 表中统计各个状态的单车数量

```
select
   status,count(*)
from
   bike_status
group by
   status;
```

模块二：数据获取与处理

(一)任务一：数据获取与清洗

1.子任务一：数据获取

```
import pandas as pd
data = pd.read_csv('bike_rides.csv',rnow=10)
print(data)
```

2.子任务二：使用 Python 进行数据清洗

(1)删除骑行距离为空或为 0 的记录，并将结果存储为 `cleaned_data_c1_26.csv`，N 为删除的数据条数
(2)删除骑行时长小于 1 分钟或大于 24 小时的异常记录，并将结果存储为 `cleaned_data_c2_25.csv`，N 为删除的数据条数
(3)将天气状况中的空值替换为该时段最常见的天气状况（众数为「多云」），并存储为 `cleaned_data_c3_30.csv`，N 为修改的数据条数
(4)识别并删除重复的骑行记录，将结果存储为 `cleaned_data_c5_19.csv`，N 为删除的数据条数（题目原文编号为第 (4) 步，但要求输出的文件名是 `cleaned_data_c5_N.csv`，没有 c4）

清洗过程行数变化：原始数据 10020 条 → c1 后 9994 条 → c2 后 9969 条 → c3 后 9969 条 → 去重后 9950 条。

(二)任务二：数据标注

1.子任务一：骑行距离分类标注

根据骑行距离把骑行记录分为短途、中途和长途，结果存入 `ride_distance_mark.csv`（9950 行，列：骑行ID、开始时间、骑行距离(km)、距离分类）。标注结果分布为：长途 9788 条（98.37%）、中途 109 条（1.10%）、短途 53 条（0.53%），超长途骑行是本数据集的绝对主体。

2.子任务二：时段热度标注

基于骑行开始时间与周末标记标注时段热度，结果存入 `time_period_mark.csv`（9950 行，列：骑行ID、开始时间、周末标记、时段热度）。标注结果分布为：低峰时段 5557 条（55.85%）、平峰时段 2618 条（26.31%）、高峰时段 1775 条（17.84%），工作日早晚高峰 7:00-9:00 与 17:00-19:00 的骑行量占全部记录的不足两成。

(三)任务三：数据统计

1.子任务一：HDFS 文件操作

(1)`hdfs dfs -mkdir /bike_data`
(2)`hdfs dfs -chown 777 /bike_data`
(3)`hdfs dfs -get /bike_data /tmp`

2.子任务二：计算输入文件中的单词数

(1)`hdfs dfs -mkdir -p /user/hadoop/input`
(2)`hdfs dfs -put /var/log/dmesg /user/hadoop/input`
(3)`hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar wordcount /user/hadoop/input/dmesg /user/hadoop/output`
(4)`hdfs dfs -cat /user/hadoop/output/*** | head -n 10`

3.子任务三：计算区域平均骑行时长

(1)编写 MapReduce 程序，计算每个区域（根据起始位置划分）的平均骑行时长，输入数据格式为 **`起始位置,结束位置,骑行时长(分钟)`**
(2)Map 函数从输入数据中提取起始位置的区域名称和骑行时长，Reduce 函数计算每个区域的平均骑行时长
(3)将计算结果输出到 HDFS 的 `/user/hadoop/avg_duration` 目录下，输出格式为 **`区域名称 平均骑行时长(分钟)`**
(4)查看程序运行结果，结果如下

```
区域名称 平均骑行时长(分钟)
东城区 726.2
顺义区新国展 726.0
大兴区亦庄 725.6
海淀区 722.9
石景山区鲁谷 721.6
延庆区延庆镇 720.0
房山区良乡 717.7
门头沟区石门营 717.1
昌平区 716.3
西城区 711.5
```

模块三：业务分析与可视化

(一)任务一：数据分析与可视化

1.子任务一：数据分析

(1)按平均骑行量排序的前三个高峰时段：22 时 5.12 次/天、10 时 5.06 次/天、17 时 4.94 次/天。夜间 22 点是全天最活跃的时段，10 点与 17 点的通勤需求紧随其后
(2)不同天气状况下的平均骑行时长和平均骑行距离：中雨 729.07 分钟 / 182.17 km（1299 次）、多云 700.41 分钟 / 174.51 km（1334 次）、大雨 718.66 分钟 / 179.39 km（1235 次）、小雨 712.80 分钟 / 177.24 km（1172 次）、晴 692.68 分钟 / 173.98 km（1303 次）、阴 720.70 分钟 / 180.42 km（1186 次）、雪 715.93 分钟 / 181.29 km（1217 次）、雾 726.49 分钟 / 181.86 km（1204 次）。晴天的骑行时长与距离最低，恶劣天气并未抑制骑行总量，只改变了单次骑行的长短
(3)工作日与周末骑行模式差异：工作日平均骑行量 110.39 次/天、平均骑行时长 713.43 分钟、平均骑行距离 178.55 km（共 7065 次，覆盖 64 天）；周末平均骑行量 110.96 次/天、平均骑行时长 716.56 分钟、平均骑行距离 179.39 km（共 2885 次，覆盖 26 天）。两者差异极小，工作日与周末的骑行模式基本一致
(4)最热门的上车区域与下车区域：最热门上车区域为顺义区新国展（起始次数 589），最热门下车区域为大兴区亦庄（结束次数 590），两者恰好构成一对供需缺口明显的区域
(5)不同温度区间的平均骑行量：0°C以下 13.92 次/天（1253 次）、0-10°C 27.74 次/天（2497 次）、10-20°C 27.17 次/天（2445 次）、20-30°C 28.07 次/天（2526 次）、30°C以上 13.66 次/天（1229 次）。0～30°C 区间骑行量稳定在 27～28 次/天，两端区间明显偏低，说明极端气温会抑制骑行需求

2.子任务二：数据可视化

(1)创建时间热力图展示一周内各时段的骑行量分布，横轴为星期（周一至周日），纵轴为小时（0-23 时），颜色深浅表示骑行量的多少
(2)使用折线图展示一天 24 小时内的骑行量变化趋势，图中包含工作日和周末两条折线，用于对比不同类型日期的使用模式差异
(3)制作区域流向图，展示不同区域之间的骑行流量，用箭头的粗细表示流量大小，颜色表示平均骑行时长
(4)创建散点图分析气温与骑行量的关系，横轴为温度，纵轴为日骑行量，每个点的大小表示平均骑行时长，颜色表示天气状况

(二)任务二：业务分析

(1)单车周转率：观测期 90 天共完成 9950 次骑行，涉及 9407 辆单车，观测期内单车周转率 1.06 次/辆、日均 0.0118 次/辆/天，其中 94.47%（8887 辆）的单车只被骑行 1 次，车辆使用极不均衡。按题目口径（日均使用时长 / 24 小时）计算，工作日日均使用时长 0.1929 小时、周转率 0.8036%（6806 辆车 / 64 天），周末日均使用时长 0.4666 小时、周转率 1.9442%（2840 辆车 / 26 天），周末周转率约为工作日的 2.4 倍
(2)区域供需分析：按（供给量 − 需求量）/ 需求量 × 100% 计算平衡指数，18 个区域中 17 个落

在 ±20% 的理想范围内；仅大兴区亦庄供给过剩（供给 590、需求 487、指数 +21.15%），石景山区鲁谷 +9.98%、门头沟区石门营 +8.86% 次之；负值最高的是顺义区新国展 −18.00%（供给 483、需求 589），说明该区域车辆长期紧张、需要主动调运

(3)高峰期分析：工作日早晚高峰（7-9 点、17-19 点）共产生 1775 次骑行，小时分布为 7 时 285 次、8 时 308 次、9 时 279 次、17 时 303 次、18 时 304 次、19 时 296 次，18 时与 8 时为最强小时。各区域高峰供需比介于 4.89～8.17，全部高于 2.0，判定为供给过剩，其中大兴区亦庄 8.17、丰台区方庄 6.97、海淀区五道口 6.70 最高，说明高峰时段的车辆投放密度远高于实际骑行需求，是调度优化的首要目标