样题4

模块一：平台搭建与运维

(一)任务一：大数据平台搭建

1.子任务一：基础环境准备

(1)`ifconfig`

`hostnamectl set-hostname master` 配置主机名

`systemctl restart network`

`vim /etc/hosts`

```
ip master
ip slave1
ip slave2
```

`cat /etc/hosts`

(2)`tar -zxvf /opt/software/jdk-8u191-linux-x64.tar.gz -C /opt/module`

(3)`vim /etc/profile`

```
export JAVA_HOME=/opt/module/jdk
export PATH=$PATH:$JAVA_HOME/bin
```

`source /etc/profile`

(4)`java -version`

(5)`useradd hadoop`

`passwd hadoop`

`visudo /etc/sudoers`

```
hadoop ALL=(ALL)    NOPASSWD=ALL
```

`grep 'hadoop' /etc/sudoers`

(6)`systemctl stop firewalld`

`systemctl disable firewalld`

`systemctl status firewalld`

(7)`ssh-keygen -t rsa`

`ssh-copy-id slave1`

`ssh slave1`

2.子任务二：Hadoop 完全分布式安装配置

(1)`tar -zxvf /opt/software/adoop- 3.3.6.tar.gz -C /opt/module`

(2)`mv /opt/module/Hadoop /opt/module/hadoop`

`chown -R hadoop:hadoop /opt/module/hadoop`

(3)`cd /opt/module/hadoop/etc/hadoop`

hadoop-env.sh

```shell
export JAVA_HOME=/opt/module/jdk
export HADOOP_HOME=/opt/module/hadoop
export HADOOP_CONF_DIR=${HADOOP_HOME}/etc/hadoop
export HADOOP_LOG_DIR=${HADOOP_HOME}/logs
```

core-site.xml

```xml
<property>
   <name>fs.defaultFS</name>
   <value>hdfs://master:9820</value>
</property>
<property>
   <name>hadoop.tmp.dir</name>
   <value>/opt/module/hadoop/tmp</value>
</property>
```

hdfs-site.xml

```xml
<property>
   <name>dfs.replication</name>
   <value>3</value>
</property>
<property>
   <name>dfs.namenode.secondary.http-address</name>
   <value>master:9896</value>
</property>
<property>
   <name>dfs.datanode.data.dir</name>
   <value>/opt/module/hadoop/datanode/data</value>
</property>
```

mapred-site.xml

XML

```xml
<property>
   <name>mapreduce.framework.name</name>
   <value>yarn</value>
</property>
<property>
   <name>mapreduce.jobhistory.address</name>
   <value>master:10020</value>
</property>
<property>
   <name>mapreduce.jobhistory.webapp.address</name>
   <value>master:19888</value>
</property>
```

yarn-site.xml

XML

```xml
<property>
   <name>yarn.resourcemanager.hostname</name>
   <value>master</value>
</property>
<property>
   <name>yarn.nodemanager.aux-services</name>
   <value>mapreduce_shuffle</value>
</property>
<property>
   <name>yarn.log-aggregation-enable</name>
   <value>true</value>
</property>
<property>
   <name>yarn.log.server.url</name>
   <value>http://master:19888/jobhistory/logs</value>
</property>
```

masters

```
master
slave1
slave2
```

workers

```
master
slave1
slave2
```

(4)`scp -r /opt/module/hadoop root@slave1:/opt/module/`
`scp -r /opt/module/hadoop root@slave2:/opt/module/`
(5)`chown -R hadoop:hadopp /opt/module/hadoop`
(6)`vim /etc/profile`

```
export HADOOP_HOME=/opt/module/hadoop
export PATH=$PATH:$HADOOP_HOME/bin
```

`source /etc/profile`
(7)`su - hadoop`
`hdfs namenode -format`
日志
(8)`start-dfs.sh`
`start-yarn.sh`
`mapred --daemon start historyserver`
`jps`
(9)`ssh slave1`
`jps`

(二)任务二：数据库服务器的安装与运维

1.子任务一：MySQL 安装配置

(1)`tar -xvf /opt/software/mysql-5.7.44-1.el7.x86_64.rpm-bundle.tar -C /opt/module`
(2)`rpm -ivh mysql-communitycommon mysql-community-libs mysql-community-libscompat mysql-community-client mysql-community-server`
(3)`systemctl start mysqld`
`systemctl enable mysqld`
`mysqld --initialize --user=mysql`

2.子任务二：MySQL 运维

(1)`vim /etc/my.cnf`

```
[mysqld]
max_connections = 1000
```

(2)`creat database toursim default character set utf8mb4 collate utf8mb4_unicode_ci;`
(3)备份脚本
`vim /../../toursim_backup.sh`

```shell
#!/bin/bash
user="root"
pass="密码"
database="tourism"
date=$(date +%Y%m%d_%H%M%S)
backup="/../.." # 备份存放目录
mkdir -p /../..
mysqldump -u"$user" -p"$pass" "tourism" > "${backup}/${database}_backup_$date.sql"
(crontab -l 2>/dev/null; echo"0 2 * * * /../..backup.sh") | crontab -
```

`chmod +x /../../toursim_backup.sh`
`(crontab -l 2 >/dev/null; echo "0 2 * * * /../../toursim_backup.sh") | crontab -l`

(4)`vim /etc/my.cnf`

```
slow_query_log=1 # 打开慢查询
long_query_time=3
```

(5)`vim /etc/my.cnf`

```
binlog_expire_logs_seconds = 604800
```

3.子任务三：数据表的创建及维护

(1)`use tourism;`

```
create table scenic_spot(
   spot_id int primary key auto_increment,
   spot_name varchar(n),
   city varchar(n),
   level varchar(n),
   type varchar(n),
   ticket_price decimal(n,n),
   opening_hours varchar(n),
   max_capacity int
);
```

(2)

```
create table visitor_flow(
   record_id int primary key auto_increment,
   spot_id int,
   visit_date date,
   visitor_count int,
   peak_hour time,
   weather varchar(n),
   is_holiday boolean,
   foreign key(spot_id) references scenic_spot(spot_id)
);
```

(3)查询2024年1月每个景区的总游客人数。查询结果需要显示景区名称、所在城市和游客总数，并按游客总数降序排列

```
select
   v.spot_id,
   s.city,
   sum(v.visitor_count) as 游客总数
from
   visitor_flow as v
join
   scenic_spot as s
on
   v.spot_id = s.spot_id
where
   year(v.visit_date) = 2024 and month(v.visit_date) = 1
order by
   游客总数 desc;
```

统计每个景区在节假日和非节假日的平均游客数量。查询结果需要显示景区名称、景区等级、节假日平均游客数和非节假日平均游客数，按景区编号排序

```
select
   s.spot_name,
   s.level,
   avg(case when v.is_holiday = true then v.visitor_count end) as 节假日平均游客数,
   avg(case when v.holiday = false then v.visitor_count end) as 非节假日平均游客数
from
   scenic_spot as s
join
   visitor_flow as v
on
   s.spot_id = v.spot_id
group by
   s.spot_id,
   s.spot_name,
   s.level
order by
   s.spot_id;
```

找出所有景区中单日游客量超过该景区最大承载量的情况。查询结果需要显示景区名称、参观日期、实际游客数量、最大承载量和超出人数， 按超出人数降序排列

```
select
   s.spot_name,
   v.visit_date,
   v.visitor_count,
   s.max_capacity,
   (v.visitor_count - s.max_capacity) as 超出人数
from
   scenic_spot as s
join
   visitor_flow as v
on
   s.spot_id = v.spot_id
where
   v.visitor_count > s.max_capacity
order by
   超出人数 dese;
```

模块二：数据获取与处理

(一)任务一：数据获取与清洗

1.子任务一：数据获取

```
import pandas as pd
date = pd.read_csv('tourist_data.csv',rnow=10)
print(date)
```

2.子任务二：使用 Python 进行数据清洗

(1)删除天气状况为空或为零的记录，并将结果存储为 `cleaned_data_c1_1438.csv`，N 为删除的数据条数
(2)删除停留时长异常（超过 24 小时或小于 0.1 小时）的记录，并将结果存储为 `cleaned_data_c2_155.csv`，N 为删除的数据条数
(3)将游客来源地为空的记录填充为「未知」，并将结果存储为 `cleaned_data_c3_284.csv`，N 为修改的数据条数
(4)将满意度评分超出范围（0-5 分）的记录删除，并将结果存储为 `cleaned_data_c4_607.csv`，N 为删除的数据条数
(5)将消费金额明显异常（超过该景区平均消费金额 5 倍）的记录删除，并将结果存储为 `cleaned_data_c5_54.csv`，N 为删除的数据条数

(二)任务二：数据标注

1.子任务一：游客价值分类标注

按消费金额与停留时长标注，结果存入 `tourist_value_mark.csv`（2746 行，列：编号、景区名称、消费金额（元）、停留时长（小时）、游客价值类型）。标注结果分布为：低价值游客 2097 条（76.37%）、高价值游客 331 条（12.06%）、中价值游客 318 条（11.58%），低价值游客占比近八成，是最需要通过二次营销与服务提升转化的群体。

2.子任务二：旅游旺季标注

按月游客量与平均消费标注，结果存入 `season_mark.csv`。全年月均游客量 228.83 人次、年平均消费 610.60 元，各月标注结果全部为平季：游客量占比最高的是 8 月（111.0%）、最低的是 10 月（93.5%），平均消费占比最高的是 12 月（115.5%）、最低的是 11 月（86.2%）；由于没有任何月份同时满足「游客量 > 120% 且平均消费 > 110%」或「游客量 < 80% 且平均消费 < 90%」，旺季与淡季的判定条件在本数据集上均不成立。

(三)任务三：数据统计

1.子任务一：HDFS 文件操作

(1)`hdfs dfs -mkdir/toursim_data`
(2)`hdfs dfs -chmod 777 /tourism_data`
(3)`hdfs dfs -put <本地路径> /tourism_data`

2.子任务二：使用 MapReduce 进行数据分析

(1)编写 MapReduce 程序，统计不同景区的每日平均游客数量：Map 阶段以景区名称为 key、输出该景区的日期与游客条数，Reduce 阶段对同一景区的记录累加总数并除以该景区的有记录天数
(2)将统计结果存储到 HDFS 的 `/tourism_analysis/daily_visitors` 目录下
(3)运行 MapReduce 程序并查看执行结果，结果前十行如下

```
丽江古城 1.49
桂林山水 1.49
西湖 1.47
九寨沟 1.46
张家界 1.45
长城 1.44
故宫 1.43
鼓浪屿 1.41
三亚 1.40
黄山 1.38
```

3.子任务三：使用 Hive 进行数据分析

(1)在 Hive 中创建外部表 `tourist_flow` 并加载 HDFS 中的旅游数据

SQL

```sql
create external table if not exists tourist_flow (
    景区名称 string,
    日期 string,
    游客来源地 string,
    游客年龄段 string,
    停留时长 double,
    消费金额 double,
    满意度评分 double,
    出行方式 string,
    天气状况 string
)
row format delimited fields terminated by ','
location '/tourism_data';
```

(2)编写 HQL 查询完成三项统计

统计每个景区的月度游客总量

```SQL
select
    景区名称,
    substr(日期, 1, 7) as 月份,
    count(*) as 游客总量
from
    tourist_flow
group by
    景区名称,
    substr(日期, 1, 7)
order by
    景区名称,
    月份;
```

计算不同游客来源地的平均消费金额

```SQL
select
    游客来源地,
    avg(消费金额) as 平均消费金额
from
    tourist_flow
group by
    游客来源地
order by
    平均消费金额 desc;
```

统计不同天气状况下的游客总量

```SQL
select
    天气状况,
    count(*) as 游客总量
from
    tourist_flow
group by
    天气状况
order by
    游客总量 desc;
```

(3)将查询结果导出到本地文件系统

```
hive -e "use tourism; select 景区名称, substr(日期,1,7) as 月份, count(*) as 游客总量
from tourist_flow group by 景区名称, substr(日期,1,7);" -h -r
/home/analysis/monthly_visitors.tsv
hive -e "use tourism; select 游客来源地, avg(消费金额) as 平均消费金额 from tourist_flow
group by 游客来源地 order by 平均消费金额 desc;" -h -r
/home/analysis/source_avg_spend.tsv
hive -e "use tourism; select 天气状况, count(*) as 游客总量 from tourist_flow group by
天气状况 order by 游客总量 desc;" -h -r /home/analysis/weather_visitors.tsv
```

三项统计结果：月度游客总量以 8 月（254 人次）、5 月（246 人次）为高点（长城 5 月 34 人次、张家界 4 月 33 人次、长城 12 月 32 人次、九寨沟 3 月 32 人次）；来源地平均消费前三位为青岛 695.35 元、大连 694.72 元、厦门 667.37 元；天气状况游客总量前三位为多云 581 人次、阴 558 人次、小雨 474 人次。

模块三：业务分析与可视化

(一)任务一：数据分析与可视化

1.子任务一：数据分析

(1)各景区的游客来源地分布：客源地非常分散，全库有 7 个「景区-客源地」组合的占比超过 20%，全部来自「未知」——鼓浪屿 28.8%、丽江古城 27.2%、三亚 24.6%、长城 24.1%、九寨沟 24.2%、黄山 23.1%、西湖 20.1%；其余景区（张家界 19.2%、桂林山水 19.1%、故宫 15.2%）的最高占比都在 20% 以下，杭州、上海、西安、广州、成都等客源地在各景区占比多在 8%～12% 之间，说明「未知」是本数据集最大的单一客源地，各景区的主要客源市场尚未形成聚集
(2)不同年龄段游客的平均消费与停留时长：55 岁以上组平均消费 628.82 元、平均停留 5.59 小时；36-45 岁组 617.71 元、6.00 小时；26-35 岁组 613.89 元、5.90 小时；18-25 岁组 603.03 元、5.97 小时；46-55 岁组 589.18 元、5.81 小时。55+ 组消费最高最具消费潜力，36-45 组停留时间最长
(3)周末与工作日的游客量差异：周末 743 人次 / 104 天，日均 7.14 人次；工作日 2003 人次 / 262 天，日均 7.65 人次；周末相对工作日的增长为 −6.55%，客流并未向周末集中
(4)不同出行方式的游客比例并按平均消费排序：骑行/徒步 588 人次、占比 21.41%、平均消费 593.14 元；飞机 558 人次、20.32%、635.93 元；自驾 548 人次、19.96%、644.51 元；大巴 541 人次、19.70%、582.61 元；高铁/火车 511 人次、18.61%、596.29 元。自驾消费能力最强，骑行/徒步人数占比最高但消费最低
(5)满意度评分与停留时长的关系：皮尔逊相关系数 `r = 0.0063`（n=2746），两者几乎完全无线性相关，满意度不受停留时长影响

2.子任务二：数据可视化

(1)玫瑰图展示各景区的游客量分布，扇形半径表示游客量，颜色深浅代表游客量级别（数据无「景区等级」字段，按各景区平均消费金额的三分位反推 5A/4A/3A 作为代理指标），添加图例说明和标题，支持鼠标悬停显示详细数据
(2)气泡图展示景区特征分布，横轴为平均消费金额，纵轴为日均游客量，气泡大小表示满意度评分，颜色表示景区等级，支持图例筛选和缩放交互
(3)堆叠面积图展示各主要客源地游客量在一年内的变化趋势，不同颜色代表不同来源地，显示月度数据点并支持区域高亮
(4)雷达图对比不同年龄段游客的消费特征，包含消费金额、停留时长、满意度评分、重游率、景点打卡数等维度（后两项数据中无对应字段，改用平均满意度与平均停留时长替代），并添加数据标签

(二)任务二：业务分析

1.基础指标分析

(1)客流指标分析：全年共接待游客 2746 人次，覆盖 366 天，日均客流量 7.50 人次/天；客流波动系数（标准差/平均值）为 0.3808，波动幅度偏大；节假日客流比因数据中没有节假日标记字段无法直接计算，改用周末与工作日的日均客流之比 7.14 / 7.65 = 0.93 作为近似参考。分景区看日均游客量，丽江古城与桂林山水最高 1.49 人次/天，黄山最低 1.38 人次/天，各景区客流分布相当均衡
(2)消费行为分析：人均消费 610.60 元（总消费 1676706.00 元 / 2746 人），平均停留 5.85 小时。按年龄段分组，55+ 组 628.82 元最高、46-55 组 589.18 元最低；按来源地分组，青岛 695.35 元、大连 694.72 元、厦门 667.37 元位居前三
(3)游客体验评估：满意度评分为 5 分制，2746 条记录全部在有效范围内（0.0～5.0），加权平均值 2.54 分，得分率 50.88%，游客体验整体偏低；分景区看长城最高 2.66 分、故宫最低 2.40 分

2.运营建议

(1)差异化票价策略：客流波动系数 0.3808 说明各日客流起伏明显，建议按淡旺季与工作日/周末分档定价——周末与工作日客流基本持平（7.14 vs 7.65 人次）说明提价空间有限，但对春节、五一、十一等法定节假日应实施分时段动态上浮，工作日推出淡季折扣门票以平衡峰谷
(2)服务优化方案：满意度加权平均仅 2.54 分（得分率 50.88%），且满意度与停留时长几乎不相关（r = 0.0063），说明现有的服务体验与游客停留行为脱节，应从排队时长、导览讲解、卫生与设施维护等具体环节入手整改，而不是指望延长停留时间带动满意度，并建立月度满意度回访机制
(3)精准营销建议：高价值游客占 12.06%，55+ 组消费最高（628.82 元），自驾出行消费能力最强（644.51 元），据此对 55+ 客群与自驾人群设计深度游、康养主题与房车营地组合产品；

针对占比 76.37% 的低价值游客推出文创、餐饮与二次讲解等增值服务，把人均消费从 610.60 元提升到景区平均消费水平以上