样题2

项目一：平台搭建与运维

(一)任务一：大数据平台搭建

1.子任务一：基础环境准备

(1)`hostnamectl set-hostname master`
`vim /etc/hosts`

```
ip master
ip node01
ip node02
```

`ping -c 4 node01`
(2)`tar -zxvf /opt/software/jdk-8u391-linux-x64.tar.gz -C /opt/module`
`ll /opt/module`
(3)`vim /etc/profile`

```
exprot JAVA_HOME=/opt/module/jdk
export PATH=$PATH:$JAVA_HOME/bin
```

`source /etc/profile`
(4)`systemctl stop firewalld`
`systemctl disable firewalld`
`systemctl status firewalld`
(5)`ssh-keygen -t rsa`
`ssh-copy-id root@node1`
`ssh-copy-id root@node2`
`sudo systemctl restart sshd`
`ssh node1(node2)`
(6)`scp -r /opt/module/jdk root@node1:/opt/module`
`vim /etc/profile`

```
exprot JAVA_HOME=/opt/module/jdk
export PATH=$PATH:$JAVA_HOME/bin
```

`source /etc/profile`
(7)`java -version`
(8)`useradd hadoop`

`passwd hadoop`
`visudo /etc/sudoers`

```
hadoop ALL=(ALL)    NOPASSWD:ALL
```

`grep 'hadoop' /etc/sudoers`

2.子任务二：Hadoop 完全分布式安装配置

(1)`tar -zxvf /opt/software/hadoop-3.1.3.tar.gz -C /opt/module`
(2)`mv /opt/module/hadoop-3.1.3 /opt/module/hadoop`
`chown -R haddop:hadoop /opt/module/hadoop`
(3)`su - hadoop`
hadoop-env.sh

```shell
export JAVA_HOME=/opt/module/jdk
export HADOOP_HOME=/opt/module/hadoop
export HADOOP_CONF_DIR=${HADOOP_HOME}/etc/hadoop
export HADOOP_LOG_DIR=${HADOOP_HOME}/logs
```

core-site.xml

```xml
<property>
    <name>fs.defaultFS</name>
    <value>hdfs://master:9820</value>
</property>
<property>
    <name>hadoop.tmp.dir</name>
    <value>/opt/module/hadoop/tmp</value>
</property>
```

hdfs-site.xml

```xml
<property>
   <name>dfs.replication</name>
   <value>3</value>
</property>
<property>
   <name>dfs.namenode.secondary.http-address</name>
   <value>node01:9868</value>
</property>
<property>
   <name>dfs.datanode.data.dir</name>
   <value>/opt/module/hadoop/datanode/data</value>
</property>
```

mapred-site.xml

```xml
<property>
   <name>mapreduce.framework.name</name>
   <value>yarn</value>
</property>
<property>
   <name>mapreduce.jobhistory.address</name>
   <value>node01:10020</value>
</property>
<property>
    <name>mapreduce.jobhistory.webapp.address</name>
    <value>node01:19888</value>
</property>
```

yarn-site.xml

```xml
<property>
   <name>yarn.resourcemanager.hostname</name>
   <value>master</value>
</property>
<property>
   <name>yarn.nodemanager.aux-services</name>
   <value>mapreduce_shuffle</value>
</property>
<property>
    <name>yarn.log-aggregation-enable</name>
    <value>true</value>
</property>
<property>
    <name>yarn.log.server.url</name>
    <value>http://node01:19888/jobhistory/logs</value>
</property>
```

work

```
master
node1
node2
```

(4)`vim /etc/profile`

```
export HADOOP_HOME=/opt/module/hadoop
export PATH=$PATH:$HADOOP_HOME/bin
```

(5)`scp -r /opt/module/hadoop root@node1:/opt/module`
`chown -R hadoop:hadoop /opt/module/hadoop`
(6)`hdfs namenode -format`
(7)`start-dfs.sh`
`start-yarn.sh`
`mapred --daemon start historyserver`
`jps`
(8)`ssh node1`
`jps`

(二)任务二：数据库服务器的安装与运维

1.子任务一：MySQL 安装配置

(1)`tar -zxvf /opt/software/mysql-5.7.25-1.el7.x86_64.rpm-bundle.tar -C /opt/module`

(2)`rpm -qa | grep mariadb`
`rpm -e -nodeps mariadb...`
`rpm -ivh mysql-communitycommon mysql-community-libs mysql-community-libs-compat mysql-community-client mysql-community-server`

(3)`rpm -qa | grep mysql`

(4)`systemctl start mysqld`
`mysqld --initialize --user=mysql`

2.子任务二：MySQL 运维

(1)`vim /etc/my.cnf` 打开配置文件 在[mysqld]部分添加以下内容

```
bind-address = 0.0.0.0
```

(2)`mysql -u root -p`
`use mysql;`
`update user set host='%' where user='root';`

(3)`show databases;`

(4)`create user 'hadoop'@'%' identified by 'qwER12#$'`
`grant select,insert,delete on *.* to 'hadoop'@'%'`
`flush privileges`

3.子任务三：数据表的创建及维护

(1)`create database education`
`use education`

```
create table course(
   course_id int primary key,
   title varchar(255),
   subject varchar(100),
   difficulty char(10) enum("初级","中级","高级"),
   total_lessons int,
   original_price decimal(10,2),
   current_price decimal(10,2),
   teacher_name varchar(100),
   publish_date date,
   total_students int,
   avg_review_score float check (avg_review_score >= 0.0 and avg_review_score <= 5.0)
)
```

(2)

```
create table study_behavior(
   record_id bigint primary key,
   user_id int,
   course_id int,
   access_date date,
   daily_study_minutes int,
   finished_lessons int,
   assignment_score float
   is_joined_discussion tinyint,
   note_count int,
   foreign key(course_id) references course(course_id)
)
```

(3)
查询各难度级别课程的平均好评率与平均学习人数

```
select
   c.course_id,
   c.avg_review_score,
   avg(c.total_students) as 平均学习人数,
   c.diffculty
from
   course as c
group by
   c.diffculty
```

统计每位主讲教师名下所有课程的总学习人次（需关联学习行为表）

```
select
   c.teacher_name,
   count(s.record_id) as 总学习人次
from
   course as c
join
   study_behavior as s
on
   c.course_id = s.course_id
group by
   c.teacher_name;
```

找出“编程”学科中，当日学习时长超过 60 分钟且完成了作业（作业得分大于 0）的所有学习记录

```
select
   s.*
from
   course as c
join
   study_behavior as s
on
   c.course_id = s.course_id
where
   c.subject = '编程' and s.daily_study_minutes > 60 and s.assignment_score > 0;
```

项目二：数据获取与处理

(一)任务一：数据获取与清洗

1.子任务一：数据获取

有一份在线教育平台的用户学习行为数据集，包含学员 ID、课程 ID、课程名称、课程类别、内容形式、学习时长(分钟)、章节完成率、测试得分、提问次数、登录设备、学习时间段、最近学习日期等信息，数据已存入到 `user_study_log.csv` 文件中，请使用 pandas 读取该文件，并将数据集的前 8 行打印输出

```
import pandas as pd
data = pd.read_csv('user_study_log.csv',nrows=8)
print(data)
```

2.子任务二：使用 Python 进行数据清洗

(1)删除「学习时长(分钟)」为空或小于等于 5 分钟的记录，存储为 `cleaned_step1_62.csv`（N=62）
(2)将「测试得分」中小于 0 分的记录修正为 0 分、大于 100 分的记录修正为 100 分，存储为 `cleaned_step2_35.csv`（N=35）
(3)将「最近学习日期」列统一转换为 YYYY-MM-DD 格式，存储为 `cleaned_step3_1350.csv`（N=1350）
(4)删除「章节完成率」大于 100% 或小于 0% 的异常记录，存储为 `cleaned_step4_43.csv`（N=43）
(5)基于「学员 ID」「课程 ID」和「最近学习日期」三列判断并删除完全重复的记录，存储为 `cleaned_step5_55.csv`（N=55）

(二)任务二：数据标注

1.子任务一：学习投入度标注

根据「学习时长(分钟)」与「提问次数」对单次学习会话分级：学习时长 > 45 分钟且提问次数 ≥ 3 记为「高度活跃」，学习时长在 15-45 分钟（含）或提问次数为 1-2 记为「一般活跃」，学习时长 < 15 分钟且提问次数为 0 记为「不活跃」，结果存入 `activity_label.csv`（1900 行，在原数据集 12 列基础上新增「活跃度等级」列）。标注结果分布为：高度活跃 956 条（50.32%）、一般活跃 933 条（49.11%）、不活跃 11 条（0.58%），平台整体学习投入度较高。

```
学员ID 课程ID 课程名称 课程类别 内容形式 学习时长(分钟) 章节完成率 测试得分 提问次数 登录设备 学习时间段 最近学习日期 活跃度等级
U00040 C022 项目管理PMP 语言学习 互动课 17.0 0.73 51 2 桌面电脑 8 2026-09-22 一般活跃
U00385 C019 商务英语写作 职场技能 互动课 109.0 0.46 21 1 桌面电脑 3 2026-08-20 一般活跃
U00557 C004 UI/UX设计原理 设计创意 视频 29.0 0.94 55 6 桌面电脑 5 2026-10-05 一般活跃
```

2.子任务二：学习模式标注

为每位用户统计最常使用的设备和最主要的学习时间段，据此标注偏好类型：学习时间段集中在 06:00-09:00 且主要使用「手机」或「平板」记为「晨间移动型」，集中在 09:00-18:00 且主要使用「台式机」或「笔记本电脑」记为「日间桌面型」，集中在 22:00-次日 02:00 且平均单次学习时长 ≥ 60 分钟记为「深夜沉浸型」，未明显集中于上述时段且使用过至少两种设备记为「跨设备灵活型」，结果存入 `preference_analysis.csv`（563 行，列：学员ID、最常使用设备、最主要学习时间段、平均单次学习时长、偏好类型）。标注结果分布为：日间桌面型 239 人（42.45%）、跨设备灵活型 137 人（24.33%）、深夜沉浸型 129 人（22.91%）、晨间移动型 58 人（10.31%），白天桌面学习是平台的主流学习模式。

```
学员ID 最常使用设备 最主要学习时间段 平均单次学习时长 偏好类型
U00001 网页端 10 118.33 跨设备灵活型
U00002 网页端 20 94.17 跨设备灵活型
U00003 智能手机 11 104.75 深夜沉浸型
```

(三)任务三：数据统计

1.子任务一：HDFS 文件操作

(1)`hdfs dfs -mkdir /bigdata_edu/input` 在 HDFS 上创建目录 /bigdata_edu/input
(2)`hdfs dfs -put cleaned_step5_55.csv /bigdata_edu/input` 将本地清洗后的最终数据文件上传至该 HDFS 目录
(3)`hdfs dfs -ls -h /bigdata_edu/input` 检查该文件在 HDFS 中的存储状态并确认其文件大小

2.子任务二：计算输入文件中的单词数

(1)`hdfs dfs -mkdir -p /bigdata_edu/reviews` 将课程评价文本数据 course_reviews.txt 所在目录创建出来
(2)`hdfs dfs -put course_reviews.txt /bigdata_edu/reviews` 将文本文件上传至 HDFS 的 /bigdata_edu/reviews 目录
(3)`hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar wordcount /bigdata_edu/reviews/course_reviews.txt /bigdata_edu/review_wordcount` 调用 Hadoop 官方示例 jar 包中的词频统计程序，对评论文本进行统计
(4)`hdfs dfs -cat /bigdata_edu/review_wordcount/part-r-00000 | head -n 10` 将词频统计结果中按词频降序排列的前 10 个单词及其频次截图

3.子任务三：学习行为分析

(1)Map 阶段：以用户 ID 为键，输出该用户有学习记录的日期
(2)Reduce 阶段：对同一用户 ID 下的所有日期进行去重，并统计该月去重后的日期数量，即为月度活跃天数
(3)输出格式为「用户 ID,月度活跃天数」，并将结果存储到 HDFS 的 `/bigdata_edu/monthly_active_days` 目录下
(4)程序运行后，结果文件的前 10 行内容如下

```
用户ID 月度活跃天数
U00289 5
U00305 5
U00106 5
U00516 5
U00130 5
U00144 5
U00455 5
U00364 5
U00511 5
U00349 5
```

统计结果共覆盖 1119 个 (用户, 月份) 组合，最大月度活跃天数为 5 天。

项目三：业务分析与可视化

(一)任务一：数据分析与可视化

1.子任务一：数据分析

(1)各课程类别的平均最终通过率并筛选出高于平台整体平均通过率 0.4956 的类别，按通过率从高到低排序：设计创意 0.525629、语言学习 0.506676、数据科学 0.499954，编程开发 0.475661 与职场技能 0.472842 低于整体水平
(2)四个学习区间的独立用户数：深夜(22:00-4:59) 353 人、午间(11:00-16:59) 329 人、清晨(5:00-10:59) 320 人、傍晚(17:00-21:59) 284 人，最活跃的学习区间是深夜
(3)不同内容形式的平均用户满意度评分：直播 57.558887、图文 56.942268、互动课 55.176842、视频 54.993658，最受欢迎的内容形式是直播
(4)各类登录设备的平均单次访问时长与平均页面访问深度：智能手机 94.085470 分钟、深度 0.493932（468 条）；平板电脑 93.941292 分钟、深度 0.497867（511 条）；网页端 93.882743 分钟、深度 0.497611（452 条）；桌面电脑 91.364606 分钟、深度 0.492751（469 条），四类设备的访问深度差异极小，单次访问时长以桌面电脑最低
(5)以最近 30 天（2026-09-14 ~ 2026-10-13）为窗口统计高留存用户，窗口内活跃用户 459 人，其中累计学习天数 ≥ 10 天的高留存用户数为 0，按题目口径无达标课程；放宽到累计学习天数 ≥ 3 天后，各门课程的高留存用户占比前三名为 Python零基础入门 0.391304、Java企业级开发 0.384000、商务英语写作 0.353333

2.子任务二：数据可视化

(1)绘制双轴组合图，主 Y 轴（柱状图）为各课程的平均学习时长，次 Y 轴（折线图，带标记点）为对应课程的近一年更新次数，X 轴为按学科领域分组的课程列表，图中包含清晰的标题、双轴标签、图例及必要的数值标注
(2)绘制热力图，呈现用户学习时段（按小时划分）与常用设备类型之间的共现关系，X 轴为一天

中的 24 个小时，Y 轴为主要的设备类型，单元格颜色深浅代表在该时段使用该设备的学习人次占比，图中包含色标、标题及坐标轴标签

(二)任务二：业务分析

(1)用户活跃规律：用户最活跃的时段是深夜（22:00-4:59），该区间发起学习会话的独立用户数达 353 人，高于午间的 329 人、清晨的 320 人和傍晚的 284 人；按单小时看 15 点是全天最活跃的时段，学习人次达 100；设备方面最偏好平板电脑（511 人次，占 26.9%），最典型的设备与时段组合是「平板电脑 + 下午 1 点」，共 31 人次，说明用户在白天与午休时段倾向于用平板进行碎片化学习，而深夜则是全天活跃度最高的时段
(2)课程内容表现：直播类内容的平均满意度最高（57.56 分），图文、互动课、视频分别为 56.94、55.18、54.99 分；但从完成率看图文的平均章节完成率最高（0.5126），直播的完成率反而最低（0.4807），说明直播凭借即时互动拉高了满意度，却没有带动课程完成；课程类别方面设计创意 0.5256、语言学习 0.5067、数据科学 0.5000 三类通过率高于整体 0.4956，其中设计创意不仅平均完成率最高（0.5256），平均得分也最高（57.28 分），是最受欢迎的学科方向
(3)潜在风险与机会：编程开发（0.4757）与职场技能（0.4729）两类课程的平均完成率低于平台整体水平 0.4956，是参与度下降最明显的类别，存在流失风险；渠道方面桌面电脑的平均学习时长仅 91.36 分钟，明显低于智能手机的 94.09 分钟、平板电脑的 93.94 分钟与网页端的 93.88 分钟，说明 PC 端的内容加载与交互体验是当前最需要优化的渠道；同时高留存用户为 0 也表明平台整体缺乏持续学习习惯，短期热度高但长期留存薄弱

基于核心发现，提出以下数据驱动的优化建议
(1)内容与运营策略：把设计创意类课程的章节切分与互动节奏沉淀为可复制模板，向完成率偏低的编程开发、职场技能等类别推广复用；图文形式 0.5126 的完成率最高，应继续作为图文类知识点的承载主力，同时用直播的即时答疑补足直播 0.4807 的完成率短板
(2)功能与体验优化：结合 15 点与深夜两个活跃高峰，把学习提醒与内容推送集中在 15 点前后，并为深夜时段配置夜间模式与护眼字号；针对桌面电脑端平均学习时长偏低（91.36 分钟）的问题优化 PC 端界面与内容加载速度
(3)资源分配建议：课程更新优先投向职场技能等完成率靠后的类别，技术开发优先投入平板电脑端与桌面电脑端，市场推广集中投放在 15 点前后的活跃高峰时段，以最小成本提升整体参与度与留存

项目四：AI 大模型应用开发综合实践

(一)任务一：AI 大模型服务综合部署

1.子任务一：基本配置

本任务需要使用 root 用户完成相关配置，已提供操作系统镜像及需要配置的前置环境，所需软件安装包均在 /root/ 目录下
(1)`mkdir -p /media/cdrom` 在 AI-SRV 中将操作系统镜像挂载至 /media/cdrom，并实现开机自启
情况一：镜像文件在 `/root/` 目录下

```
mount -o loop /root/openEuler-22.03-LTS-SP4-x86_64-dvd.iso /media/cdrom
```

情况二：镜像已通过虚拟光驱加载到设备 `/dev/sr0`

```
mount /dev/sr0 /media/cdrom
```

编辑 `vim /etc/fstab`

```
末尾添加
/dev/sr0    /media/cdrom    iso9660    defaults,ro    0    0
```

注意：
`/dev/sr0` 光驱设备名（用 `lsblk` 确认）
`/media/cdrom` 挂载点
`iso9660` 光盘文件系统类型
`defaults,ro` 表示默认选项且只读（推荐加 `ro` 以避免警告）
`0 0` 表示不备份、不检查
`mount -a` 验证
如果没有报错，说明配置成功
(2)`vim /etc/yum.repos.d/local.repo` 在 AI-SRV 中完成软件源配置文件的编写，禁用 GPG 校验，并为源数据建立缓存

```
[local]
name=Local Repository
baseurl=file:///media/cdrom
enabled=1
gpgcheck=0
```

`yum makecache` 建立缓存

```
(可能需要删除所有默认远程源)
cd /etc/yum.repos.d/
ls 查看是否有默认远程源
rm -f /etc/yum.repos.d/openEuler.repo 删除除了local.repo以外的
```

验证是否仅使用本地源

2.子任务二：环境搭建

本任务需要使用 root 用户完成相关配置，已提供 ollama 安装包及需要配置的前置环境
(1)`groupadd ollama` 为 ollama 配置用户/组，该用户仅用于运行服务，禁止其登录系统
`useradd -r -g ollama -d /usr/share/ollama -s /sbin/nologin ollama`
(2)`usermod -aG ollama root` 为 root 用户加入附加组 ollama
(3)`tar -zxvf /root/ollama-linux-amd64.tgz -C /usr` 将 ollama-linux-amd64.tgz 解压安装至 /usr 目录下
`mv /usr/bin/ollama /usr/bin/ollama_bak`（若提示目标已存在，先备份原程序）
`mv /usr/lib/ollama /usr/lib/ollama_bak`
`mv /usr/share/ollama /usr/share/ollama_bak`
(4)编写 SystemD 服务配置 `vim /etc/systemd/system/ollama.service`，使用服务运行专用用户完成启动，无论发生任何意外情况，服务都会进行自动重启（冷却 3 秒），以保证服务可靠运行，服务需要监听所有地址

```
[Unit]
Description=Ollama Service
After=network-online.target

[Service]
ExecStart=/usr/bin/ollama serve
User=ollama
Group=ollama
Restart=always
RestartSec=3
Environment="OLLAMA_HOST=0.0.0.0:11434"

[Install]
WantedBy=multi-user.target
```

`systemctl daemon-reload` 重载服务配置
(5)`systemctl enable ollama` 启动 ollama 服务并完成开机启动配置
`systemctl start ollama`
`systemctl status ollama` 查看服务状态，确认端口监听正常
(6)`ollama create qwen2.5:1.5b -f 1.5b.tgz` 导入 1.5b.tgz 压缩文件模型至 ollama
`ollama list` 查看已导入的模型列表

(二)任务二：AI 大模型综合应用开发

1.子任务一：Dify 运行环境搭建

本任务需要使用 root 用户完成相关配置，已提供安装 dify 及需要配置的前置环境
(1)`yum install -y docker` 在 AI-SRV 中完成 Docker 环境的安装
`systemctl start docker`

`systemctl enable docker`
`docker --version` 查看 Docker 版本信息
(2)`tar -zxvf /root/dify-0.14.2.tar.gz -C /opt` 将 dify-0.14.2.tar.gz 解压至 /opt 路径中
`cd /opt/dify/docker` 进入 dify 的 docker 目录
(3)`docker load -i /opt/dify/docker/dify-images/*.tar` 完成 dify 镜像的导入，相关文件位于 dify-images 目录中
`docker images` 检查镜像列表
(4)`docker compose up -d` 完成 dify 的启动，并在客户机中访问 AI-SRV 中的 dify web 服务
`docker ps` 查看容器运行状态
(5)在客户机中访问 dify，完成用户注册，邮箱为 admin@dify.ai，用户名为 admin，密码为 Qwer1234，注册后登录 dify 管理页面
(6)在客户机中访问 dify，完成对 ollama 模型提供商的注册，API 地址填 `http://<AI-SRV 的 IP>:11434`，模型名称选已导入的 qwen2.5:1.5b

2.子任务二：教育数据分析助手构建

(1)根据教育数据分析场景需要，创建空白应用 "Edu Data Assistant"
(2)为用户提供教育数据查询功能，其中参数包含 Query（查询内容），支持以下类型的查询
学生查询
学生成绩查询（如："张明最近的考试成绩"）
学习进度查询（如："李华完成了多少课程"）
出勤情况查询（如："王磊这个月的出勤记录"）
课程查询
课程信息查询（如："Python 基础课有多少学生"）
课程难度分析（如："哪些课程学生挂科最多"）
教师授课查询（如："张老师教哪些课"）
统计查询
班级排名查询（如："三班学生的平均分"）
成绩分布查询（如："数学考试的成绩分布"）
学习时间统计（如："学生平均每天学多久"）
(3)为确保结果准确性，需要从以下多个维度提供数据支持
从 MySQL 的 education 数据库读取数据
从本地 CSV 文件（user_study_log.csv）读取数据
使用 Ollama 本地模型分析数据
(4)配置提示词要求
系统角色设定为"教育数据分析助手"
支持 SQL 查询语句的自动生成和解释
支持自然语言到数据分析需求的转换
输出结果需包含数据来源说明
(5)运行应用，测试以下查询场景
简单统计查询："查询编程课程的平均分"，检查能否正确查询 course 表

学生信息查询："学生李四的学习记录"，检查能否连接 study_behavior 表
成绩分析查询："哪些学生数学不及格"，检查能否筛选数据
时间统计查询："上周的学习时长统计"，检查能否按时间查询
多表关联查询："张老师教的学生成绩"，检查能否关联 course 和 study_behavior 表