样题3

项目一：平台搭建与运维

(一)任务一：大数据平台搭建

1.子任务一：基础环境准备

(1)`hostnamectl set-hostname master`
`vim /etc/hosts`

```
ip master
ip slave1
ip slave2
```

`cat /etc/hosts`
(2)`tar -zxvf /opt/software/jdk-8u391-linux-x64.tar.gz -C /opt/module`
(3)`vim /etc/profile`

```
export JAVA_HOME=/opt/module/jdk
export PATH=$PATH:$JAVA_HOME/bin
```

`source /etc/profile`
(4)`java -version`
(5)`useradd hadoop`
`passwd hadoop`
`visudo /etc/sudoers`

```
hadoop ALL=(ALL)    NOPASSWD:ALL
```

`grep 'hadoop' /etc/sudoers`
(6)`systemctl stop firewalld`
`systemctl disable firewalld`
`systemctl status firewalld`
(7)`ssh-keygen -t rsa`
`ssh-copy-id root@slave1(slave2)`
`sudo systemctl restart sshd`
`ssh slave1(slave2)`

2.子任务二：Hadoop 完全分布式安装配置

(1)`tar -zxvf /opt/software/hadoop-3.1.3.tar.gz -C /opt/module`

(2)`mv /opt/module/hadoop-3.1.3 /opt/module/hadoop`

`chown -R hadoop:hadoop /opt/module/hadoop`

(3)

hadoop-env.sh

```shell
export JAVA_HOME=/opt/module/jdk
export HADOOP_HOME=/opt/module/hadoop
export HADOOP_CONF_DIR=${HADOOP_HOME}/etc/hadoop
export HADOOP_LOG_DIR=${HADOOP_HOME}/logs
```

core-site.xml

```xml
<property>
    <name>fs.defaultFS</name>
    <value>hdfs://master:9820 </value>
</property>
<property>
    <name>hadoop.tmp.dir</name>
    <value>/opt/module/hadoop/tmp</value>
</property>
```

hdfs-site.xml

```xml
<property>
    <name>dfs.replication</name>
    <value>3</value>
</property>
<property>
    <name>dfs.namenode.secondary.http-address</name>
    <value>master:9868</value>
</property>
<property>
    <name>dfs.datanode.data.dir</name>
    <value>/opt/module/hadoop/data</value>
</property>
```

mapred-site.xml

```xml
<property>
   <name>mapreduce.framework.name</name>
   <value>yarn</value>
</property>
<property>
   <name>mapreduce.jobhistory.address</name>
   <value>master:10020</value>
</property>
```

yarn-site.xml

```xml
<property>
   <name>yarn.resourcemanager.hostname</name>
   <value>master</value>
</property>
<property>
   <name>yarn.nodemanager.aux-services</name>
   <value>mapreduce_shuffle</value>
</property>
```

workers

```
master
slave1
slave2
```

(二)任务二：数据库服务器的安装与运维

1.子任务一：MySQL 安装配置

(1)`tar -zxvf /opt/software/mysql-5.7.25-1.el7.x86_64.rpm-bundle.tar -C /opt/module`

(2)`rpm -ivh mysql-community-common mysql-community-libs mysql-community-libs-compat mysql-community-client mysql-community-server`

(3)`systemctl start mysqld`

`mysqld --initialize --user=mysql`

2.子任务二：MySQL 运维

(1)`vim /etc/my.cnf` 在 [mysqld] 部分添加以下内容，配置服务端远程连接

```
bind-address = 0.0.0.0
```

(2)`mysql -u root -p` 登录后配置 root 用户允许任意 IP 连接

`use mysql;`

`update user set host='%' where user='root';`

`flush privileges;`

(3)`show tables;` 查看 mysql 库下的所有表

(4)创建 hadoop 用户，设置密码为 qwER12#$，并允许任意 IP 连接

```
create user 'hadoop'@'%' identified by 'qwER12#$';
```

(5)授予 hadoop 用户拥有对所有数据库的插入数据、查询数据、删除数据权限

```
grant insert,select,delete on *.* to 'hadoop'@'%';
```

(6)在 MySQL 中创建名为 hddb 的数据库，指定 utf8mb4 字符集和 utf8mb4_unicode_ci 排序规则

```
create database hddb default character set utf8mb4 collate utf8mb4_unicode_ci;
```

(7)创建名为 hdadmin 的新用户，并授予其对 hddb 数据库的全部权限

```
create user 'hdadmin'@'%' identified by '密码';
grant all privileges on hddb.* to 'hdadmin'@'%';
```

(8)刷新权限并查看 hdadmin 用户的权限信息

```
flush privileges;
show grants for 'hdadmin'@'%';
```

(9)查看 MySQL 数据库的全局默认字符集

```
show variables like 'character_set_server';
```

3.子任务三：数据表的创建及维护

(1)在 hddb 数据库中创建天气表 new_weather

```
use hddb;
create table new_weather(
   id int primary key auto_increment,
   province_id int not null,
   city_name varchar(255) not null,
   zip_code int,
   levels int,
   climate varchar(255)
);
```

(2)向天气表插入三亚、上海、乌鲁木齐三条记录，并查看天气表的全部记录

```
insert into new_weather(province_id,city_name,zip_code,levels,climate) values
(1016,'三亚',572000,2,'热带海洋性季风气候');
insert into new_weather(province_id,city_name,zip_code,levels,climate) values
(1026,'上海',200000,1,'亚热带季风气候');
insert into new_weather(province_id,city_name,zip_code,levels,climate) values
(1032,'乌鲁木齐',830000,2,'中温带半干旱大陆性气候');
select * from new_weather;
```

(3)为天气表添加气候介绍字段 comment，并查询天气表的结构

```
alter table new_weather add column comment varchar(255);
desc new_weather;
```

(4)将 /opt/software/mysql 路径下的 city_info.sql、province_info.sql、weather.sql 导入 hddb 数据库

```SHELL
mysql -u root -p hddb < /opt/software/mysql/city_info.sql
mysql -u root -p hddb < /opt/software/mysql/province_info.sql
mysql -u root -p hddb < /opt/software/mysql/weather.sql
```

(5)对导入的三份数据执行以下四条查询
查询最高气温超过 30 且天气为多云的所有记录

```
select * from weather where max_temp > 30 and weather_condition = '多云';
```

统计城市阿克苏最高气温超过 17 度的记录，并按照最高气温降序排列

```
select * from weather where city_name = '阿克苏' and max_temp > 17 order by max_temp
desc;
```

统计每个城市当日天气状况为多云的天数，并按照天数降序排列

```
select city_name,count(*) as 多云天数 from weather where weather_condition = '多云'
group by city_name order by 多云天数 desc;
```

查询属于亚热带季风气候、最高气温大于 30 度且风力大于 2 级的城市名称和最高气温

```
select city_name,max_temp from weather where climate = '亚热带季风气候' and max_temp >
30 and wind_level > 2;
```

项目二：数据获取与处理

(一)任务一：数据获取与清洗

1.子任务一：数据获取

使用 pandas 读取气象观测数据集 `weather_observations.csv` 并打印前 10 行

```
import pandas as pd
data = pd.read_csv('weather_observations.csv',nrows=10)
print(data)
```

2.子任务二：使用 Python 进行数据清洗

(1)删除「降水量」为空值且「天气现象」不为「雨」或「雪」的无效记录，存储为 `cleaned_weather_c1_8.csv`（N=8）
(2)识别并删除物理上不可能的异常记录（气温低于 -50°C 或高于 50°C，气压低于 800hPa 或高于 1100hPa），存储为 `cleaned_weather_c2_9.csv`（N=9）
(3)将「观测日期」和「观测时间」两列合并为标准的 YYYY-MM-DD HH:MM:SS 格式的「观测时间戳」列并删除原两列，存储为 `cleaned_weather_c3_183.csv`（N=183，为处理后数据总行数）
(4)删除所有字段完全相同的重复观测记录，存储为 `cleaned_weather_c5_7.csv`（N=7）

(二)任务二：数据标注

1.子任务一：气温等级标注

按「观测日期」和「观测站ID」分组计算日最高气温，再按寒冷（< 10°C）、凉爽（10°C ≤ T < 20°C）、舒适（20°C ≤ T < 28°C）、炎热（≥ 28°C）四类进行标注，结果存入 `temperature_level.csv`（171 行，列：观测日期、观测站ID、日最高气温、气温等级）。标注结果分布为：凉爽 61 条（35.67%）、舒适 49 条（28.65%）、炎热 44 条（25.73%）、寒冷 17 条（9.94%），夏季偏热的气温等级占了一半以上。

```
观测日期 观测站ID 日最高气温 气温等级
2025-01-01 STATION_005 10.9 凉爽
2025-01-05 STATION_001 16.3 凉爽
2025-01-08 STATION_002 13.0 凉爽
```

2.子任务二：降水强度标注

基于「天气现象」和「降水量」字段进行标注：小雨/小雪（天气现象为雨或雪且降水量 < 10mm）、中雨/中雪（10mm ≤ 降水量 < 25mm）、大雨/大雪（≥ 25mm）、非降水（晴、多云、阴等），结果存入 `precipitation_intensity.csv`（176 行，列：记录ID、观测时间、天气现象、降水量(mm)、降水强度）。标注结果分布为：非降水 119 条（67.61%）、小雪 27 条（15.34%）、小雨 23 条（13.07%）、中雪 5 条（2.84%）、中雨 2 条（1.14%），本数据集未出现大雨/大雪量级。

```
记录ID 观测时间 天气现象 降水量(mm) 降水强度
1 2025-01-13 23:30:00 多云 4.6 非降水
2 2025-08-05 01:00:00 多云 10.1 非降水
3 2025-08-03 07:45:00 晴 1.0 非降水
```

(三)任务三：数据统计

1.子任务一：HDFS 文件操作

(1)`hdfs dfs -mkdir /weather_data/input` 在 HDFS 根目录下新建目录

(2)`hdfs dfs -chmod 755 /weather_data/input` 修改该目录权限，赋予其 755 权限

(3)`hdfs dfs -put cleaned_weather_c5_7.csv /weather_data/input` 将本地清洗后的最终数据文件上传至该目录

(4)`hdfs dfs -ls -h /weather_data/input` 检查文件在 HDFS 中的存储状态并确认文件大小

2.子任务二：计算输入文件中的单词数

(1)`hdfs dfs -mkdir -p /weather_data/keywords`
(2)`hdfs dfs -put weather_keywords.txt /weather_data/keywords`
(3)`hadoop jar $HADOOP_HOME/share/hadoop/mapreduce/hadoop-mapreduce-examples-*.jar wordcount /weather_data/keywords/weather_keywords.txt /weather_data/keyword_count`
(4)`hdfs dfs -cat /weather_data/keyword_count/* | head -n 10` 统计结果输出到 /weather_data/keyword_count 目录并取前十行

3.子任务三：计算区域平均气温

(1)编写 MapReduce 程序，计算每个观测站所在区域（根据观测站 ID 前缀划分，如 STATION_BJ_001 前缀为 BJ）的月平均气温，输入数据格式为 **`观测站ID,观测时间戳,气温`**
(2)Map 函数需要从每条记录中提取 (区域-月份) 作为键（如 BJ-202501），气温作为值
(3)Reduce 函数需要计算每个 (区域-月份) 组合下的所有气温值的平均值
(4)将计算结果输出到 HDFS 的 `/weather_data/avg_temperature` 目录下，输出格式为 **`区域-月份 平均气温`**
(5)程序运行结果的前十行如下

```
区域-月份 平均气温
001-202501 23.23
001-202502 23.30
001-202503 19.68
001-202504 20.23
001-202505 13.75
001-202506 23.30
001-202507 23.85
001-202508 19.40
001-202509 15.50
001-202510 19.60
```

本数据集共有 58 个 (区域-月份) 组合。

项目三：业务分析与可视化

(一)任务一：数据分析与可视化

1.子任务一：数据分析

(1)一天中每个小时的平均温度、最高温度和最低温度：日温差最大的三个时段为 10 时 39.4°C、2 时 39.1°C、15 时 38.3°C，其中 10 时平均气温 26.22°C、最高 47.6°C、最低 8.2°C；全天气温最高的小时是 16 时（平均 28.98°C），最低的是 3 时（平均 15.46°C），一日内温差最大的三个时段集中在上午 10 时、凌晨 2 时和下午 3 时，说明夜间到清晨的辐射降温与午后日射增温叠加造成极值

(2)不同天气现象下的平均温度、平均降水量和平均风速：阴天平均温度最高 24.99°C，晴天最低 20.25°C，雪天降水量最大 6.03mm 且风速 3.46 m/s，雨天风速最小 3.22 m/s，雾天相对湿度高而温度居中（22.08°C）
(3)不同季节的温度与降水量模式差异：春季平均温度 21.82°C、总降水量 191.70mm，夏季 22.02°C、213.80mm，秋季 20.29°C、185.30mm，冬季 21.63°C、270.40mm。四季温度差异不足 2°C，但冬季降水量最高，是全年降水最集中的季节
(4)各观测站的日最高气温极值和日最低气温极值：STATION_001 最高 47.6°C、最低 -5.0°C，STATION_002 最高 37.5°C、最低 -1.0°C，STATION_003 最高 47.7°C、最低 4.2°C，STATION_004 最高 43.4°C、最低 -2.7°C，STATION_005 最高 43.2°C、最低 8.2°C。高温区域为 STATION_003（47.7°C），低温区域为 STATION_001（-5.0°C）
(5)降水量等级与平均相对湿度、平均风速的关系：无降水记录平均相对湿度 82.20%、平均风速 1.50 m/s，小雨等级平均相对湿度 62.22%、风速 3.60 m/s，中雨等级平均相对湿度 60.37%、风速 3.77 m/s，本数据集无大雨记录。降水强度越大空气越干、风速也略大，无降水时静风且湿度接近饱和

2.子任务二：数据可视化

(1)创建时间热力图展示一周内各时段（小时）的温度分布，横轴为星期（周一至周日），纵轴为小时（0-23 时），颜色冷暖表示温度高低
(2)使用多系列折线图展示一年中（按月份）的温度变化趋势，图中包含平均气温、历史同期最高气温和最低气温三条折线以便对比
(3)制作风向玫瑰图，展示特定区域（如某城市）在特定时期内（如一个季度）的风向频率分布，使用扇区表示风向，半径长度表示该风向出现的频率
(4)创建散点图分析温度与相对湿度的关系，横轴为温度（°C），纵轴为相对湿度（%），每个点的大小表示观测时的风速，颜色表示天气现象

(二)任务二：业务分析

1.基础指标分析

(1)气象数据质量评估：数据完整性方面，5 个观测站的气温、降水量、风速有效记录条数与总记录条数完全一致，完整率均为 100.00%（STATION_001 为 37 条、STATION_002 为 39 条、STATION_003 为 33 条、STATION_004 为 30 条、STATION_005 为 37 条）。数据稳定性方面，各站日温差的月际波动标准差分别为 STATION_001 0.08、STATION_002 0.89、STATION_003 3.80、STATION_004 1.33、STATION_005 0.00，STATION_003 的日温差月际波动最大。异常值检出率方面，以全体均值 ±3 倍标准差为基准，气温（均值 21.48°C、σ=9.81）检出 0 条占比 0.00%，相对湿度（均值 62.11%、σ=18.29）检出 0 条占比 0.00%，降水量（均值 4.89mm、σ=4.42）检出 3 条占比 1.70%，风速（均值 3.61m/s、σ=1.73）检出 1 条占比 0.57%，气压（均值 1013.57hPa、σ=14.39）检出 0 条占比 0.00%
(2)预报准确性对比分析：当前数据集只包含实际观测要素，不含预报温度与预报降水量字段，因此温度预报误差 MAE = mean(|实际气温 - 预报气温|)、降水预报准确率（正确判定的有降水/无降水记录数 ÷ 总记录数）与趋势一致性（预报升降温方向与实际一致的天数 ÷ 总天数）三项指

标无法用现有数据计算，计算公式已在 `业务分析.py` 中给出，补充预报数据后即可直接套用
(3)服务需求分析：日最高气温超过 35°C 的天数为 15 天，这些高温日在午后（12-18 时）的平均相对湿度为 54.16%、平均风速为 3.41 m/s，体感较干热；中雨及以上降水（降水量 ≥ 10mm）事件共 21 条，夜间发生 12 条、白天发生 9 条，伴随平均风速 3.77 m/s；人体舒适度区间（温度 18-26°C、湿度 40%-70%）全年有观测的天数为 138 天，其中处于舒适区间的仅 23 天，占比 16.67%，舒适度天数明显偏少

2.运营建议

(1)观测网络优化建议：STATION_003 的日温差月际波动标准差达 3.80，远高于其他观测站，建议核查该站传感器安装位置是否受局部热源或通风条件影响，同时对降水量异常记录占比 1.70%、风速异常记录占比 0.57% 的时段开展现场标定，提升观测数据稳定性
(2)预报模型与数据集补充建议：本数据集不含预报字段导致预报准确性无法评估，建议在数据采集环节同步落库每日发布的预报温度与预报降水量，并回溯积累近五年历史以支撑 ±3σ 异常基准的建立，使预报误差和命中率能够被持续量化
(3)公众气象服务建议：全年舒适区间天数占比仅 16.67%、大于 35°C 的高温日达 15 天，建议面向高温日推出午后时段（12-18 时）高温湿热指数预警与降温出行提示，面向降水集中时段（≥ 10mm 事件 21 条，其中夜间占 12 条）发布夜间强降水提醒，提升服务的针对性和公众可达性

项目四：AI 大模型应用开发综合实践

(一)任务一：AI 大模型服务综合部署

1.子任务一：基本配置

本任务需要使用 root 用户完成相关配置，已提供操作系统镜像及需要配置的前置环境，所需软件安装包均在 /root/ 目录下
(1)`mkdir -p /media/cdrom` 在 AI-SRV 中将操作系统镜像挂载至 /media/cdrom，并实现开机自启
情况一：镜像文件在 `/root/` 目录下

```
mount -o loop /root/openEuler-22.03-LTS-SP4-x86_64-dvd.iso /media/cdrom
```

情况二：镜像已通过虚拟光驱加载到设备 `/dev/sr0`

```
mount /dev/sr0 /media/cdrom
```

编辑 `vim /etc/fstab`

```
末尾添加
/dev/sr0    /media/cdrom    iso9660    defaults,ro    0    0
```

注意：
`/dev/sr0` 光驱设备名（用 `lsblk` 确认）
`/media/cdrom` 挂载点
`iso9660` 光盘文件系统类型
`defaults,ro` 表示默认选项且只读（推荐加 `ro` 以避免警告）
`0 0` 表示不备份、不检查
`mount -a` 验证
如果没有报错，说明配置成功
(2)`vim /etc/yum.repos.d/local.repo` 在 AI-SRV 中完成软件源配置文件的编写，禁用 GPG 校验，并为源数据建立缓存

```
[local]
name=Local Repository
baseurl=file:///media/cdrom
enabled=1
gpgcheck=0
```

`yum makecache` 建立缓存

```
(可能需要删除所有默认远程源)
cd /etc/yum.repos.d/
ls 查看是否有默认远程源
rm -f /etc/yum.repos.d/openEuler.repo 删除除了local.repo以外的
```

验证是否仅使用本地源

2.子任务二：环境搭建

本任务需要使用 root 用户完成相关配置，已提供 ollama 安装包及需要配置的前置环境
(1)`groupadd ollama` 为 ollama 配置用户/组，该用户仅用于运行服务，禁止其登录系统
`useradd -r -g ollama -d /usr/share/ollama -s /sbin/nologin ollama`
(2)`usermod -aG ollama root` 为 root 用户加入附加组 ollama
(3)`tar -zxvf /root/ollama-linux-amd64.tgz -C /usr` 将 ollama-linux-amd64.tgz 解压安装至 /usr 目录下
`mv /usr/bin/ollama /usr/bin/ollama_bak`（若提示目标已存在，先备份原程序）
`mv /usr/lib/ollama /usr/lib/ollama_bak`
`mv /usr/share/ollama /usr/share/ollama_bak`
(4)编写 SystemD 服务配置 `vim /etc/systemd/system/ollama.service`，使用服务运行专用用户完成启动，无论发生任何意外情况，服务都会进行自动重启（冷却 3 秒），以保证服务可靠运行，服务需要监听所有地址

```
[Unit]
Description=Ollama Service
After=network-online.target

[Service]
ExecStart=/usr/bin/ollama serve
User=ollama
Group=ollama
Restart=always
RestartSec=3
Environment="OLLAMA_HOST=0.0.0.0:11434"

[Install]
WantedBy=multi-user.target
```

`systemctl daemon-reload` 重载服务配置
(5)`systemctl enable ollama` 启动 ollama 服务并完成开机启动配置
`systemctl start ollama`
`systemctl status ollama` 查看服务状态，确认端口监听正常
(6)`ollama create qwen2.5:1.5b -f 1.5b.tgz` 导入 1.5b.tgz 压缩文件模型至 ollama
`ollama list` 查看已导入的模型列表

(二)任务二：AI 大模型综合应用开发

1.子任务一：Dify 运行环境搭建

本任务需要使用 root 用户完成相关配置，已提供安装 dify 及需要配置的前置环境
(1)`yum install -y docker` 在 AI-SRV 中完成 Docker 环境的安装
`systemctl start docker`
`systemctl enable docker`
`docker --version` 查看 Docker 版本信息
(2)`tar -zxvf /root/dify-0.14.2.tar.gz -C /opt` 将 dify-0.14.2.tar.gz 解压至 /opt 路径中
`cd /opt/dify/docker` 进入 dify 的 docker 目录
(3)`docker load -i /opt/dify/docker/dify-images/*.tar` 完成 dify 镜像的导入，相关文件位于 dify-images 目录中
`docker images` 检查镜像列表
(4)`docker compose up -d` 完成 dify 的启动，并在客户机中访问 AI-SRV 中的 dify web 服务
`docker ps` 查看容器运行状态
(5)在客户机中访问 dify，完成用户注册，邮箱为 admin@dify.ai，用户名为 admin，密码为 Qwer1234，注册后登录 dify 管理页面
(6)在客户机中访问 dify，完成对 ollama 模型提供商的注册，API 地址填 `http://<AI-SRV 的 IP>:11434`，模型名称选已导入的 qwen2.5:1.5b

2.子任务二：气象数据智能助手构建

(1)根据气象数据分析场景需要，创建空白应用 "Meteorological Data Assistant"
(2)为用户提供气象数据智能查询功能，其中参数包含 Query（查询内容），支持以下类型的查询
城市气候查询（如："查询'广州'的历史平均温度、年降水量"）
极端天气统计（如："查询 2025 年广东省最高气温超过 35°C 的天数"）
天气现象分析（如："查询'暴雨'事件的发生频率和平均持续时间"）
区域对比分析（如："对比珠三角和粤北地区的年平均风速"）
气象趋势预测建议（基于历史数据的简单推演）
(3)为确保结果准确性，需要从以下多个维度提供数据支持
基于 MySQL 数据库中的结构化气象数据（如 hddb 数据库中的 weather、city_info 等表）
基于清洗后的 CSV 文件（如 cleaned_weather_c5_N.csv 及相关处理结果）
基于大模型的智能解析和推理能力
(4)配置提示词要求
系统角色设定为"气象数据分析专家"
支持 SQL 查询语句的自动生成和解释
支持自然语言到气象数据分析需求的转换
输出结果需包含数据来源说明（如数据库表、CSV 文件等）
(5)运行应用，测试以下查询场景
"查询 2025 年广州市每月平均气温和降水量"
"广东省哪个城市在 2025 年出现暴雨次数最多？"
"对比深圳和珠海的风向频率分布"
"预测未来一周深圳的天气趋势（基于历史同期数据）"